UNIVERSITÀ DEGLI STUDI DI ROMA TOR VERGATA

MACROAREA DI INGEGNERIA



CORSO DI LAUREA MAGISTRALE IN
Ingegneria Medica

TESI DI LAUREA IN
Pattern Recognition & Machine Learning

Caratterizzazione e stratificazione label-free di linee cellulari di carcinoma prostatico mediante tecnologia ODEP e Deep Learning

Relatore:
Prof. *Eugenio Martinelli*

Laureanda:
Silvia Gialloreto
Matricola:
0350055

Correlatrici:
Dott.ssa *Joanna Filippi*
Prof.ssa *Arianna Mencattini*

Anno Accademico 2024/2025

Indice

Introduzione 4

1. Capitolo 1: Fondamenti biologici e tecnologici 5

1.1 Il Carcinoma Prostatico (PCa) 5

1.2 Complessità Biologica del PCa: Eterogeneità e Dinamiche Metastatiche 6

1.3 La Plasticità Epitelio-Mesenchimale (EMT) 7

1.4 Verso la caratterizzazione Single-Cell 8

1.5 Analisi Cellulare Tradizionale: la Citometria a Flusso 8

1.6 L'Evoluzione verso i MEMS e i Lab-on-a-Chip (LoC) 10

1.7 Analisi Label-Free e introduzione alla DEP 11

1.8 La Dielettroforesi (DEP) 11

1.8.1 Modellazione a Guscio delle Cellule Biologiche 15

1.9 Dalla DEP all'ODEP 19

2. Capitolo 2: Materiali e Metodi 23

2.1 Architettura del dispositivo ODEP 23

2.2 Protocollo di fabbricazione 25

2.2.1 Preparazione dei canali microfluidici 25

2.2.2 Perforazione del substrato di vetro superiore 26

2.2.3 Pulizia e bonding termico 28

2.2.4 Assemblaggio dei componenti superiori 29

2.2.5 Assemblaggio del supporto meccanico e contatti elettrici 31

2.3 Setup sperimentale 34

2.4 Preparazione dei campioni biologici 38

2.4.1 Linee cellulari di carcinoma prostatico 38

2.4.3 Preparazione del mezzo di sospensione (Buffer) 39

2.5 Procedura sperimentale e acquisizione dati 41

2.5.1 Principio della misura 41

2.5.2 Fase di stabilizzazione 42

2.5.3 Protocollo operativo e interfaccia GUI 43
2.5.4 Sequenza di misura 44
2.5.5 Analisi delle immagini con Deep Learning 46
3. Capitolo 3: Analisi dei dati e Deep Learning 47
3.1 Analisi Multimodale del Segnale ODEP 47
3.2 Pre-processing dei video 49
3.2.1 Segmentazione e centratura dinamica 49
3.2.2 Normalizzazione del background 50
3.2.3 Intensity stretching e organizzazione in clip 50
3.3 Classificazione tramite LDA 51
3.3.1 Il Contrasto di Michelson come indicatore di defocus 51
3.3.2 Estrazione delle feature 53
3.3.3 Selezione delle feature e modello di classificazione 53
3.4 Classificazione tramite Deep learning 54
3.4.1 Analisi morfologica dei frame 54
3.4.2 Architettura della rete neurale R(2+1)D 55
3.4.3 Strategia di confronto tra configurazioni 58
4. Capitolo 4: Risultati e Discussione 61
4.1 Dataset e Protocollo di Validazione 61
4.2 Risultati: valutazione dello sfocamento (LDA) 61
4.2.1 Accuratezza in funzione del numero di cicli 61
4.2.2 Matrice di confusione 63
4.2.3 Analisi dei risultati LDA 64
4.3 Risultati: classificazione tramite Deep Learning 64
4.3.1 Rete 2D convenzionale (SqueezeNet) 64
4.3.2 Rete R(2+1)D (configurazione statica) 66
4.3.3 Rete R(2+1)D (configurazione dinamica) 67
4.3.4 Confronto riassuntivo 68
4.4 Conclusioni e sviluppi futuri 69
BIBLIOGRAFIA 71

Ringraziamenti 79

Introduzione

Il carcinoma prostatico metastatico rappresenta una delle principali sfide cliniche in oncologia, rendendo urgente lo sviluppo di strumenti per la stratificazione precoce dell'aggressività tumorale a livello della singola cellula. In questo lavoro viene proposta una piattaforma *label-free* basata sulla tecnologia ODEP (Optically-induced Dielectrophoresis) su dispositivo lab-on-chip con strato fotoconduttore in silicio amorfo idrogenato (a-Si:H), applicata alla caratterizzazione e stratificazione di tre linee cellulari di carcinoma prostatico a diversa aggressività metastatica: LNCaP, DU145 e PC3. La prima novità del lavoro consiste nello sfruttare lo spostamento verticale della cellula lungo l'asse z indotto dal campo dielettroforetico, che si traduce in una firma caratteristica di sfocamento in frequenza utilizzata come parametro discriminante tra le tre linee cellulari. La seconda novità risiede nell'analisi di tale firma tramite una pipeline di deep learning che, per la prima volta in questo contesto, opera direttamente sui pixel dei frame acquisiti durante la manipolazione, estraendo simultaneamente informazioni morfologiche e dinamiche della cellula. A tal fine viene impiegata l'architettura R(2+1)D, una rete neurale convoluzionale spazio-temporale che, fattorizzando la convoluzione in una componente spaziale e una temporale, è in grado di modellare esplicitamente sia la morfologia cellulare nei singoli frame sia la sua evoluzione nel tempo durante il protocollo di stimolazione. I risultati mostrano un'accuratezza bilanciata dell'83% con la rete R(2+1)D dinamica, superiore alla baseline morfologica statica (78% con SqueezeNet 2D) e alla classificazione basata sul solo defocus scalare (61.7% con LDA), confermando il valore aggiunto dell'approccio proposto.

1. Capitolo 1: Fondamenti biologici e tecnologici

1.1 Il Carcinoma Prostatico (PCa)

La prostata è una ghiandola esocrina appartenente all'apparato genitale maschile, situata in posizione sottovescicale. La sua funzione fisiologica principale risiede nella secrezione di una componente fondamentale del liquido seminale, atta a garantire il nutrimento e la motilità degli spermatozoi, influenzando direttamente la fertilità e partecipando attivamente alla regolazione del flusso urinario. Dal punto di vista biochimico, la ghiandola è responsabile della sintesi dell'antigene prostatico specifico (PSA), un enzima proteolitico deputato alla liquefazione del coagulo seminale. Ad oggi, il PSA rappresenta il biomarcatore elettivo per il monitoraggio e la diagnosi precoce delle patologie prostatiche, tra le quali la più critica è certamente il cancro alla prostata (PCa).

Il PCa, nella maggior parte dei casi classificabile come adenocarcinoma, si conferma come la neoplasia più incidente nella popolazione maschile over-50 nei paesi occidentali. Come riportato dai dati più recenti del '*Cancer Statistics, 2026'*, esso costituisce una delle principali sfide per la salute pubblica globale. La patologia presenta solitamente una progressione lenta e asintomatica nelle fasi iniziali; tuttavia, negli stadi avanzati, manifesta un elevato tropismo metastatico, con una spiccata tendenza alla colonizzazione del tessuto osseo.

L'impatto clinico del PCa metastatico è severo, con una mortalità che supera i 400.000 decessi annui, dato che si prevede possa raddoppiare entro il 2040 [1]. La gestione terapeutica è ulteriormente complicata dall'evoluzione della patologia verso forme di carcinoma prostatico resistente alla castrazione (CRPC), una condizione refrattaria alla terapia di deprivazione androgenica (ADT) che rappresenta la causa primaria di morbilità [2]. L'ultimo stadio evolutivo, il CRPC resistente alla terapia (t-CRPC), configura un quadro clinico terminale per il quale non sussistono attualmente opzioni terapeutiche risolutive.

1.2 Complessità Biologica del PCa: Eterogeneità e Dinamiche Metastatiche

La complessità intrinseca del carcinoma prostatico (PCa) risiede nella sua natura multifocale e dinamica. La patologia non si presenta come un'entità biologicamente uniforme, ma è caratterizzata da una marcata eterogeneità inter-tumorale [3] e intra-tumorale [4].

- L'eterogeneità inter-tumorale implica la presenza contemporanea di diversi focolai indipendenti all'interno della ghiandola, caratterizzati da profili genomici distinti, diverse velocità di proliferazione e risposte differenziate ai protocolli farmacologici.

- L'eterogeneità intra-tumorale si manifesta invece all'interno del singolo focolaio, dove la coesistenza di subcloni cellulari, derivanti da un'origine multiclonale o da mutazioni cumulative durante la replicazione, rende il tumore un mosaico biologico in continua evoluzione. [5]

Questa variabilità molecolare, alimentata da una vasta gamma di geni "driver", è considerata il motore principale della progressione verso la resistenza farmacologica. La preesistenza di subcloni resistenti o la loro induzione a seguito del trattamento, determina spesso il fallimento delle terapie convenzionali. [6]
Tale scenario evidenzia un limite strutturale della biopsia prostatica standard (tissutale): essendo un campionamento localizzato, essa fallisce nel catturare l'intero spettro mutazionale e la complessità biologica dei diversi focolai, rischiando di trascurare subcloni minoritari ma estremamente aggressivi.
Comprendere i meccanismi alla base di questa progressione rappresenta una delle principali sfide della ricerca biomedica contemporanea. In questo contesto, l'eterogeneità si riflette nella migrazione cellulare, processo strettamente coinvolto nell'invasione e nella metastasi. Le cellule tumorali acquisiscono infatti un fenotipo invasivo, caratterizzato dalla perdita delle interazioni cellula-cellula e da un aumento significativo della motilità. Questo dinamismo consente loro di migrare dal sito primario di crescita, attraversando la matrice extracellulare (ECM) e penetrando nei vasi sanguigni o linfatici (intravasazione), per poi uscire dal sistema circolatorio (extravasazione) e colonizzare tessuti distanti.

La regolazione di questi processi migratori è mediata da una complessa rete di fattori, tra cui le integrine e gli enzimi deputati alla degradazione della ECM. Negli ultimi anni, è emerso come anche i segnali elettrici possano rappresentare un elemento di regolazione

cruciale. Le cellule trasformate presentano infatti alterazioni delle proprietà bioelettriche: mostrano una maggiore carica superficiale negativa e un potenziale di membrana generalmente più depolarizzato rispetto alle cellule sane. Tali gradienti di potenziale potrebbero agire come segnali direzionali in grado di guidare la migrazione tumorale, influenzata dall'intensità del campo elettrico e dallo stato delle vie di segnalazione intracellulare [7].

1.3 La Plasticità Epitelio-Mesenchimale (EMT)

Il cuore pulsante di questa transizione verso la metastaticità è la plasticità epitelio-mesenchimale, che svolge un ruolo chiave sia nella disseminazione del PCa che nella resistenza ai trattamenti [8],[9]. La transizione epitelio-mesenchimale (EMT) è un processo molecolare necessario durante lo sviluppo embrionale per i cambiamenti morfogenetici [10], che le cellule neoplastiche "sequestrano" per i propri scopi invasivi. Le cellule epiteliali, normalmente connesse da giunzioni aderenti e desmosomi, vengono convertite in uno stato mesenchimale attraverso un programma finemente regolato [11]. Durante l'EMT, le proprietà di adesione vengono perse a favore di un fenotipo invasivo che promuove la resistenza all'apoptosi e la progressione metastatica [12], generando così uno spettro di stati ibridi con diverse capacità metastatiche [13].

Come illustrato schematicamente nella Figura 1.1 alla fine del paragrafo, l'attivazione del programma di EMT permette alle cellule del carcinoma *in situ* di distaccarsi dalla massa primaria, invadere lo stroma circostante e penetrare nel torrente ematico (intravasazione). Nel contesto del carcinoma prostatico, la transizione epitelio-mesenchimale (EMT) non rappresenta solo un meccanismo di fuga cellulare, ma determina una profonda ristrutturazione del citoscheletro e della morfologia superficiale. Tali cambiamenti fenotipici si riflettono direttamente sulle proprietà dielettriche intrinseche delle cellule (quali capacità di membrana e conducibilità), rendendo la caratterizzazione biofisica un indicatore affidabile del grado di aggressività tumorale direttamente sui campioni bioptici.

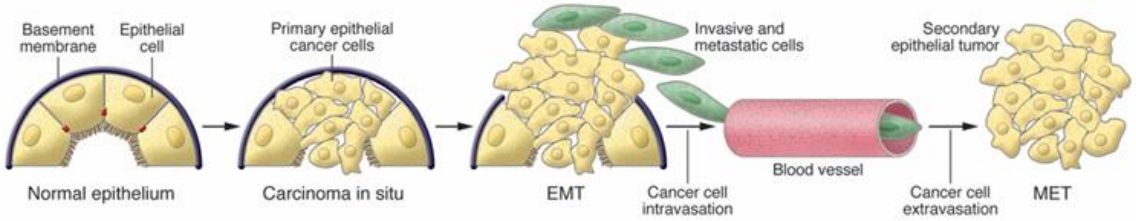


Figura 1.1: Rappresentazione schematica del ruolo dell'EMT nella progressione tumorale. Si evidenzia il passaggio da carcinoma in situ a tumore invasivo. [14]

1.4 Verso la caratterizzazione Single-Cell

Sebbene la biopsia tissutale rimanga il pilastro della diagnosi oncologica, la ricerca recente ha evidenziato come l'analisi morfologica convenzionale non sia sempre sufficiente a descrivere l'eterogeneità fenotipica intrinseca del carcinoma prostatico [15]. Le tecniche di analisi dell'intero tessuto tendono infatti a fornire un valore medio delle proprietà biologiche, mascherando la presenza di rare sottopopolazioni cellulari che hanno completato il processo di transizione epitelio-mesenchimale (EMT) discusso nel paragrafo precedente.

L'emergere delle tecnologie single-cell ha rivoluzionato questo approccio, permettendo di decodificare la complessità del microambiente tumorale con un'elevata precisione analitica. L'analisi individuale delle cellule, infatti, è fondamentale non solo per mappare l'eterogeneità genomica, ma anche per identificare quei cambiamenti biomeccanici e strutturali indotti dall'EMT che alterano la risposta cellulare agli stimoli esterni [16]. Nel contesto della progressione tumorale, passare dall'osservazione del tessuto alla caratterizzazione della singola cellula dissociata permette di isolare i profili più aggressivi basandosi sulla loro specifica 'firma' biofisica.

Tuttavia, l'isolamento e l'analisi di singole unità cellulari richiedono piattaforme in grado di gestire campioni in sospensione con elevata accuratezza. La necessità di processare tali campioni ha portato, storicamente, all'adozione della metodologia che rappresenta tuttora il riferimento principale in ambito clinico e di ricerca.

1.5 Analisi Cellulare Tradizionale: la Citometria a Flusso

Lo standard per la caratterizzazione di sottopopolazioni cellulari eterogenee è la Citometria a Flusso, che misura le proprietà ottiche e di fluorescenza di singole particelle in un flusso di fluido quando passano attraverso una sorgente luminosa [17]. Il sistema integra quattro pilastri:

- Fluidica: responsabile di dirigere il liquido verso la sorgente luminosa tramite un flusso coassiale (*sheath fluid*), creando una focalizzazione idrodinamica che allinea le cellule in fila singola attraverso il raggio laser [18].
- Ottica: la luce laser colpisce la cellula generando diffusione (*scattering*), correlata alla morfologia, e fluorescenza, proporzionale ai marcatori legati ai target.
- Elettronica e Computazione: convertono il segnale luminoso in dati digitali. [19]

L'architettura complessiva di un citometro a flusso è schematizzata in Figura 1.3, dove si osserva il percorso del segnale dalla camera di flusso microfluidica fino all'elaborazione digitale sul computer di controllo.

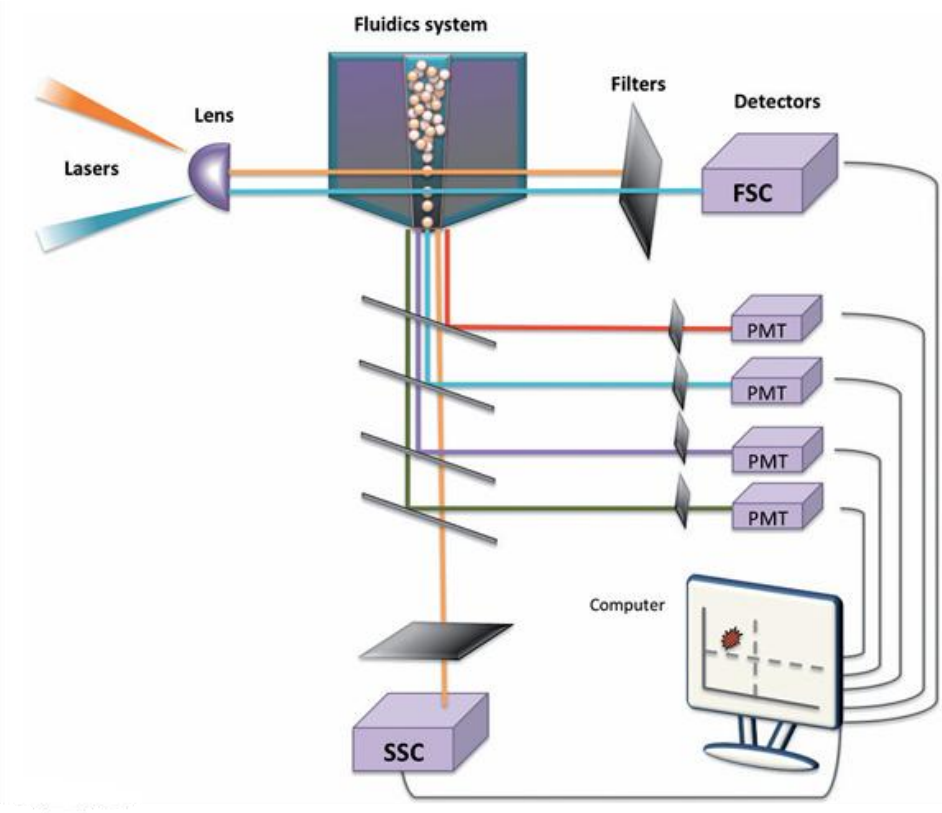


Figura 1.3: Rappresentazione schematica dei componenti di un citometro a flusso: sistema fluidico per il trasporto del campione, sorgenti laser, filtri ottici per la selezione delle lunghezze d'onda e rilevatori (PMT) per la conversione del segnale luminoso in segnale elettronico. [20]

Esistono sistemi *non-sorting,* che consentono solo l'analisi delle popolazioni cellulari, e sistemi *sorting*, capaci di separare fisicamente popolazioni marcate in tempo reale. Tra questi ultimi, la variante più avanzata e maggiormente utilizzata è il FACS (Fluorescence-Activated Cell Sorting), che sfrutta l'etichettatura fluorescente con distinte lunghezze d'onda di eccitazione per identificare e smistare le cellule bersaglio, rappresentando oggi il gold

standard nella citometria ad alta risoluzione. Nonostante la sua diffusione, il FACS però presenta criticità significative nell'analisi di campioni rari:

- Alterazione nativa: la dissociazione dei tessuti può perturbare i profili di espressione genica originari. [21]
- Stress e Danni: gli stress enzimatici rischiano di degradare le proteine di superficie che fungono da marcatori [22],[23].
- Requisiti di Campionamento: richiede grandi quantità di cellule, risultando inadatto per campioni limitati [24],[25].
- Limiti della Marcatura: dipende dalla disponibilità di anticorpi e dal rischio di cross-reattività [26],[27], a cui si aggiungono i costi elevati dei reagenti fluorescenti e la necessità di personale altamente specializzato per la loro gestione e interpretazione dei risultati. Inoltre, l'ispezione visiva diretta è assente [28], con perdita di informazioni morfologiche fini. [29]

1.6 L'Evoluzione verso i MEMS e i Lab-on-a-Chip (LoC)

I metodi tradizionali di coltura e analisi cellulare, basati sull'utilizzo di piastre di Petri e flask, risultano oggi ampiamente standardizzati ma presentano limitazioni intrinseche quali l'elevato consumo di reagenti e campioni, la necessità di numerose operazioni manuali e una capacità ridotta di controllo fine del microambiente cellulare. In questo scenario, la tecnologia microfluidica, appartenente alla più ampia classe dei Sistemi Micro-Elettro-Meccanici (MEMS), si è affermata come una valida alternativa consentendo la manipolazione di volumi di fluido estremamente ridotti, nell'ordine dei nanolitri, all'interno di canali con dimensioni micrometriche.

Su questa base si è sviluppato il concetto di Lab-on-a-Chip (LoC), introdotto con l'obiettivo di miniaturizzare e integrare all'interno di un singolo dispositivo le operazioni tipicamente svolte in un laboratorio convenzionale. Tali piattaforme garantiscono una superiore efficienza operativa grazie alla possibilità di eseguire analisi ad alta produttività e alla drastica riduzione dei costi per singola cellula analizzata [30],[31],[32].

Oltre al vantaggio economico e prestazionale, i sistemi LoC permettono una vera e propria digitalizzazione dell'analisi biologica; l'uso di barcode molecolari univoci consente infatti

un conteggio digitale delle molecole di RNA, eliminando i bias sistematici tipici dei metodi di amplificazione tradizionali [33], [34]. Infine, la natura intrinsecamente modulare di questi dispositivi favorisce un'integrazione End-to-End, dove la raccolta del campione, l'analisi bioinformatica e la visualizzazione dei dati vengono condensate in un unico flusso di lavoro automatizzato [35],[36],[37]. L'affermazione della tecnologia LOC ha reso possibile integrare gradualmente strumenti di laboratorio da banco, storicamente ingombranti e costosi, in dispositivi palmari di pochi centimetri, mantenendo inalterate le prestazioni analitiche [38]. La fabbricazione di tali chip microfluidici richiede processi tecnologici avanzati per integrare strutture dedicate al pretrattamento, all'erogazione e alla manipolazione delle particelle [39]. In questo ambito, la separazione delle particelle è un processo cruciale che influenza direttamente la precisione del rilevamento [40].

1.7 Analisi Label-Free e introduzione alla DEP

L'applicazione della microfluidica permette analisi ad alta risoluzione su singola cellula. Il passaggio fondamentale risiede negli approcci label-free: poiché i marcatori molecolari possono risultare inaffidabili in condizioni patologiche [41],[42], l'identificazione basata su parametri fisici e comportamento elettrofisiologico permette di preservare la vitalità originale [43],[44].

Sebbene esistano tecniche consolidate come la filtrazione, ostacolata nei sistemi LOC dal rischio di intasamento del mezzo poroso [45],[46], la centrifugazione [47], la separazione magnetica [48], le *acoustic tweezers* [49], la cromatografia [50] o l'elettroforesi [51] (limitata alle sole particelle cariche), la Dielettroforesi (DEP) emerge come la tecnica più promettente. La DEP, infatti, a differenza di questi metodi, è un metodo label-free [52], economico, veloce e altamente selettivo, capace di isolare cellule basandosi esclusivamente sulle loro proprietà elettriche intrinseche [53].

1.8 La Dielettroforesi (DEP)

La tecnica DEP è stata scoperta per la prima volta all'inizio degli anni '50 da Herbert Pohl, i cui lavori pionieristici hanno aperto la strada all'applicazione di questo fenomeno all'analisi cellulare [54]. Essa si riferisce al movimento di particelle dielettriche causato dagli effetti di polarizzazione quando soggette a un campo elettrico non uniforme, generato da elettrodi metallici fissi integrati nel dispositivo microfluidico [55]. A differenza dell'elettroforesi, le

particelle nella DEP non devono necessariamente trasportare una carica netta, ma devono essere polarizzabili. Quando una particella è immersa in un campo elettrico, le cariche si accumulano all'interfaccia con il mezzo circostante, creando dei dipoli elettrici che interagiscono con il campo stesso.

In un campo elettrico uniforme, la forza risultante sulla particella è nulla poiché i dipoli sono bilanciati. Al contrario, in un campo elettrico non uniforme, la particella sperimenta una forza dielettroforetica (F_{DEP}) che la spinge verso regioni a maggiore o minore intensità di campo, a seconda della sua polarizzabilità rispetto a quella del mezzo; questo concetto è mostrato nella Figura 1.4 seguente, dove nel caso (A) si osserva l'equilibrio delle forze in campo uniforme e nel caso (B) la generazione della forza netta in presenza di un gradiente di campo.

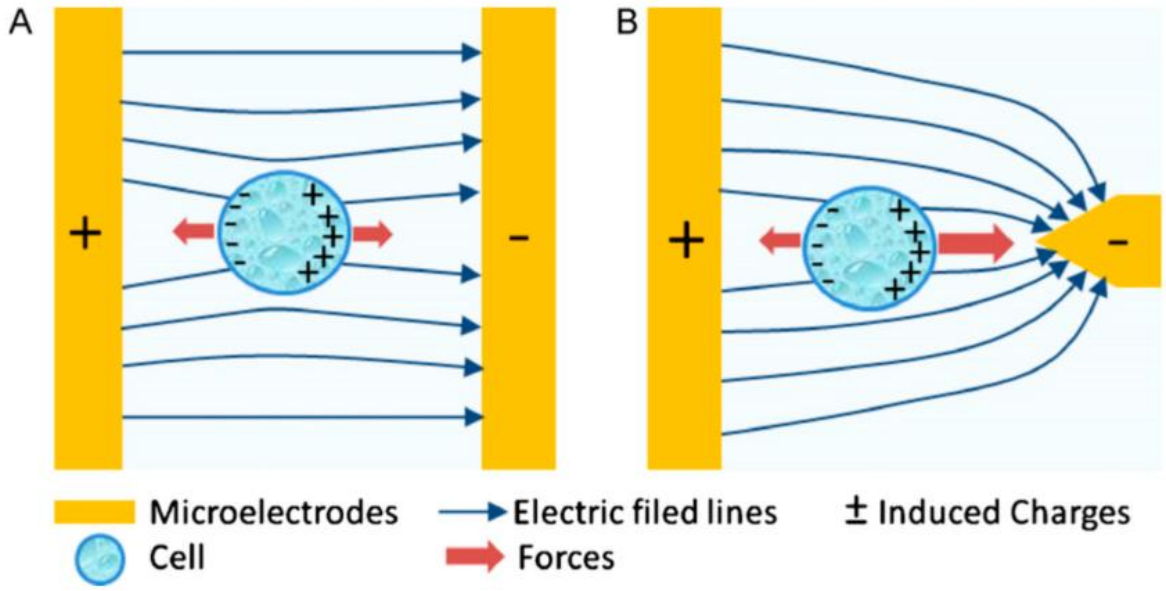


Figura 1.4: Comportamento di una particella polarizzabile: (A) in un campo uniforme le forze sui dipoli si elidono; (B) in un campo non uniforme la distribuzione asimmetrica delle cariche genera una forza netta verso il massimo del campo (se la particella è più polarizzabile del mezzo).[56]

L'ampiezza della forza dielettroforetica esercitata su una particella sferica e idealmente omogenea immersa in un fluido segue la seguente Equazione [57] (1):

$$F_{DEP} = 2\pi r_p^3 \varepsilon_m \mathrm{Re}[f_{CM}] \nabla E^2 \quad (1)$$

Dove:

- r_p è il raggio della particella sferica.
- ε_m è la permittività relativa del mezzo di sospensione.

- ∇E^2 è il gradiente del quadrato del valore efficace del campo elettrico applicato (E_{RMS}).
- $\mathrm{Re}[f_{CM}]$ è la parte reale del fattore di Clausius–Mossotti.

Il fattore di Clausius-Mossotti, che prende il nome dagli scienziati Ottaviano-Fabrizio Mossotti e Rudolf Clausius [58], riflette la polarizzabilità della cellula rispetto al mezzo e varia, per cellule sferiche, tra -0.5 e 1.0. Esso è definito tramite le permittività complesse della particella (ε_p^*) e del mezzo (ε_m^*):

$$f_{CM}(\omega) = \frac{\varepsilon_p^* - \varepsilon_m^*}{\varepsilon_p^* + 2\varepsilon_m^*} \quad (2)$$

dove la permittività complessa incorpora la conduttività elettrica (σ) e la frequenza angolare del campo (ω) : $\varepsilon^* = \varepsilon\varepsilon_0 - j(\sigma/\omega)$, con $j = \sqrt{-1}$ e $\omega = 2\pi f$. Le componenti reale e immaginaria del fattore sono espresse come [59]:

$$\mathrm{Re}(f_{CM}) = \frac{(\sigma_p - \sigma_m)(\sigma_p + 2\sigma_m) + \omega^2(\varepsilon_p - \varepsilon_m)(\varepsilon_p + 2\varepsilon_m)}{(\sigma_p + 2\sigma_m)^2 + \omega^2(\varepsilon_p + 2\varepsilon_m)^2} \quad (3)$$

$$\mathrm{Im}(f_{CM}) = \frac{3\omega(\varepsilon_m\sigma_p - \varepsilon_p\sigma_m)}{(\sigma_p + 2\sigma_m)^2 + \omega^2(\varepsilon_p + 2\varepsilon_m)^2} \quad (4)$$

La parte immaginaria è associata alle perdite energetiche (calore) durante la polarizzazione [60].

Esistono due limiti asintotici fondamentali per la parte reale:

- Basse frequenze ($\omega \to 0$): il fattore è dominato dalle conduttività, $f_{CM} = \frac{\sigma_p - \sigma_m}{\sigma_p + 2\sigma_m}$. $Se\ \sigma_p > \sigma_m$ si ha pDEP, altrimenti nDEP.
- Alte frequenze ($\omega \to \infty$): il contributo ionico è trascurabile e dominano le permittività, $f_{CM} = \frac{\varepsilon_p - \varepsilon_m}{\varepsilon_p + 2\varepsilon_m}$.

La frequenza in cui $\mathrm{Re}[f_{CM}] = 0$ è definita frequenza di crossover (f_{co}):

$$f_{co} = \frac{1}{2\pi}\sqrt{\frac{(\sigma_m - \sigma_p)(\sigma_p + 2\sigma_m)}{(\varepsilon_p - \varepsilon_m)(\varepsilon_p + 2\varepsilon_m)}} \quad (5)$$

In questa condizione la polarizzabilità del mezzo e della particella sono uguali e la particella non risente di alcuna forza dielettrica, rimane dunque ferma. Tale parametro è fondamentale per separare particelle in una miscela, poiché la condizione di crossover avviene a frequenze diverse per tipi cellulari differenti [61].

Il segno della parte reale del fattore di Clausius-Mossotti ($\mathrm{Re}[f_{CM}]$) è l'elemento determinante per la direzione del movimento della particella rispetto al gradiente del campo, delineando due regimi operativi distinti (Figura 1.5):

1. DEP positiva (pDEP): si verifica quando $\mathrm{Re}[f_{CM}] > 0$. Il momento di dipolo indotto è nella stessa direzione del campo e la cellula migra verso le regioni ad alto gradiente (elettrodi).
2. DEP negativa (nDEP): si verifica quando $\mathrm{Re}[f_{CM}] < 0$. La cellula viene respinta dalle regioni ad alto gradiente poiché il momento di dipolo è opposto alla direzione del campo.

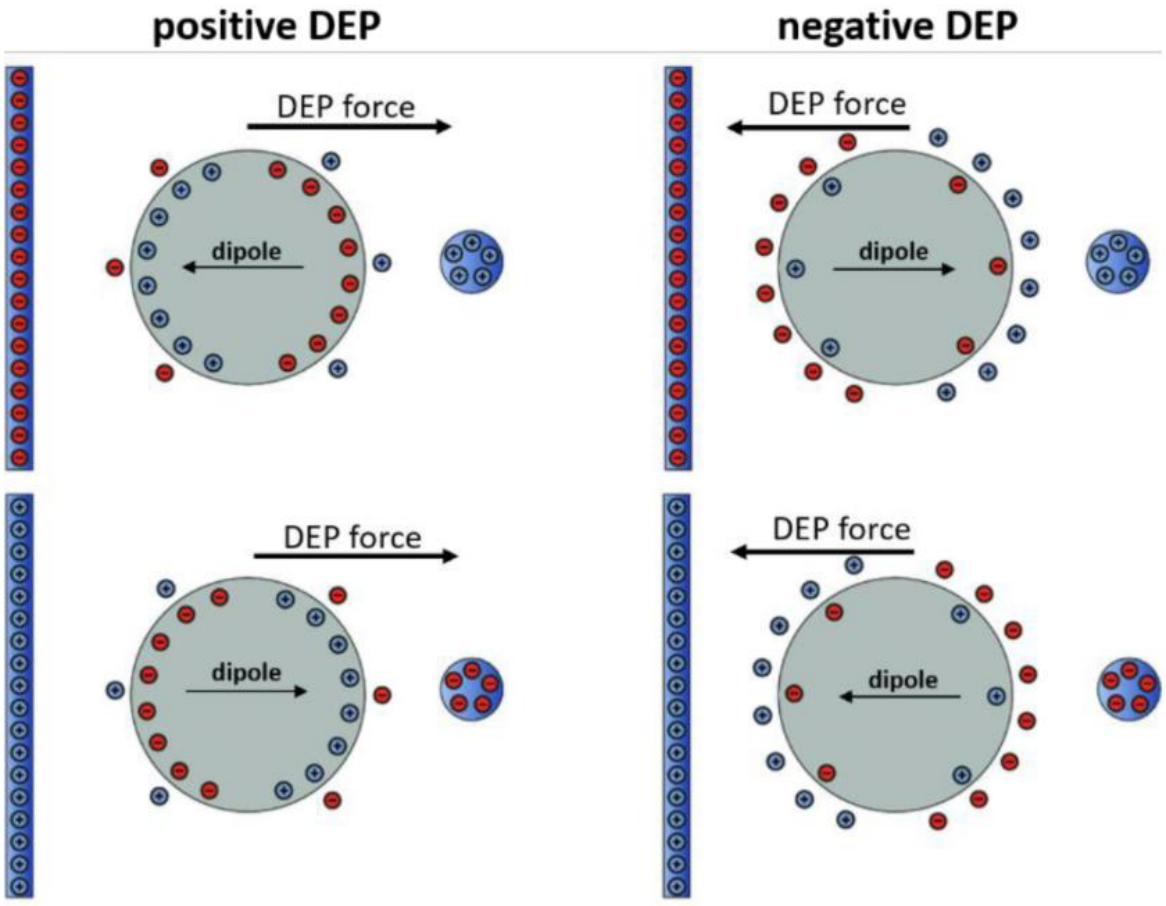


Figura 1.6: Rappresentazione schematica dei due regimi operativi della DEP. (a) DEP positiva (pDEP), che si verifica quando la polarizzabilità della particella (ε_p) è maggiore di quella del mezzo circostante (ε_m): la forza netta spinge la particella verso le regioni ad alto campo elettrico. (b) DEP negativa (nDEP), che si manifesta quando la polarizzabilità della particella è minore di quella del mezzo ($\varepsilon_p < \varepsilon_m$): la forza spinge la particella lontano dalle zone ad alta intensità, verso il minimo di campo. [62]

1.8.1 Modellazione a Guscio delle Cellule Biologiche

Una particella biologica, come una cellula, possiede una struttura complessa composta da più strati (citoplasma, membrana plasmatica, organelli e, in alcuni organismi, parete cellulare), ciascuno caratterizzato da proprietà dielettriche distinte. Quando tale struttura è soggetta a un campo elettrico alternato non uniforme, le cariche positive e negative si accumulano alle interfacce tra i diversi strati che la compongono e il mezzo circostante, generando dipoli indotti. Questo fenomeno, noto come polarizzazione di Maxwell-Wagner o polarizzazione interfacciale, è il meccanismo fisico fondamentale che governa la risposta dielettrica della cellula [63]: la distribuzione di queste cariche alle interfacce, e quindi l'entità del momento di dipolo risultante, dipende dalle proprietà dielettriche (conduttività e permittività) di ciascuno strato e dalla frequenza del campo applicato. È proprio questa dipendenza che rende la frequenza di crossover un parametro così sensibile alle proprietà intrinseche della cellula.

Di conseguenza, il calcolo del fattore di Clausius-Mossotti (f_{CM}) risulta particolarmente impegnativo e richiede l'adozione di un modello equivalente che sia in grado di incorporare fedelmente le caratteristiche dielettriche e morfologiche di ogni singolo strato.

Il modello semplificato più comunemente utilizzato rappresenta la cellula come una sfera circondata da gusci dielettrici concentrici, come illustrato nella Figura 1.7 seguente. In particolare, si può osservare il passaggio da un modello a guscio singolo (**a**), che considera solo la membrana plasmatica, a modelli più complessi a guscio multiplo (**b**) che includono organelli o la parete cellulare.

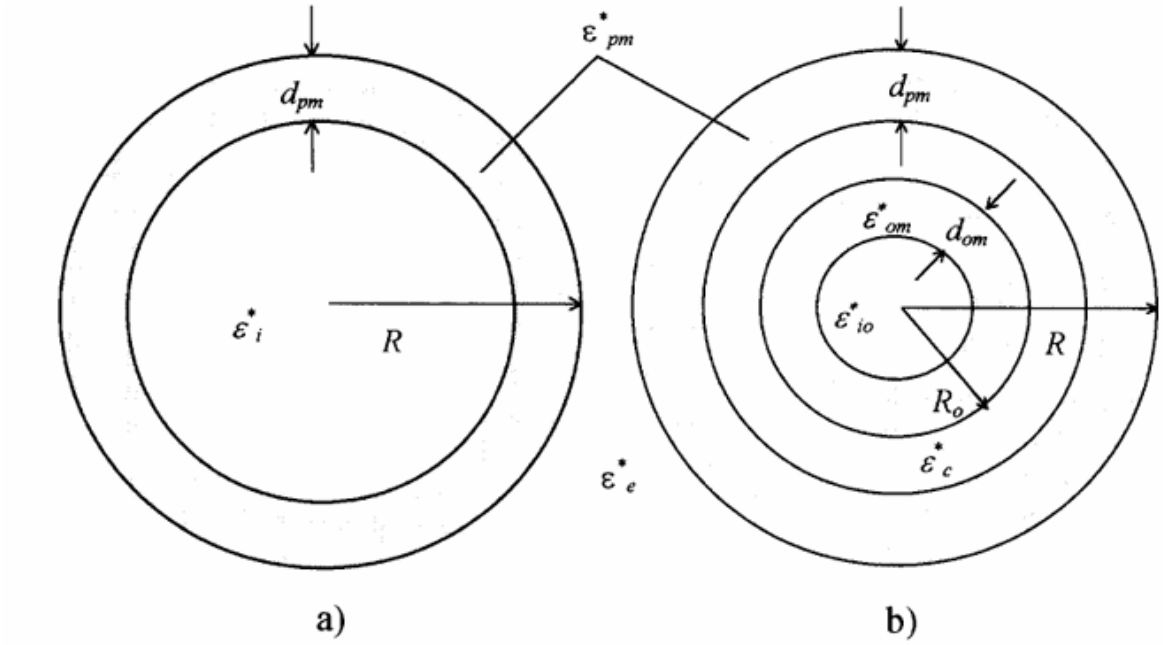


Figura 1.7: Modellizzazione dielettrica di una cellula: (a) modello single-shell e (b) modello multi-shell. Il sistema permette di schematizzare i diversi compartimenti cellulari assegnando a ciascuno specifiche proprietà di conduttività e permittività. [64]

Per i campi elettrici in corrente continua (DC), la conduttività efficace della cellula viene inizialmente calcolata tramite un modello a due gusci che considera il nucleo citoplasmatico e la membrana cellulare circostante. Tale conduttività ($\sigma_{p,2shell}$) è espressa come segue [65]:

$$\sigma_{p,2shell} = \sigma_{mem}\left[\frac{\left(\frac{r_{mem}}{r_{cyto}}\right)^3 + 2\left(\frac{\sigma_{cyto}-\sigma_{mem}}{\sigma_{cyto}+2\sigma_{mem}}\right)}{\left(\frac{r_{mem}}{r_{cyto}}\right)^3 - \left(\frac{\sigma_{cyto}-\sigma_{mem}}{\sigma_{cyto}+2\sigma_{mem}}\right)}\right] \quad (6)$$

In questa espressione, σ_{mem} e σ_{cyto} rappresentano rispettivamente le conduttività della membrana e del citoplasma, mentre r_{mem} e r_{cyto} indicano i rispettivi raggi.

Tuttavia, per ottenere una rappresentazione ancora più accurata che tenga conto anche delle proprietà della parete cellulare, è necessario passare al modello a tre gusci. Utilizzando la conduttività equivalente determinata nell'Equazione 6 come valore per il nucleo interno, la conduttività equivalente totale della particella ($\sigma_{p,3shell}$) può essere calcolata valutando la seguente espressione:

$$\sigma_{p,3shell} = \sigma_{wall}\left[\frac{\left(\frac{r_{wall}}{r_{mem}}\right)^3 + 2\left(\frac{\sigma_{p,2shell} - \sigma_{wall}}{\sigma_{p,2shell} + 2\sigma_{wall}}\right)}{\left(\frac{r_{wall}}{r_{mem}}\right)^3 - \left(\frac{\sigma_{p,2shell} - \sigma_{wall}}{\sigma_{p,2shell} + 2\sigma_{wall}}\right)}\right] \quad (7)$$

In questa seconda fase, σ_{wall} rappresenta la conduttività della parete cellulare e r_{wall} indica il raggio esterno totale della particella (parete inclusa). Questo approccio gerarchico permette di mappare con estrema precisione come i cambiamenti fisiologici, biochimici e morfologici della cellula, come quelli derivanti dal differenziamento cellulare o dai processi di apoptosi, influenzino i parametri dielettrici globali.

Ciò risulta essenziale in quanto diversi gruppi cellulari mostrano comportamenti dielettroforetici unici proprio a causa delle sottili differenze di dimensioni, capacità di membrana e conduttività interna degli strati.

Come mostrato in Figura 1.8, le cellule tumorali presentano una morfologia superficiale significativamente più complessa rispetto ai modelli cellulari idealizzati; la presenza di pieghe, microvilli e increspature (C, D) viene modellizzata attraverso il fattore di ripiegamento ϕ, un parametro introdotto per quantificare quanto l'area superficiale totale di una cellula superi l'area di un corpo paragonabile perfettamente liscio, calcolato appunto come il rapporto tra l'area effettiva della membrana cellulare e l'area di una cellula perfettamente liscia di volume simile.

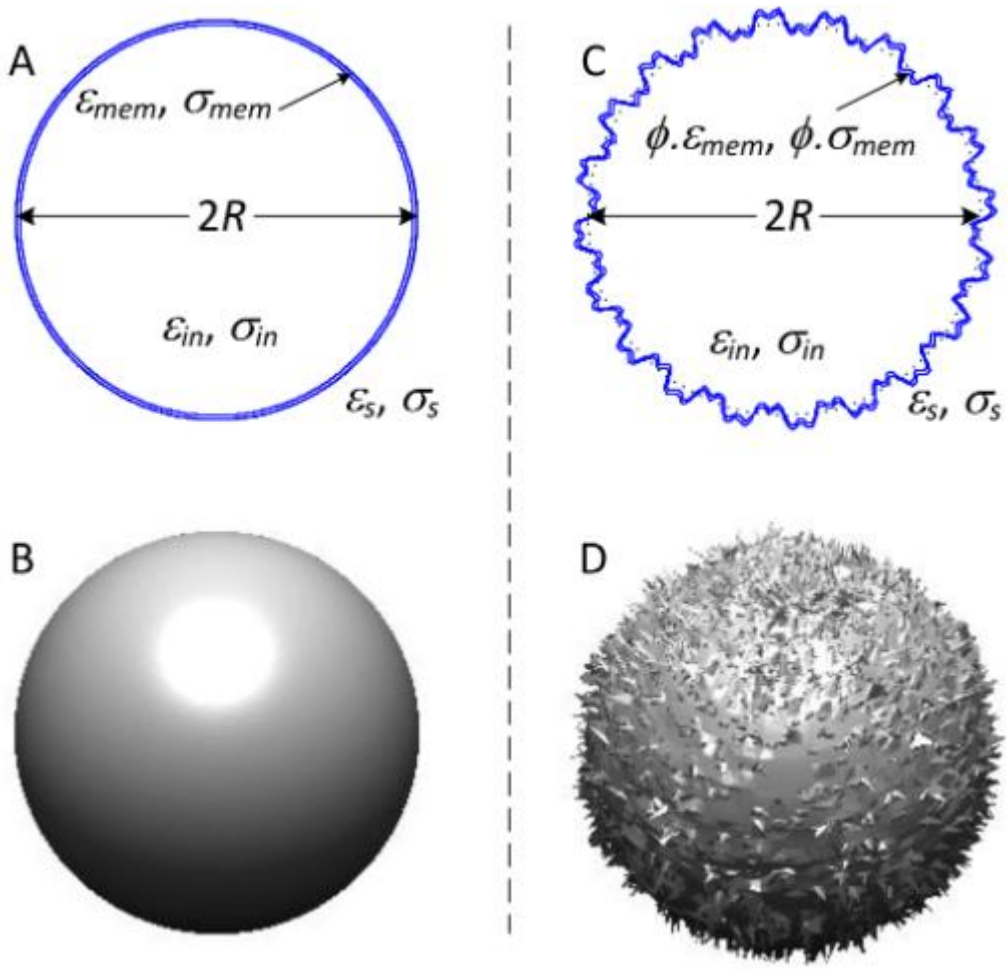


Figura 1.8: Modellazione della morfologia superficiale. (A, B) Rappresentazione di una cellula con membrana liscia idealizzata. (C, D) Rappresentazione di una cellula reale con membrana rugosa, dove il fattore di ripiegamento (ϕ) tiene conto dell'aumento dell'area superficiale tipico del fenotipo tumorale. [66]

Proprio grazie a queste differenti proprietà elettriche, la DEP ha trovato ampia applicazione nella ricerca sul cancro [67],[68]. Molti studi, infatti, evidenziano che la capacità di membrana (C_{mem}) delle cellule tumorali aumenta significativamente (dal 50% al 300%) a causa di una morfologia superficiale più complessa, ricca di pieghe, microvilli e increspature [69].

Esistono due rilassamenti dielettrici principali. Alle basse frequenze domina la nDEP guidata dalle conduttività. All'aumentare della frequenza, la capacità di membrana viene "cortocircuitata" a causa della polarizzazione interfacciale, portando alla prima frequenza di crossover (f_{co1}):

$$f_{co1} = \frac{\sqrt{2}\sigma_m}{2\pi r C_{mem}} \quad (8)$$

Poiché le cellule tumorali presentano raggio (r) e capacità di membrana (C_{mem}) maggiori rispetto alle cellule sane, esse mostrano frequenze di crossover significativamente più basse. Questa divergenza biofisica è validata sperimentalmente dai dati riportati in Figura 1.9, dove viene mappata la prima frequenza di crossover (f_{co1}) per diverse linee cellulari. Come si può osservare, esiste una netta separazione spettrale tra i tumori solidi (inclusa la prostata, evidenziata in nero) che si collocano in un range di frequenze ridotto, e le cellule del sangue normale (in rosso), che presentano invece frequenze di crossover molto più elevate.

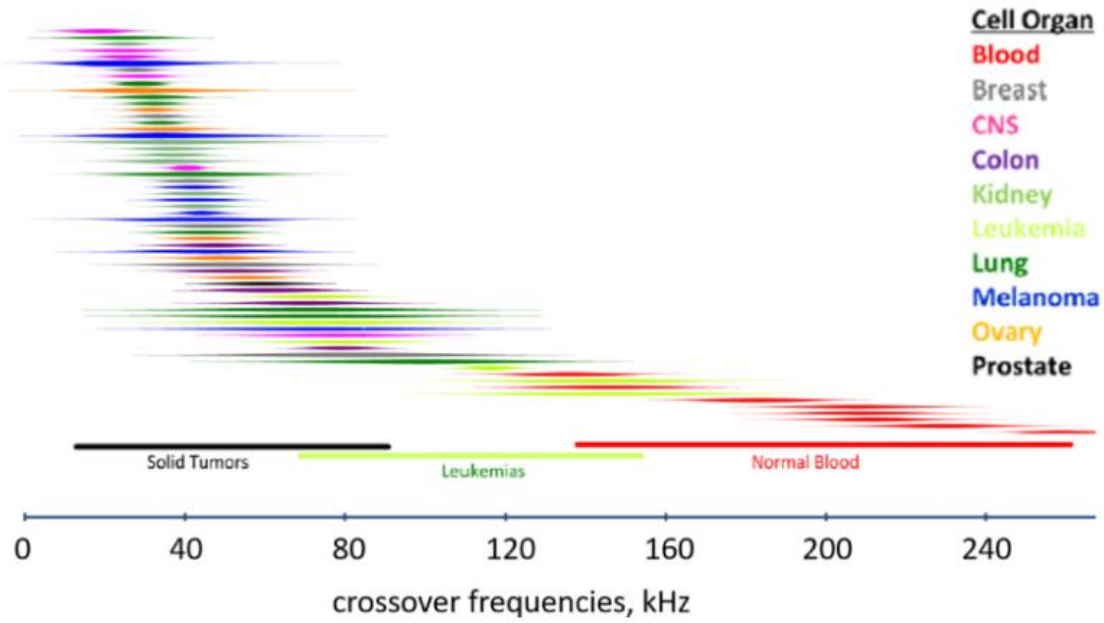


Figura 1.9: Risposte DEP di cellule cancerose e normali espresse in termini di prima frequenza di crossover (f_{co1}). [70]

Questo sfasamento nelle frequenze critiche permette di isolare con successo le cellule tumorali dai leucociti del sangue anche quando presentano dimensioni simili; operando alla frequenza opportuna, infatti, le cellule tumorali rimangono attratte dalle regioni di pDEP, mentre quelle del sangue sono respinte nelle zone di nDEP [71].

1.9 Dalla DEP all'ODEP

La dielettroforesi analizzata nel paragrafo precedente costituisce il fondamento fisico di una tecnica emersa negli ultimi anni, caratterizzata da un'elevata flessibilità e un'alta produttività: la dielettroforesi indotta dalla luce (ODEP), comunemente definita anche come pinzette

optoelettroniche (OET). Si tratta di una tecnologia all'avanguardia che combina sinergicamente stimoli luminosi e campi elettrici, sfruttando l'effetto fotoconduttivo dei materiali semiconduttori [72]. Rispetto ai metodi di manipolazione convenzionali, questo approccio permette di controllare il comportamento di micro/nano particelle o cellule in modo diretto, inducendo variazioni del campo elettrico per via ottica. Nello specifico, quando un pattern ottico illumina il materiale fotoconduttore sotto l'applicazione di un potenziale AC, si verifica una locale diminuzione dell'impedenza del materiale stesso. Questo fenomeno genera un campo elettrico non uniforme che esercita una forza dielettroforetica (DEP) sulle particelle o sulle cellule polarizzate, consentendo una manipolazione precisa e label-free

Dal punto di vista strutturale, il dispositivo ODEP convenzionale è costituito da due substrati di vetro conduttivo rivestiti di ossido di indio-stagno (ITO), che formano una camera microfluidica nel mezzo. Il substrato inferiore è rivestito con uno strato fotoconduttivo di silicio amorfo idrogenato (a-Si:H), che mostra caratteristiche di alta impedenza in assenza di luce. In questa condizione di 'buio', la tensione alternata applicata produce principalmente una caduta di tensione all'interno di questo strato, mentre nello strato liquido si forma solo un debole campo elettrico uniforme, insufficiente alla manipolazione [73]. Quando invece uno schema luminoso viene proiettato sulla superficie del chip, l'a-Si:H nell'area illuminata subisce una significativa diminuzione della resistività che porta la caduta di tensione a spostarsi verso lo strato liquido, inducendo un campo elettrico non uniforme distribuito a gradiente in prossimità dello schema luminoso [74].

La configurazione di questa camera microfluidica e il confronto con il principio di funzionamento della DEP tradizionale sono illustrati di seguito, nella Figura 1.10.

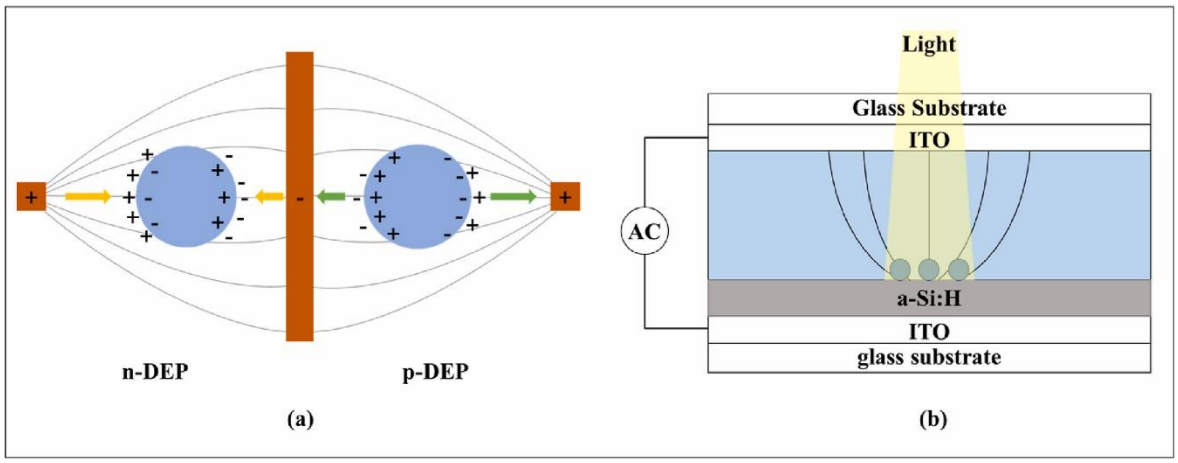


Figura 1.10: Rappresentazione schematica del principio di funzionamento: (a) Dielettroforesi tradizionale con elettrodi metallici fissi; (b) ODEP, dove l'illuminazione dello strato di silicio amorfo (a-Si:H) genera elettrodi virtuali all'interno della struttura a sandwich. [75]

Questo meccanismo di regolazione dinamica, basato sull'effetto fotoconduttivo, forma una matrice di elettrodi virtuali programmabili sulla superficie del substrato attraverso schemi ottici controllati dal computer. Diversamente dagli elettrodi metallici statici della DEP, la tecnologia ODEP genera quindi forze dielettroforetiche riconfigurabili in tempo reale, consentendo una manipolazione senza contatto, label-free e meccanicamente non invasiva di singole entità biologiche con precisione micrometrica.

Negli ultimi anni, la tecnologia ODEP è stata sviluppata e validata in diversi contesti di caratterizzazione cellulare label-free. In un primo lavoro [76], la firma dielettrica delle cellule è stata estratta attraverso spettri multi-frequenza di parametri cinematici e dinamici, quali lo spostamento cumulativo, la velocità massima e la forza DEP massima, ottenuti tramite il tracking del centroide nel piano xy. In una fase successiva [77], tale approccio è stato esteso all'analisi di traiettorie 2D multi-frequenza generate da due elettrodi alternati, caratterizzate tramite la Wavelet Scattering Transform (WST), aprendo la strada all'identificazione label-free di cellule singole in flusso. In un lavoro più recente [78], la piattaforma è stata ulteriormente arricchita integrando, oltre al centroide, l'analisi delle deformazioni ed orientazioni locali della cellula tramite PIV (Particle Image Velocimetry), aumentando il contenuto informativo della misura. Un primo tentativo di sfruttare la dinamica di sfocamento lungo l'asse z per la stratificazione di cellule prostatiche è stato infine proposto da Filippi et al. [79], dove il contrasto ottico della singola cellula viene monitorato nel tempo in risposta a stimoli ODEP alternati a diverse frequenze.

Parallelamente all'evoluzione delle piattaforme di manipolazione cellulare, il deep learning ha assunto un ruolo sempre più centrale nell'analisi di immagini biomediche da microscopia. In particolare, le reti neurali convoluzionali 2D (CNN) sono state ampiamente applicate per la classificazione e la fenotipizzazione di cellule singole a partire da immagini in campo chiaro, dimostrando capacità discriminative superiori rispetto ai metodi tradizionali [80]. Tuttavia, l'analisi di sequenze video acquisite tramite microscopia time-lapse richiede la modellazione simultanea di informazioni spaziali e temporali, un requisito che ha spinto verso lo sviluppo di architetture 3D CNN capaci di catturare le dinamiche cellulari nel tempo

[81]. Queste ultime, pur aumentando il potere rappresentativo, richiedono un numero molto elevato di parametri da addestrare, il che rappresenta una sfida critica in ambito biologico dove i dataset sono tipicamente limitati. Una soluzione promettente è rappresentata dall'architettura R(2+1)D, che fattorizza la convoluzione 3D in una convoluzione 2D spaziale e una 1D temporale, riducendo la complessità computazionale pur mantenendo la capacità di modellare separatamente morfologia e dinamica cellulare [82]. Tale architettura si è dimostrata particolarmente adatta all'analisi di video di microscopia time-lapse, dove le dinamiche degli oggetti in movimento sono lente e spesso non stazionarie nel tempo. Tuttavia, ad oggi, l'integrazione del deep learning con la tecnologia ODEP non è mai stata esplorata in letteratura.

Il presente lavoro si propone di colmare questo gap, introducendo per la prima volta l'utilizzo di algoritmi di deep learning per l'analisi diretta dei frame acquisiti durante la manipolazione optodielettroforetica. L'approccio proposto sfrutta l'intero contenuto informativo dei pixel dei frame, catturando simultaneamente variazioni di sfocamento, morfologia e texture della cellula durante la stimolazione, configurando la piattaforma ODEP come uno strumento di caratterizzazione biofisica multi-parametrica per la stratificazione delle linee cellulari di carcinoma prostatico metastatico: LNCaP (Lymph Node Carcinoma of the Prostate), DU145 (derivata da metastasi cerebrale) e PC3 (derivata da metastasi ossea di grado IV).

2. Capitolo 2: Materiali e Metodi

2.1 Architettura del dispositivo ODEP

Sulla base dei principi fisici introdotti nel capitolo precedente, il laboratorio dell'Università è stato la sede di fabbricazione del dispositivo ODEP impiegato in questo lavoro. Poiché la distribuzione delle linee di forza del campo e l'efficacia del processo di generazione dipendono fortemente dal design del dispositivo, la sua realizzazione richiede materiali e strati ben precisi.

La sua architettura si basa su una struttura a 'sandwich' composta da due substrati di vetro conduttivo, ciascuno rivestito da uno strato sottile di ossido di indio-stagno (ITO), che delimitano la camera microfluidica destinata alla manipolazione cellulare. In particolare, il substrato inferiore incorpora lo strato funzionale di silicio amorfo idrogenato (a-Si:H) il quale, come introdotto nella sezione 1.9, agisce da fotoconduttore per la generazione degli elettrodi virtuali. In condizioni di oscurità, l'alta impedenza del silicio confina la maggior parte della caduta di potenziale all'interno dello strato solido; al contrario, sotto l'azione di uno stimolo luminoso, l'assorbimento dei fotoni genera coppie elettrone-lacuna che ne aumentano significativamente la conduttività [83]. Questo processo sposta localmente la caduta di tensione verso lo strato liquido in corrispondenza delle aree illuminate, producendo gradienti di campo elettrico ad alta intensità che esercitano forze dielettroforetiche sulle cellule circostanti [84]. Risulta dunque fondamentale analizzare nel dettaglio la sequenza di fabbricazione, la geometria e le proprietà dei materiali di ciascun componente per poter interpretare correttamente i risultati sperimentali mostrati nel prosieguo del lavoro.

Il dispositivo LOC è stato dunque progettato mediante il software di modellazione parametrica Autodesk Inventor® e successivamente fabbricato in laboratorio. Come illustrato nella vista esplosa riportata in Figura 2.1, l'architettura del chip è articolata in diversi strati raggruppabili in tre sottosistemi principali: il supporto meccanico (holder), la camera microfluidica e la parte superiore di chiusura.

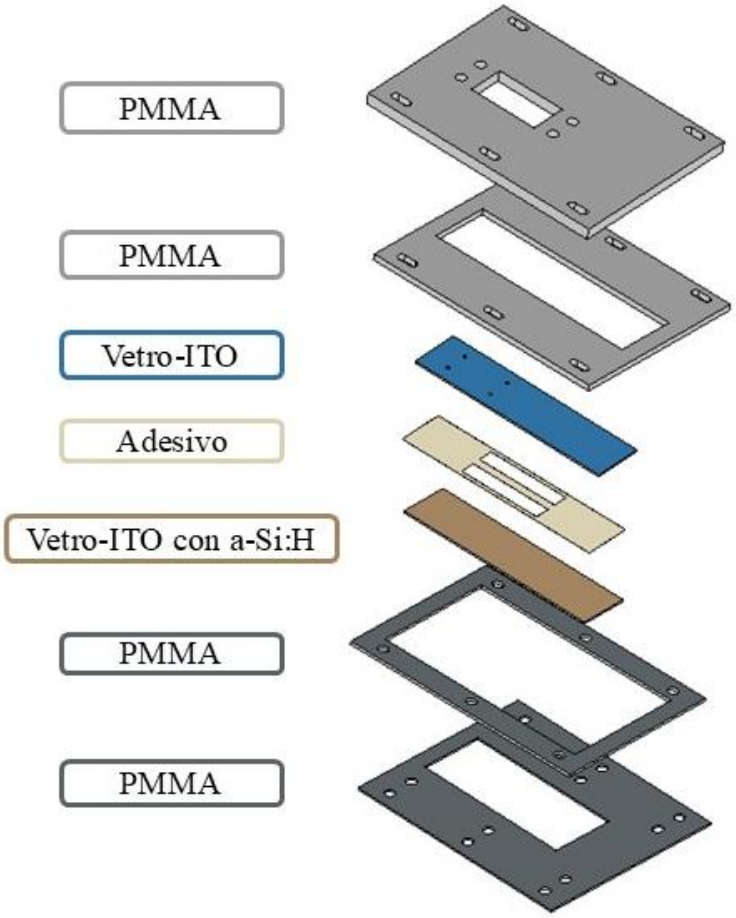


Figura 2.1: Vista esplosa del dispositivo LOC.

Il nucleo funzionale del dispositivo è la camera microfluidica con due canali, posizionata tra due substrati di vetro, ciascuno rivestito da uno strato conduttivo trasparente di ossido di indio-stagno (ITO) dello spessore di 200 nm. L'ITO è un ossido semiconduttore degenere ampiamente utilizzato in applicazioni optoelettroniche grazie alla sua combinazione unica di elevata conducibilità elettrica e alta trasmittanza ottica nel visibile [85], caratteristiche indispensabili per consentire simultaneamente il passaggio della luce di proiezione e la generazione del campo elettrico.

Uno dei due substrati è rivestito da uno strato di silicio amorfo idrogenato (a-Si:H), depositato tramite tecnica PECVD (Plasma-Enhanced Chemical Vapour Deposition) con uno spessore di 600 nm. Tra di essi, la camera è rappresentata da un sottile strato di adesivo (60 μm) su cui sono stati sagomati, mediante tagliatrice laser (Speedy 100, Trotec Laser Inc., Austria), i due canali microfluidici. La configurazione a doppio canale consente di eseguire due condizioni sperimentali in parallelo, ottimizzando l'utilizzo del substrato fotoconduttivo

e riducendo il rischio di deterioramento dello strato di a-Si:H. Lo spessore dell'adesivo definisce l'altezza della camera e rappresenta un parametro critico del dispositivo: una distanza inter-elettrodo ridotta è infatti necessaria per garantire che il gradiente di campo elettrico indotto dallo strato fotoconduttivo non si disperda in maniera eccessiva nel mezzo liquido prima di raggiungere le cellule in sospensione. Il substrato superiore, invece, presenta quattro forellini passanti, realizzati tramite perforazione con punta diamantata, che servono per il caricamento del campione biologico.

La parte superiore del dispositivo, invece, è progettata per ospitare i reservoir del campione e prevenire l'evaporazione del mezzo e si compone di due substrati di PMMA (polimetilmetacrilato), entrambi realizzati tramite taglio laser, di spessore rispettivamente 0.8 mm e 5 mm. Questi due componenti vengono incollati tra loro con adesivo e pressati a circa 100bar. Il PMMA è una termoplastica trasparente, considerata un materiale standard nella fabbricazione di dispositivi LOC proprio grazie alla sua trasparenza ottica, la sua facilità di lavorazione con taglio laser e la sua biocompatibilità [86].

Anche il supporto meccanico inferiore (holder) è stato realizzato in PMMA con taglio laser, e si compone di due strati da 3 mm incollati tra loro. Su di esso sono stati applicati nastri di rame conduttivo per garantire il contatto elettrico con entrambi i substrati di ITO. Il contatto con l'ITO inferiore è realizzato direttamente sull'holder, mentre quello con l'ITO superiore è ottenuto tramite viti conduttive che attraversano il PMMA superiore. Il dispositivo assemblato viene infine alloggiato nel supporto del microscopio (PeCon GmbH, Germany), consentendo l'integrazione con il sistema ottico di proiezione, descritto nei paragrafi successivi.

2.2 Protocollo di fabbricazione

In questo paragrafo vengono mostrati i vari step in cui si articola la fabbricazione del dispositivo LOC, che comprendono operazioni di taglio, pulizia e bonding e che coinvolgono materiali diversi, quali vetro, adesivi e polimeri. Il passaggio più critico dell'intero processo è rappresentato dalla perforazione del substrato di vetro, descritto nella sezione 2.2.2.

2.2.1 Preparazione dei canali microfluidici

I canali microfluidici sono stati realizzati mediante taglio laser di uno strato di adesivo tecnico (467 MP transfer tape, 3M™), utilizzando il sistema Trotec Speedy 100 (Trotec Laser Inc., Austria) con geometria progettata tramite il software JobControl.

Come illustrato in Figura 2.2, il design prevede due canali paralleli che consentono l'analisi simultanea di due diverse condizioni sperimentali. Ciascun canale presenta una larghezza di 8 mm e una lunghezza di 20 mm, per una superficie totale di 189 mm²; poiché lo spessore dell'adesivo definisce l'altezza della camera a 60 μm, il volume di campione biologico che può essere caricato in ciascun canale risulta pari a circa 11.34 μL.



Figura 2.2: Design e geometria dei canali microfluidici

2.2.2 Perforazione del substrato di vetro superiore

Come già descritto nel Paragrafo 2.1, la camera è alloggiata tra due substrati di vetro rivestiti da un sottile strato di ITO, entrambi di dimensioni 75 mm x 25 mm e spessore 2 mm. Il substrato inferiore incorpora inoltre lo strato funzionale di silicio amorfo idrogenato (a-Si:H), depositato su una superficie di 50 mm x 25 mm, come mostra la Figura 2.3 seguente.



Figura 2.3: Substrato inferiore in vetro-ITO con deposizione di un film sottile di silicio amorfo idrogenato (a-Si:H).

Il substrato di vetro superiore è invece destinato ad ospitare i fori di inlet e outlet per il caricamento del campione biologico e la loro realizzazione risulta essere lo step più critico dell'intero processo, poiché il vetro è un materiale fragile e soggetto facilmente a rottura se sottoposto a stress meccanici non controllati. La perforazione viene eseguita esclusivamente dal lato non conduttivo del substrato, così da preservare l'integrità dello strato di ITO. Il vetrino viene fissato su un supporto di legno tramite nastro adesivo per garantirne la stabilità durante la lavorazione e nei punti prestabiliti per i fori viene applicato un olio lubrificante che riduce l'attrito e minimizza il rischio di frattura. La perforazione avviene tramite punte diamantate specifiche per il taglio del vetro che si montano su un trapano a colonna, come visibile in Figura 2.4.

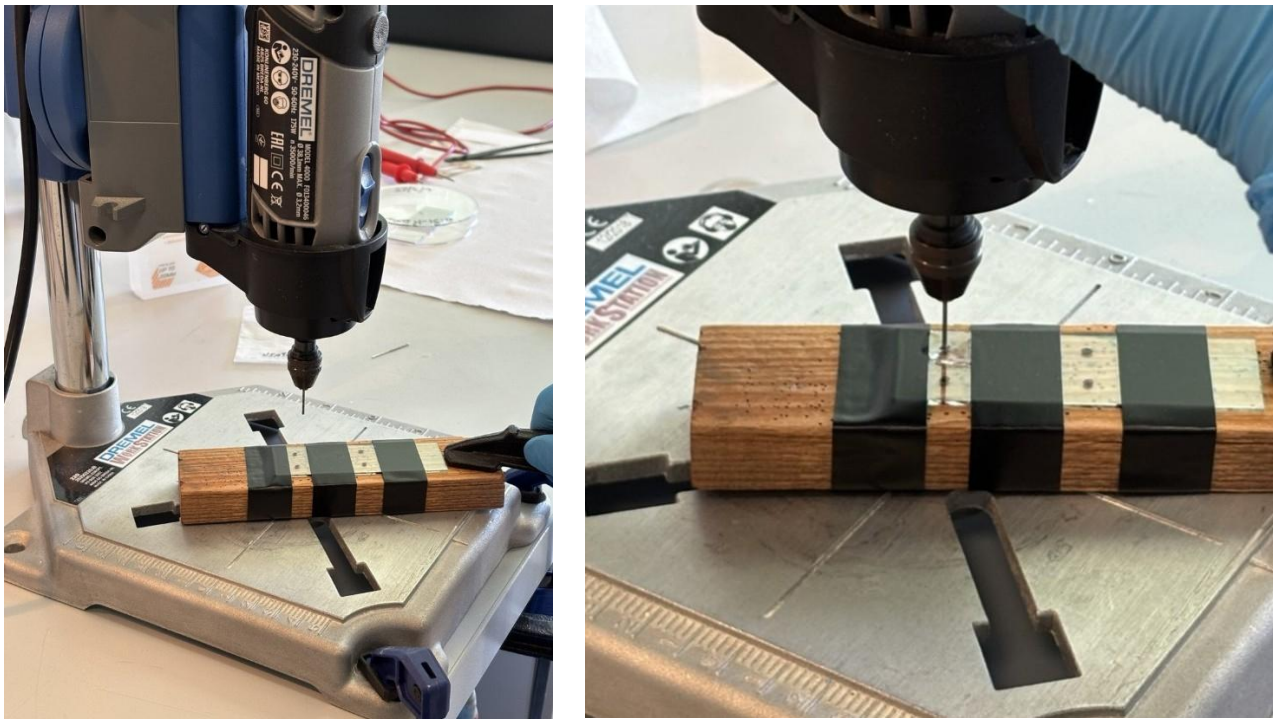


Figura 2.4: Setup sperimentale per la perforazione meccanica del substrato superiore.

Si ottiene così un substrato con quattro fori passanti, disposti a coppie in corrispondenza degli inlet e outlet di ciascun canale per il caricamento dei campioni (Figura 2.5).



Figura 2.5: Substrato superiore in vetro-ITO dopo la realizzazione dei fori.

2.2.3 Pulizia e bonding termico

Eseguita la perforazione, è essenziale procedere con una pulizia accurata del substrato superiore per rimuovere ogni residuo di olio e di polvere che potrebbero compromettere l'adesione e la qualità ottica del chip. Il protocollo di pulizia prevede prima un lavaggio con sgrassatore, successivamente un trattamento in sonicatore (strumento che sfrutta le onde

ultrasoniche per rimuovere contaminanti superficiali) con acqua distillata e detergente per 5 minuti ed infine un ultimo risciacquo con etanolo.

A questo punto si procede con l'assemblaggio del 'sandwich' microfluidico: si posizionano i canali adesivi sul substrato inferiore contenente lo strato di a-Si:H, accertandosi di orientare il lato conduttivo verso l'interno della camera; lo stesso si ripete con il substrato superiore, che viene invece adagiato sopra con il lato conduttivo rivolto verso l'interno e lasciando una porzione laterale di ITO libera per i contatti elettrici. Il bonding termico avviene in una pressa riscaldata a 70° per 15 minuti: al posto di una forte pressione meccanica, si sfrutta il calore per scaldare l'adesivo e permettergli di sigillare la camera, evitando così l'applicazione di stress meccanici che potrebbero fratturare il vetro. Questo primo assemblaggio è mostrato nella Figura 2.6 seguente.

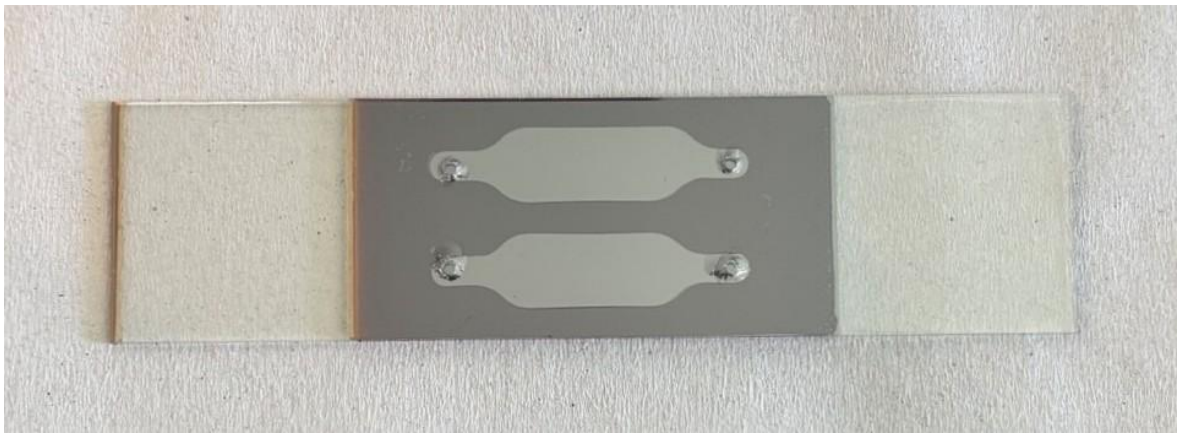


Figura 2.6: Prima fase di bonding termico: assemblaggio dei due substrati di vetro con interposizione del layer adesivo che definisce il volume della camera microfluidica.

2.2.4 Assemblaggio dei componenti superiori

La parte superiore del dispositivo, che ospita i reservoir del campione e previene l'evaporazione del mezzo durante gli esperimenti, è anch'essa realizzata tramite taglio laser di due strati di PMMA di dimensioni 85 mm x 60 mm, con spessori di 0.8 mm e 5 mm, rispettivamente. Essi vengono incollati tra loro con adesivo e pressati a 100 bar per un'adesione accurata. La Figura 2.7 mostra i due componenti separati (a) e a seguito del loro assemblaggio (b).

(a)



(b)



Figura 2.7: (a) Componenti in PMMA per la realizzazione dei reservoir prima della giunzione. (b) Blocco dei reservoir dopo il processo di pressatura.

Completato questo passaggio, si procede con l'unione di questi due componenti con il 'sandwich' di vetrini descritto nella sezione 2.2.3. L'intero sistema viene quindi nuovamente pressato a 70°C per 15 minuti, completando così l'integrazione strutturale della camera microfluidica con i reservoir (Figura 2.8).

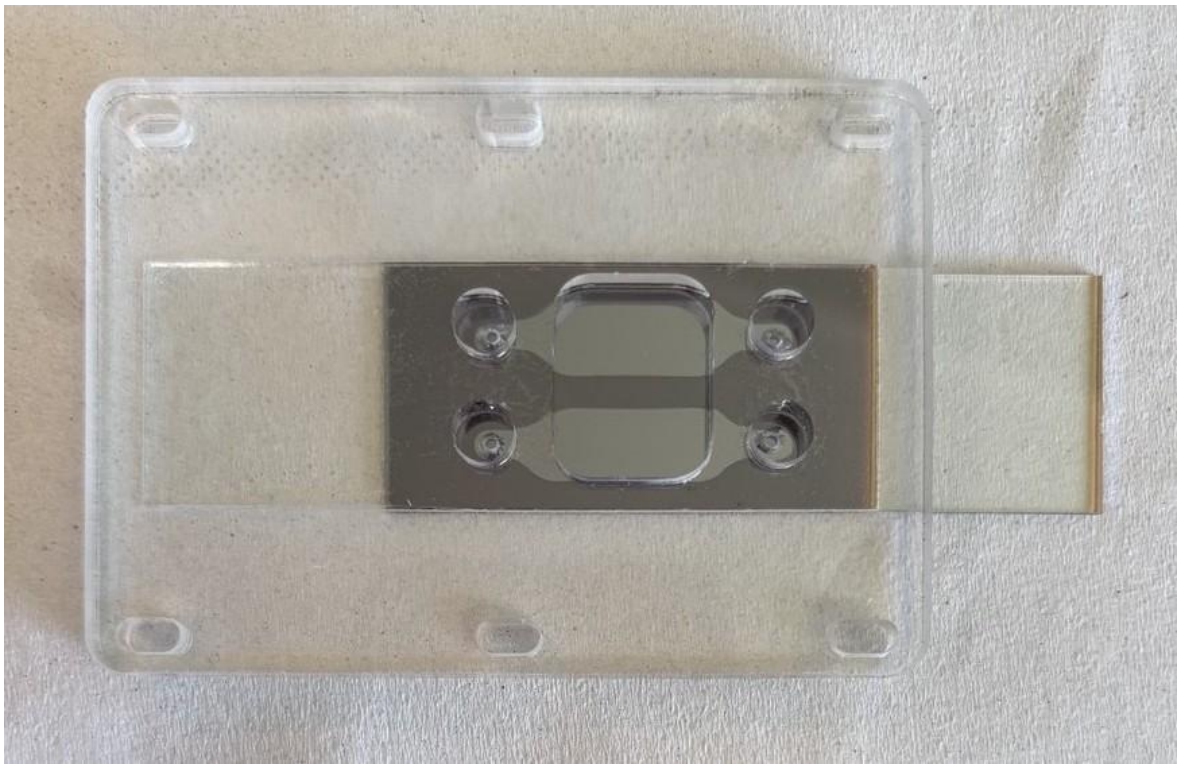


Figura 2.8: Dispositivo a seguito della seconda fase di bonding termico: integrazione finale tra la camera microfluidica e i reservoir.

2.2.5 Assemblaggio del supporto meccanico e contatti elettrici

Il supporto meccanico inferiore (holder) è composto da due strati di PMMA realizzati con taglio laser: uno da 3 mm (TroGlass Clear, Trotec Laser Inc., Austria) e l'altro da 0.8 mm (TroLase, Trotec Laser Inc., Austria). Su quest'ultimo viene applicato un nastro di rame conduttivo (AT526, Advance Tapes International, Leicester, UK) per creare il contatto elettrico con il substrato di ITO inferiore. I due strati vengono avvitati insieme e collegati, tramite un terzo strato di PMMA da 3 mm che funge da adattatore, al tavolino del microscopio (PeCon GmbH, Germany), come illustrato in Figura 2.9.

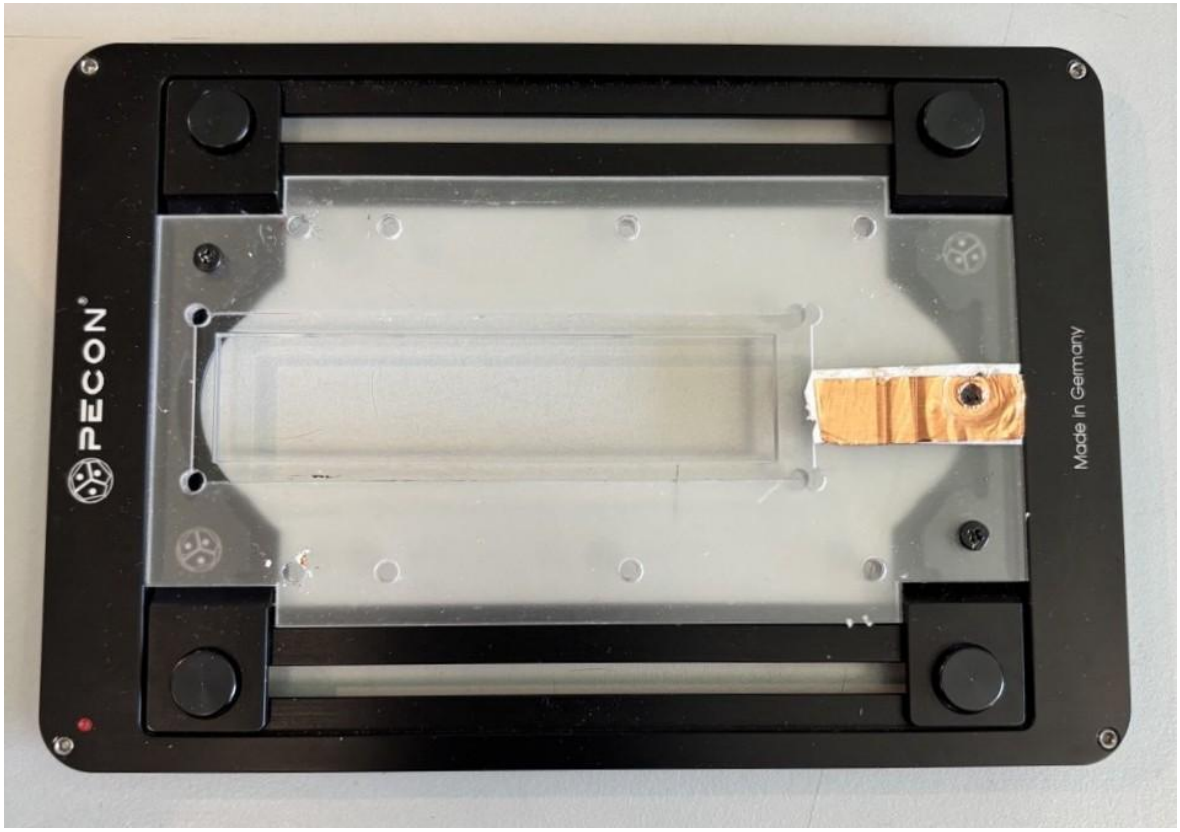


Figura 2.9: Configurazione del supporto meccanico (holder): dettaglio della stratificazione dei componenti polimerici e del nastro di rame utilizzato per il contatto elettrico del substrato inferiore.

Il contatto elettrico con il substrato di ITO superiore viene invece realizzato tramite un ulteriore elemento in PMMA da 3 mm, il cui spessore viene maggiorato con l'applicazione di nastro adesivo lungo la lunghezza dell'elettrodo e il tutto viene avvolto con nastro di rame e avvitato sul supporto.

La Figura 2.10 mostra il dispositivo finale completamente assemblato e alloggiato nel supporto del microscopio. Per il collegamento al generatore di segnale esterno, i nastri di rame che costituiscono i contatti elettrici vengono connessi tramite cavi con terminali ad occhiello, avvitati direttamente sulla superficie conduttiva. Il dispositivo è così pronto per essere integrato nel setup sperimentale.

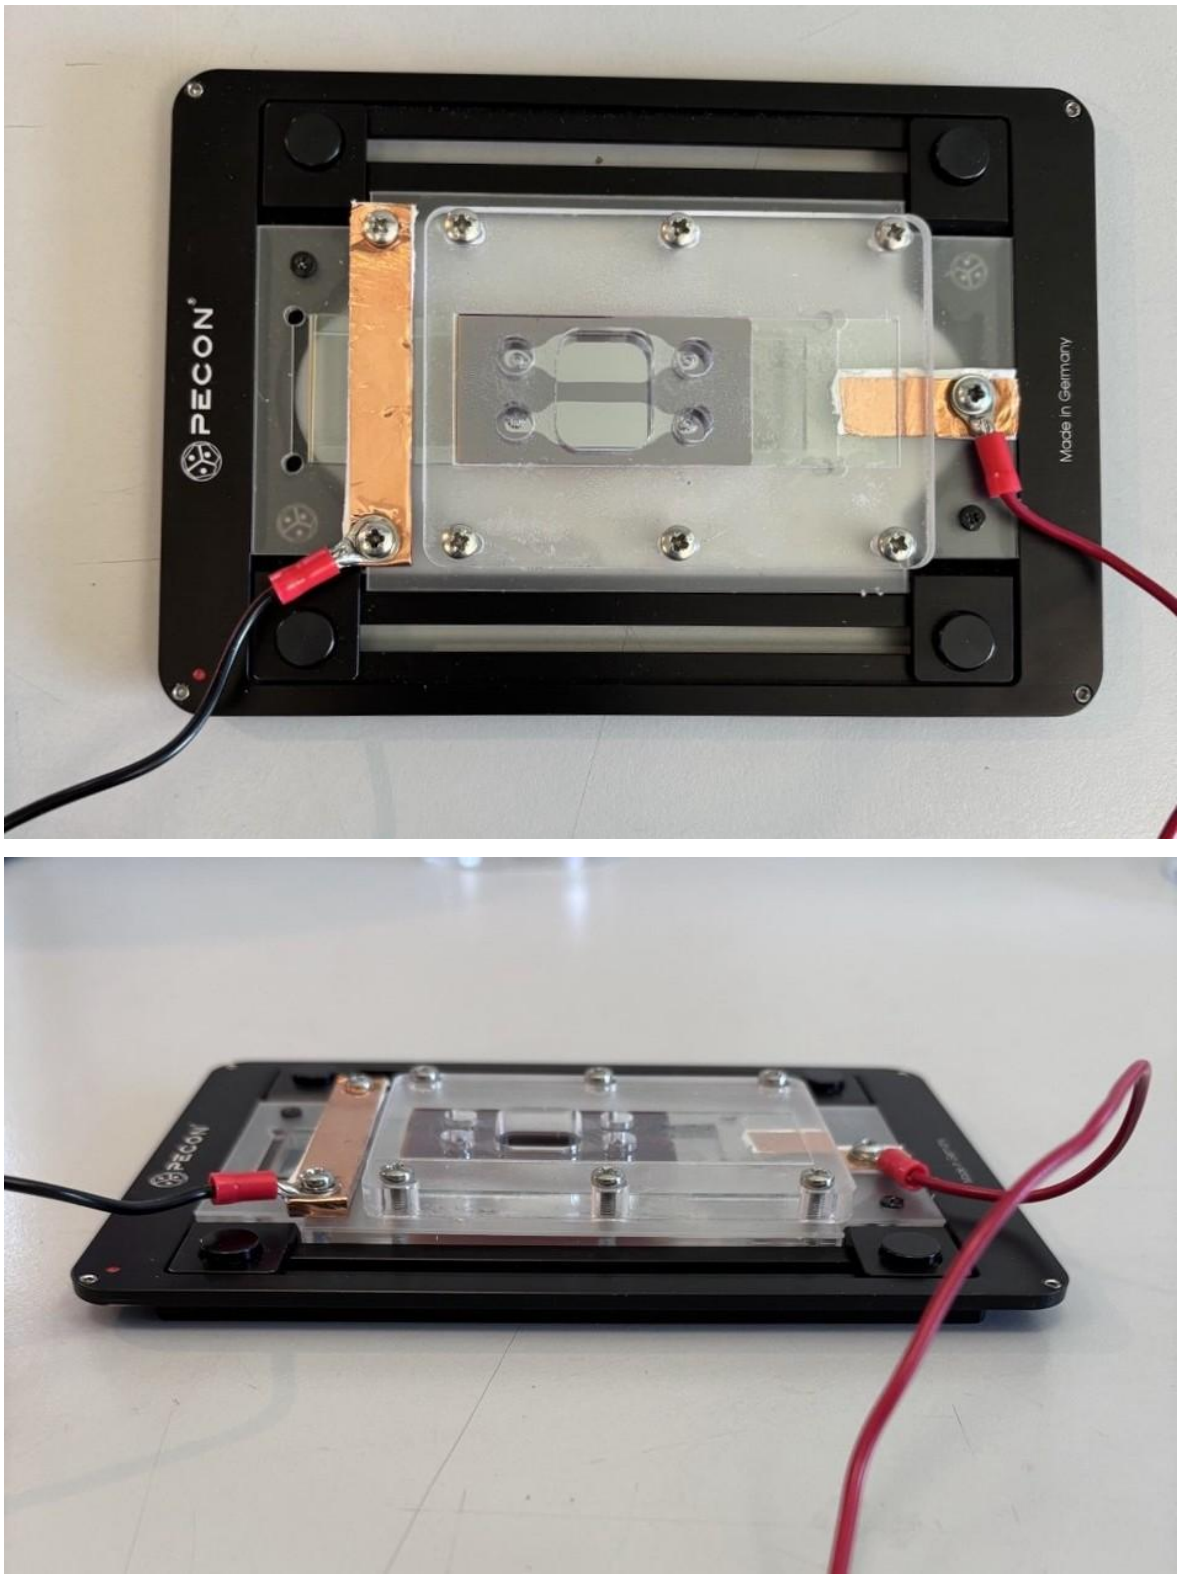


Figura 2.10: Dispositivo ODEP finale completamente assemblato, con evidenza del secondo contatto elettrico superiore e alloggiamento nel supporto per il microscopio.

2.3 Setup sperimentale

Il setup sperimentale sviluppato in questo lavoro integra componenti ottici, elettronici e microfluidici che lavorano in maniera coordinata per l'applicazione della tecnica ODEP a singole cellule di carcinoma prostatico. Il principio alla base della misura è il seguente: una cellula in sospensione situata in un canale microfluidico del dispositivo LOC viene sottoposta alternativamente a due pattern luminosi di geometria differente, che inducono forze dielettriche di segno opposto lungo la direzione verticale z. Un pattern a 'ciambella', operante a frequenza fissa inferiore della frequenza di crossover cellulare, genera una forza nDEP (repulsiva) che spinge la cellula verso l'alto, allontanandola dal piano focale del microscopio e producendo così un progressivo sfocamento dell'immagine. Un pattern a cerchio pieno, invece, operante a frequenze decrescenti superiori alla frequenza di crossover, genera una forza pDEP (attrattiva) che riporta giù la cellula verso il piano focale. Alternando ciclicamente i due pattern a frequenze del cerchio decrescenti, si ottiene uno spettro di sfocamento caratteristico della cellula: man mano che la frequenza si avvicina al valore di crossover, la forza pDEP si riduce e la cellula tende a non tornare completamente a fuoco, modificando la forma dello spettro in modo specifico per ogni popolazione cellulare. Questo spettro altro non è che la firma dielettrica della cellula e rappresenta il parametro discriminante su cui si basa la classificazione tramite deep learning, concetti che verranno approfonditi nelle sezioni successive di questo lavoro.

Affinché questa misura sia possibile, il sistema deve garantire simultaneamente la generazione e la proiezione precisa dei pattern luminosi sul dispositivo, l'applicazione del segnale elettrico alternato con frequenze e tensioni controllate, l'acquisizione video sincronizzata e il controllo software di tutti i componenti.

Una rappresentazione della strumentazione usata per il setup è fornita dalla Figura 2.11, mentre lo schema funzionale che mostra l'integrazione tra i percorsi ottici e i moduli elettronici è illustrato in Figura 2.12.

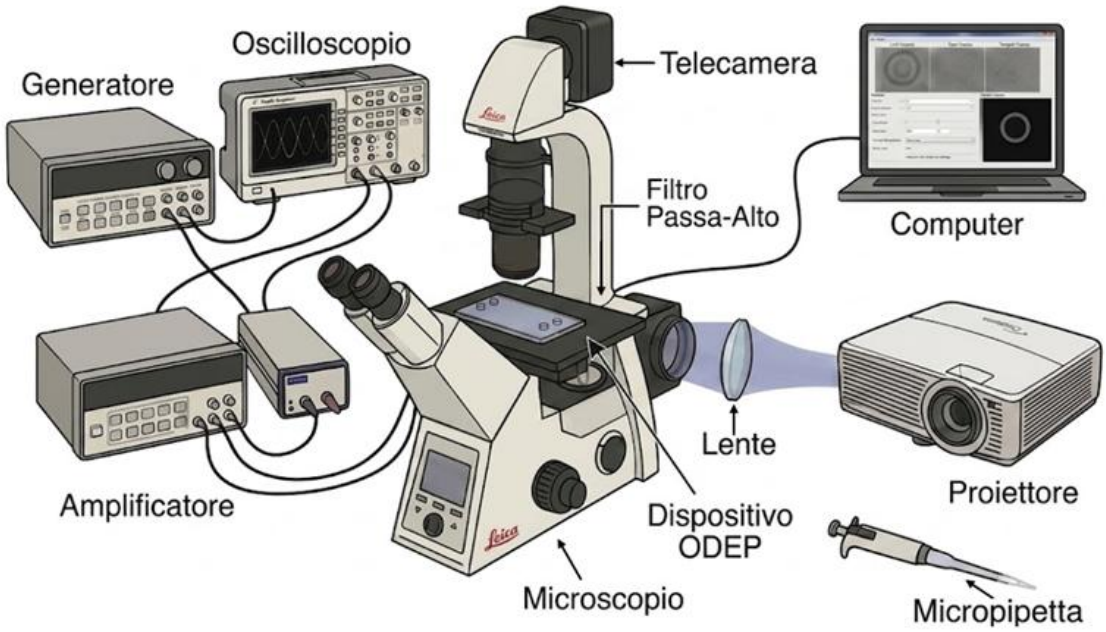


Figura 2.11: Vista d'insieme della strumentazione sperimentale nel laboratorio

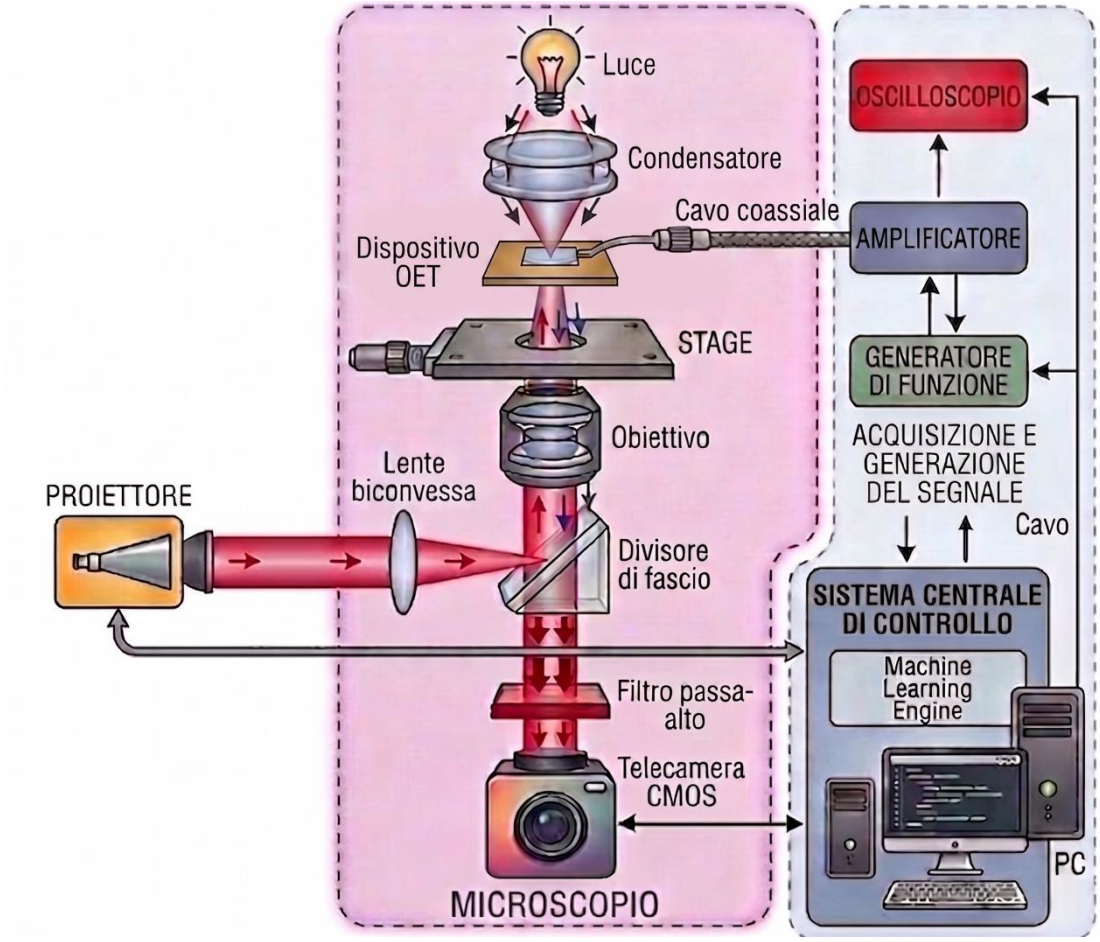


Figura 2.12: Schema funzionale della piattaforma ODEP, con dettaglio dei percorsi ottici.

Di seguito, vengono descritti nel dettaglio i quattro blocchi che compongono il setup sperimentale.

Il primo blocco è il microscopio invertito (Leica DMi8, Leica Microsystems CMS GmbH, Wetzlar, Germania), con il dispositivo LOC alloggiato nello stage motorizzato, come mostra la Figura 2.13. Il microscopio presenta un obiettivo 20x e una camera CMOS da 18 MP (MU1803 Amscope Inc., USA) per l'acquisizione video in campo chiaro ed è collegato a un amplificatore (WA301 Wide Band Amplifier, TTi, UK) e ad un generatore di funzione (33120A Hewlett Packard, USA). La luce trasmessa dal LED del microscopio illumina il campione dall'alto e dopo aver attraversato il chip viene convogliata, attraverso l'obiettivo e il beam splitter, verso la camera CMOS. Prima di raggiungerla però, il fascio passa attraverso un filtro passa-alto (FEL0650, Thorlabs Inc., USA) con taglio a 650 nm, posizionato proprio davanti alla camera.[87] Questo filtro ha la funzione di evitare la saturazione della camera, che altrimenti comprometterebbe l'acquisizione delle immagini cellulari.

Inoltre, il filtro infrarosso nativo della camera (Aptina AR1820) è stato rimosso per garantire una visuale ottimale del campo nel range di lunghezze d'onda 700–900 nm.

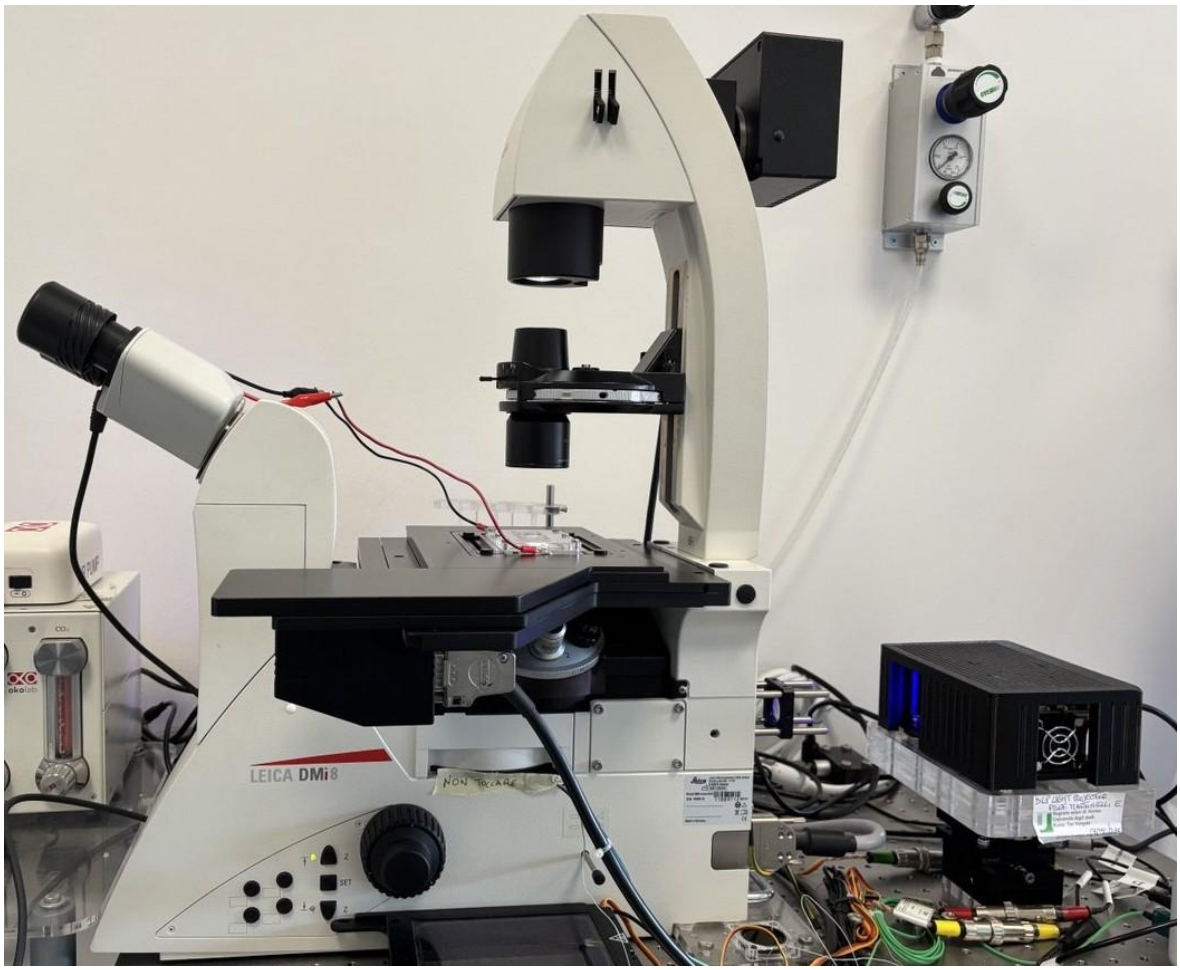


Figura 2.13: Dettaglio del setup del microscopio e del proiettore.

Il secondo blocco è rappresentato dal proiettore digitale (EKB, Technologies Ltd), ossia lo strumento responsabile della generazione dei due differenti pattern luminosi che fungono da elettrodi virtuali per l'induzione della forza ODEP sulle cellule. A differenza della configurazione descritta in lavori precedenti [88], in cui un filtro passa-banda esterno era necessario per selezionare la lunghezza d'onda utile alla fotoattivazione dell'a-Si:H dalla luce bianca del proiettore, il sistema adottato in questo lavoro impiega un proiettore dotato di LED interni che emettono direttamente alla lunghezza d'onda richiesta, nell'intervallo del blu (460 nm). La luce emessa dal proiettore, prima di raggiungere il chip, viene focalizzata da una lente bicovessa (LB1945-A, Thorlabs Inc., USA) e successivamente diretta verso il dispositivo attraverso la porta infinity del microscopio, il beam splitter (80/20) e l'obiettivo.

Il terzo blocco è il generatore di tensione AC, che applica il potenziale elettrico alternato ai due substrati di ITO. Esso è composto da un generatore di funzione (33120A Hewlett Packard, USA), un amplificatore a banda larga (WA301 Wide Band Amplifier, TTi, UK) e

un oscilloscopio (DS06032A, Agilent Technologies, Inc., USA), collegati tramite cavo coassiale. Durante la misura, i due pattern vengono applicati con diversi parametri: il pattern a ciambella opera sempre a f= 25 kHz e V_{pp}= 8 V, mentre il pattern a cerchio pieno opera a V_{pp}= 10 V con frequenza decrescente da 150 kHz fino a 30 kHz. L'oscilloscopio consente il monitoraggio in tempo reale del segnale effettivamente applicato al dispositivo, verificando la corrispondenza tra il potenziale impostato e quello erogato.

Il quarto blocco è rappresentato dal computer, che include l'unità di controllo e il motore di analisi. L'unità di controllo monitora simultaneamente tutti gli strumenti del sistema tramite un software sviluppato in Python[89], accessibile attraverso un'interfaccia grafica interattiva (GUI) da cui si controllano microscopio, generatore di segnale e proiettore; da qui si ha anche l'accesso a due differenti finestre: la 'live window', che mostra in tempo reale il campo visivo del canale microfluidico con le cellule in sospensione e la 'projection window', in cui invece si visualizza il pattern luminoso da proiettare poi sul chip.

Oltre ai componenti descritti, durante le fasi iniziali della misura viene utilizzata una micropipetta manuale per bilanciare il flusso agendo sugli inlet e outlet del dispositivo, al fine di garantire le condizioni di sospensione stazionaria necessarie alla misura.

2.4 Preparazione dei campioni biologici

2.4.1 Linee cellulari di carcinoma prostatico

Nello studio del carcinoma prostatico, le linee cellulari rappresentano uno degli strumenti più consolidati e diffusi, grazie alla facilità di coltura, alla riproducibilità sperimentale e alla possibilità di ottenere popolazioni cellulari pure adatte ad analisi molecolari e biochimiche [90]. Nel presente lavoro sono state utilizzate tre linee cellulari umane derivate da carcinoma prostatico metastatico: LNCaP, DU145 e PC3, scelte in quanto rappresentative di diversi stadi della progressione tumorale, da una forma indolente androgeno-dipendente fino a una forma altamente aggressiva e androgeno-indipendente [91]. Tutte le linee cellulari sono state mantenute in coltura a 37°C in atmosfera umidificata con 5% di CO_2.

- LNCaP (Lymph Node Carcinoma of the Prostate) è una delle linee cellulari più utilizzate nella ricerca sul carcinoma prostatico e ne rappresenta una forma indolente,

evidenziata da un comportamento biologico relativamente poco aggressivo. È derivata da una lesione metastatica sopraclavicolare di adenocarcinoma prostatico umano.[92] Le cellule LNCaP esprimono il recettore androgenico (AR) e l'antigene prostatico specifico (PSA), marcatori tipici delle cellule epiteliali luminali prostatiche, e mostrano una crescita androgeno-dipendente, per cui la privazione androgenica ne inibisce significativamente la proliferazione [93]. Sul piano del comportamento tumorale, i modelli in vivo derivati da LNCaP mostrano una crescita lenta e una ridotta capacità invasiva [94]. Per l'insieme di caratteristiche, la linea LNCaP è considerata un modello rappresentativo dell'adenocarcinoma prostatico convenzionale androgeno-dipendente.

- DU145 è stata isolata da una metastasi cerebrale di carcinoma prostatico [95] e rappresenta uno stadio intermedio della progressione tumorale, con un potenziale metastatico superiore a LNCaP ma inferiore a PC3. Le cellule DU145 sono androgeno-insensibili e non esprimono AR né PSA [96]. Si tratta di una linea cellulare usata come modello per lo studio del carcinoma prostatico in stadio avanzato, della resistenza alla terapia di deprivazione androgenica e per la valutazione dell'efficacia di farmaci antitumorali a livello molecolare [97].

- PC3 è la linea cellulare stabilita da una metastasi ossea vertebrale di adenocarcinoma prostatico di grado IV e rappresenta la forma più aggressiva della malattia [98]. A differenza di LNCaP, le cellule PC3 non esprimono AR né PSA e sono completamente androgeno-indipendenti, proliferando normalmente anche in condizioni di privazione androgenica. In vitro, PC3 mostra una spiccata capacità migratoria e invasiva, mentre i modelli in vivo derivati da questa linea presentano una crescita rapida e un'elevata aggressività. PC3 viene pertanto utilizzata come modello di carcinoma prostatico avanzato e castrazione-resistente [99].

2.4.3 Preparazione del mezzo di sospensione (Buffer)

Prima di procedere alle misure, le cellule vengono risospese in un buffer specifico, la cui composizione è determinante per il corretto funzionamento del sistema di misura. Per le misure dielettroforetiche è necessario sospendere le cellule in un buffer a bassa conducibilità, condizione indispensabile per evitare la dispersione del campo elettrico e garantire il corretto funzionamento del sistema ODEP. I terreni di coltura cellulare standard presentano infatti

una conducibilità di circa 1.2 S/m, valore incompatibile con le misure dielettriche, e devono pertanto essere sostituiti da un buffer specifico.

Il buffer utilizzato nel presente lavoro è stato preparato in un volume finale di 15 ml, con la seguente composizione: PBS 1X (Phosphate Buffered Saline, soluzione salina tamponata con fosfato, 150 µl), saccarosio (1.275 g) e BSA (albumina serica bovina, 0.075 g), corrispondenti rispettivamente a concentrazioni dell'1%, 8.5% e 0.5%. La scelta della BSA è motivata dalla sua capacità di ridurre l'adesione delle cellule al substrato, migliorando la qualità della misura.

Il buffer è formulato in modo da garantire un'osmolarità fisiologica, essenziale per preservare l'integrità cellulare durante la misura. In assenza di un agente osmoticamente attivo, la bassa concentrazione di soluti, necessaria per mantenere la conducibilità al valore target di 15 mS/m, causerebbe il raggrinzimento delle cellule per effetto osmotico. Il saccarosio svolge questa funzione di bilanciamento osmotico senza contribuire significativamente alla conducibilità della soluzione. La piccola quantità di PBS aggiunta permette invece di regolare con precisione la conducibilità finale.

Questo parametro è di fondamentale importanza poiché dalla conducibilità del mezzo dipende il fattore di Clausius-Mossotti, che a sua volta determina la frequenza di crossover e l'entità della forza dielettroforetica esercitata sulle cellule. Per garantire la comparabilità dei risultati tra le diverse linee cellulari analizzate, il buffer è stato mantenuto invariato in tutte le misure.

La preparazione prevede innanzitutto la pesatura accurata dei componenti tramite bilancia analitica (KERN, Max 160g, d=0.1mg), come mostrato in Figura 2.14(a), seguita dalla dissoluzione in acqua bidistillata sotto agitazione magnetica a 500 rpm per 30 minuti (ARGO LAB M2-D Pro), come illustrato in Figura 2.14(b). La soluzione viene infine filtrata per garantire la sterilità. Data la natura non fisiologica del buffer, la durata massima delle misure è stata fissata a 3 ore, limite oltre il quale, come riportato in letteratura, la vitalità cellulare non può essere garantita [100].

(a) 

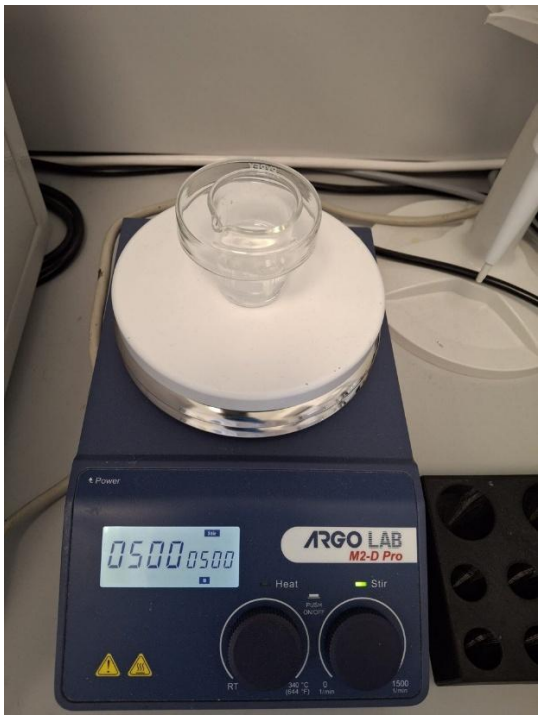
(b) 

Figura 2.14: (a) Pesatura del saccarosio sulla bilancia analitica durante la preparazione del buffer. **(b)** Dissoluzione dei componenti del buffer sotto agitazione magnetica.

2.5 Procedura sperimentale e acquisizione dati

2.5.1 Principio della misura

Il protocollo sperimentale sviluppato in questo lavoro sfrutta il moto della cellula lungo la direzione verticale z, indotto alternativamente da due pattern luminosi di geometria diversa, uno a ciambella e uno a cerchio pieno, che operano a frequenze fisse o variabili del campo elettrico. La scelta delle frequenze di lavoro si basa sulla posizione della frequenza di crossover delle cellule tumorali prostatiche, che si colloca intorno ai 30 kHz, in accordo con i valori tipici dei tumori solidi riportati in letteratura per questa conducibilità del buffer (Figura 1.9): al di sotto di questo valore il fattore di Clausius-Mossotti è negativo e la forza esercitata sulla cellula è di tipo nDEP (repulsiva), mentre al di sopra è positivo e la forza è di tipo pDEP (attrattiva).

Il pattern a ciambella viene sempre applicato a una tensione di 8 V_{pp} e alla frequenza fissa di 25 kHz, inferiore quindi alla frequenza di crossover: in questo regime la forza nDEP allontana la cellula dal piano focale del microscopio spingendola verso l'alto e producendo un progressivo sfocamento dell'immagine. Il pattern a cerchio pieno opera, invece, a una

tensione fissa di 10 V_{pp} e a frequenze variabili superiori alla frequenza di crossover, partendo da 150 kHz fino a scendere a 30 kHz con passo di 10 kHz ad ogni misura successiva: in questo regime la forza pDEP è attrattiva e riporta in basso la cellula verso il piano focale. Tuttavia, man mano che questa frequenza decresce avvicinandosi al valore di crossover, la forza pDEP disponibile si riduce progressivamente e la cellula viene riportata verso il piano focale in misura sempre minore, tendendo così a permanere in uno stato di sfocamento crescente.

La risposta della cellula a questo protocollo genera uno spettro di sfocamento caratteristico di ogni popolazione cellulare, che costituisce la firma dielettrica utilizzata per la classificazione. La novità principale dell'approccio consiste nell'impiego di algoritmi di deep learning per l'analisi diretta dei pixel dei frame ottenuti tramite microscopia time-lapse dell'intera sessione di misura su singola cellula. A differenza dei metodi basati sul solo tracking del centroide [101], questo approccio consente di estrarre informazioni non solo dallo sfocamento ma anche dalla forma e dalla possibile deformazione della cellula durante la stimolazione, arricchendo significativamente il contenuto informativo della misura.

2.5.2 Fase di stabilizzazione

Prima di procedere con le misure, è necessaria una fase di stabilizzazione del sistema. Dopo il caricamento della sospensione cellulare nei canali del dispositivo LOC, si possono verificare due condizioni problematiche che rendono la misura non eseguibile.

Il primo problema è l'adesione delle cellule al substrato: a causa della gravità e di interazioni elettrostatiche con le superfici del canale, le cellule tendono a depositarsi sul fondo del dispositivo, rimanendo adese al substrato inferiore invece di mantenersi in sospensione nel mezzo. Il secondo problema è invece il movimento incontrollato delle cellule: essendo confinate in un canale chiuso, le cellule sono soggette a gradienti di pressione generati dalla differenza di livello del liquido nei reservoir del dispositivo. In modo analogo al principio di Archimede, anche piccole differenze nel volume di mezzo presente nei due serbatoi inducono un flusso residuo che mette in moto le cellule nel canale, rendendo impossibile la misura.

In entrambi i casi si interviene con la micropipetta manuale, agendo sugli inlet e outlet del dispositivo per bilanciare il flusso: nel caso di cellule adese, si genera un leggero flusso che le distacca dal substrato e le rimette in sospensione; nel caso di cellule in movimento, si riequilibra il livello del liquido nei reservoir fino a neutralizzare il gradiente di pressione e stabilizzare le cellule, come rappresentato nella Figura 2.15. Solo quando la cellula target

risulta stabile e in sospensione (condizione di stazionarietà) si procede con il protocollo di misura.

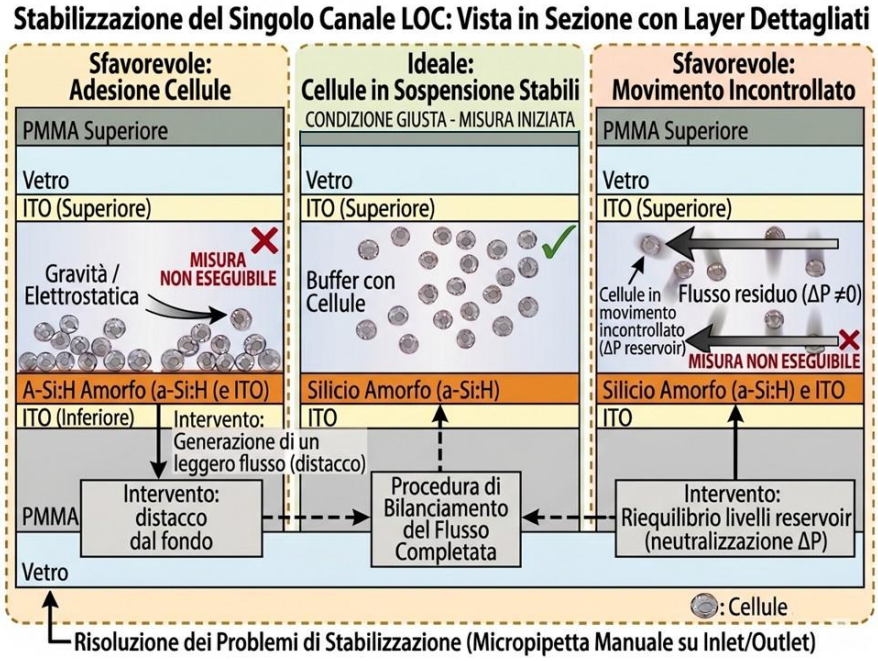
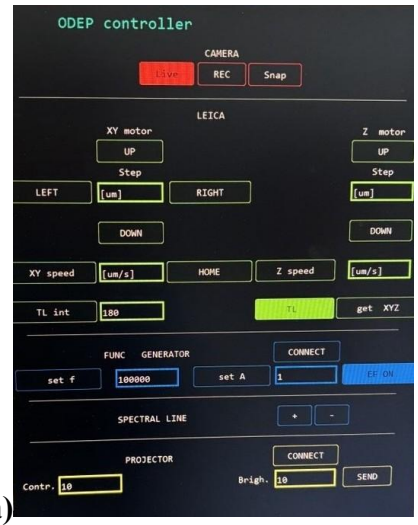


Figura 2.15: Schematizzazione delle condizioni di stabilità e instabilità cellulare all'interno del canale, con relativi interventi di bilanciamento.

2.5.3 Protocollo operativo e interfaccia GUI

Il controllo dell'intero sistema è affidato a un software sviluppato in Python (v.3.6.5) che integra i protocolli di comunicazione di tutti gli strumenti in un'unica interfaccia grafica interattiva (GUI). La GUI è costituita da tre finestre distinte: il pannello strumenti (Figura 2.16a), che consente di comandare il microscopio, il generatore di segnale e il proiettore; la finestra live, che mostra il campo visivo corrente acquisito dalla camera CMOS; la finestra di proiezione, che è uno schermo nero su cui viene renderizzato il pattern luminoso da proiettare.

È stata inoltre definita via software una working area all'interno della finestra live, corrispondente alla zona del campo visivo in cui l'illuminazione del proiettore è sufficientemente uniforme da garantire una forza DEP adeguata sulla cellula (Figura 2.16b).

(a) 

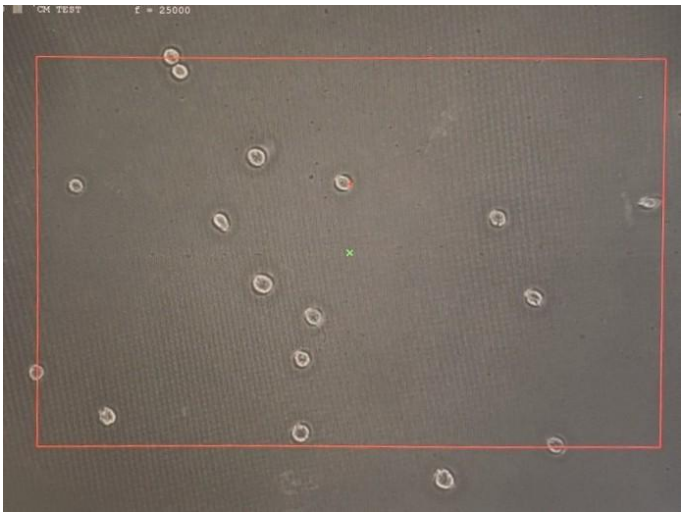
(b) 

Figura 2.16: Interfaccia dell'unità di controllo. (a) Pannello di gestione dei parametri sperimentali (b) Visualizzazione delle cellule in analisi tramite la working area della live window.

Una volta stabilizzato il flusso nel canale microfluidico, come descritto nella sezione 2.5.2, si sceglie una cellula target nella finestra live e la si centra nel campo visivo utilizzando un cursore rotativo fisico, che consente di navigare facilmente nella finestra. Quando la cellula è posizionata correttamente all'interno della working area, si preme un tasto dedicato per avviare il protocollo di misura: contestualmente parte automaticamente la registrazione time-lapse della sessione. Il protocollo esegue in sequenza automatica tutti gli step di frequenza descritti nella sezione 2.5.4 e una volta spazzolato l'intero range di frequenze, interrompe autonomamente sia il protocollo che la registrazione video.

Nel caso in cui durante la misura si verifichino condizioni che la rendono non valida, come adesione al substrato o morte cellulare, è possibile interrompere manualmente il protocollo e contestualmente verrà interrotta anche la registrazione video. Si procede quindi con una nuova cellula target.

2.5.4 Sequenza di misura

La misura si basa sull'alternanza ciclica di due pattern luminosi applicati in sequenza temporale alla stessa cellula: un pattern a ciambella, operante a frequenza fissa di 25 kHz e 8 V_{pp}, e un pattern a cerchio pieno, operante a frequenze decrescenti da 150 kHz fino a 30 kHz con passo di 10 kHz e tensione di 10 V_{pp}.

La sequenza completa di una singola sessione di misura si articola come segue. Al tempo t=0 si attiva il pattern a ciambella a 25 kHz e 8 V_{pp}: la forza nDEP spinge la cellula verso

l'alto, che inizia a sfocare nell'immagine. Dopo 2 secondi, si sostituisce il pattern con il cerchio pieno a 150 kHz e 10 V_{pp}: la forza pDEP riporta la cellula al piano focale. Dopo altri 2 secondi si riattiva la ciambella a 25 kHz e 8 V_{pp}: la cellula risale e sfoca nuovamente. Dopo 2 secondi, si riapplica il cerchio pieno, ora alla prima frequenza di misura decrescente di 140 kHz e 10 V_{pp}. Questa alternanza viene ripetuta per tutti i valori di frequenza decrescenti del cerchio pieno, mantenendo sempre la ciambella fissa a 25 kHz come step di risalita intermedio. La sequenza dell'esperimento e la corrispondente risposta dinamica della cellula sono schematizzate in Figura 2.17.

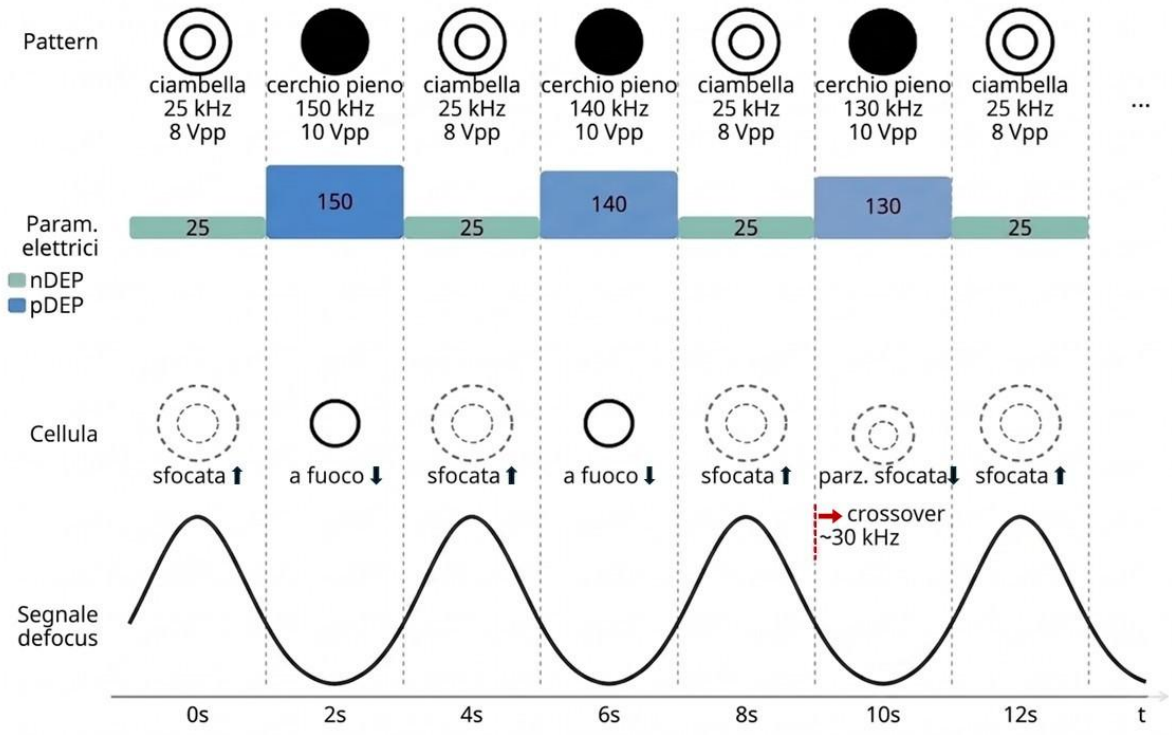


Figura 2.17: Schema del protocollo di misura: alternanza dei pattern luminosi e generazione del segnale di sfocamento in funzione della frequenza applicata.

Il risultato è uno spettro di sfocamento in frequenza caratteristico della cellula. Il segnale presenta picchi massimi in corrispondenza di ogni step a 25 kHz, poiché la forza nDEP è sempre sufficiente a spingere la cellula fuori fuoco indipendentemente dalla frequenza del cerchio. I picchi minimi, invece, corrispondono ai successivi step a cerchio pieno: il primo minimo, a 150 kHz, è il più pronunciato, poiché a quella frequenza la forza pDEP è massima e la cellula viene riportata completamente al piano focale. Man mano che la frequenza del cerchio pieno decresce e si avvicina alla frequenza di crossover, la forza pDEP disponibile

si riduce progressivamente e la cellula non viene più riportata completamente a fuoco: i minimi dello spettro crescono quindi in ampiezza, riflettendo un grado di sfocamento residuo sempre maggiore. La forma complessiva di questo spettro è specifica di ogni popolazione cellulare e costituisce il parametro discriminante su cui si basa la classificazione delle linee cellulari analizzate in questo lavoro.

2.5.5 Analisi delle immagini con Deep Learning

I frame acquisiti durante l'intera sessione di misura vengono utilizzati come input per il modello di deep learning descritto nel Capitolo 3. L'approccio basato sull'analisi diretta dei pixel dell'immagine consente di catturare simultaneamente informazioni sulla morfologia della cellula, sulla sua forma e su eventuali deformazioni indotte dal campo elettrico durante la stimolazione, ampliando la capacità discriminativa del sistema. Questo configura la piattaforma come uno strumento di caratterizzazione biofisica multi-parametrica label-free per la stratificazione del carcinoma prostatico.

3. Capitolo 3: Analisi dei dati e Deep Learning

3.1 Analisi Multimodale del Segnale ODEP

L'output del protocollo sperimentale descritto nel Capitolo 2 non è un singolo valore numerico, ma un flusso video acquisito tramite microscopia time-lapse, in cui ogni frame cattura la risposta ottica della cellula target alla stimolazione optodielettroforetica. Estrarre da questo flusso un'informazione classificatoria richiede una pipeline di analisi articolata, che costituisce il cuore del presente capitolo. Una rappresentazione schematica è riportata in Figura 3.1.

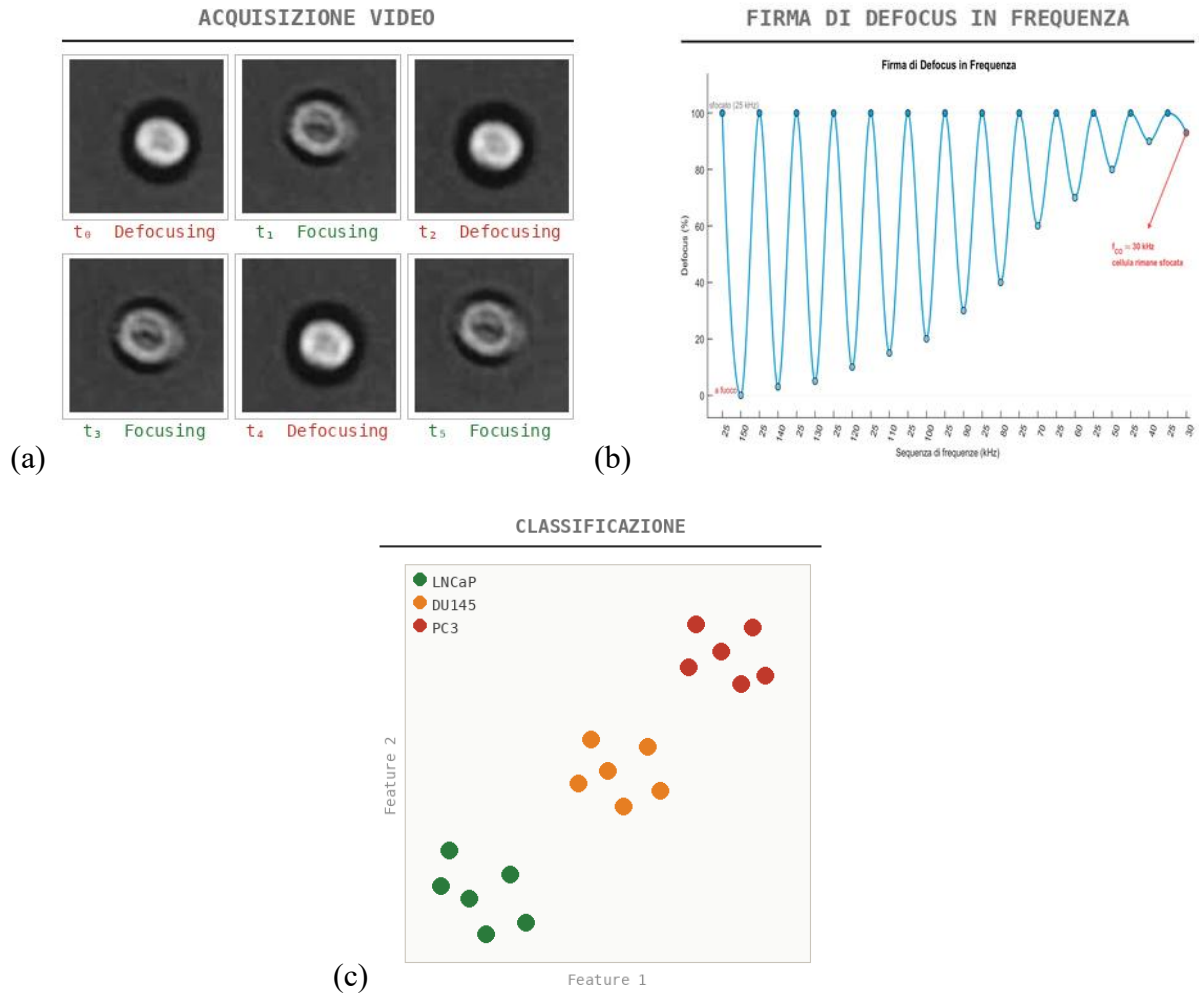


Figura 3.1: Pipeline di analisi multimodale del segnale ODEP: (a) sequenza di frame con alternanza di fasi di defocusing (nDEP, f = 25 kHz) e focusing (pDEP, f = [30–150] kHz); (b) firma di defocus in frequenza; (c) classificazione delle tre linee cellulari (LNCaP, DU145, PC3).

L'approccio adottato è di natura multimodale: dal medesimo dato video vengono estratti due tipi di informazione complementari. Il primo riguarda la dinamica di defocus lungo l'asse z, ovvero la variazione di nitidezza dell'immagine cellulare indotta dalla forza DEP verticale. Come descritto nella Sezione 2.5.1, questa variazione è strettamente legata alle proprietà dielettriche intrinseche della cellula e dipende, in particolare, dalla posizione della sua frequenza di crossover rispetto alle frequenze di stimolazione applicate: durante la fase nDEP la cellula viene spinta verso l'alto, allontanandosi dal piano focale e perdendo nitidezza; nella fase pDEP successiva la forza attrattiva la riporta verso il substrato e il fuoco recupera progressivamente, con un'entità di recupero che decresce man mano che la frequenza di stimolazione si avvicina alla frequenza di crossover f_{CO} della cellula, producendo l'inviluppo decrescente visibile in Figura 3.2. Il secondo tipo di informazione riguarda invece la morfologia della cellula nei singoli frame: l'analisi diretta dei pixel consente di rilevare variazioni di forma e distribuzione dell'intensità luminosa che arricchiscono il contenuto diagnostico della misura al di là del solo segnale di sfocamento.

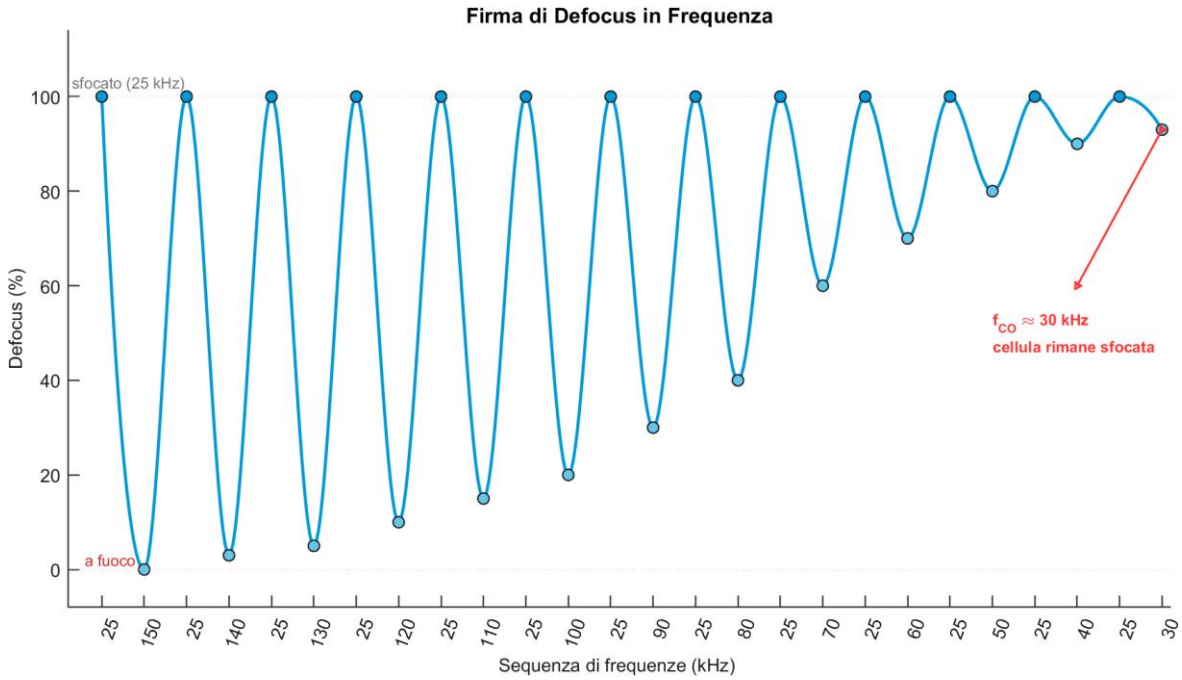


Figura 3.2: Esempio di dinamica di defocus. L'inviluppo decrescente indica l'avvicinarsi della frequenza di stimolazione alla f_{CO} cellulare.

Prima di procedere con l'analisi, i video acquisiti sono stati sottoposti a una pipeline di pre-processing descritta nella Sezione 3.2, finalizzata a standardizzare il dato, ridurre le sorgenti di variabilità confondente e preparare l'input per i modelli di classificazione.

La pipeline di analisi si articola in due rami paralleli che operano sullo stesso dato di partenza. Il primo ramo, descritto nella Sezione 3.3, implementa un approccio classico basato sull'estrazione di feature interpretabili dalla dinamica di sfocamento, rappresentata come segnale scalare tempo-variante, e sulla loro classificazione tramite un modello lineare. Questo approccio costituisce la baseline del sistema e consente di quantificare il contenuto informativo del solo segnale di defocus in assenza di informazione morfologica. Il secondo ramo, descritto nelle Sezioni 3.4 e 3.5, adotta un approccio di deep learning basato sull'analisi diretta delle sequenze video tramite reti neurali convoluzionali: in questo caso la rete apprende autonomamente le feature rilevanti, integrando simultaneamente l'informazione morfologica dei singoli frame e la dinamica temporale del defocus. Il confronto tra i risultati dei due rami consente di quantificare il guadagno informativo ottenuto dall'integrazione della dimensione morfologica rispetto alla sola analisi dello sfocamento scalare.

L'obiettivo finale è la classificazione automatica delle cellule nelle tre linee di carcinoma prostatico analizzate (LNCaP, DU145 e PC3), rappresentative di un gradiente crescente di aggressività tumorale, dalla forma androgeno-dipendente e a bassa invasività fino al fenotipo castrazione-resistente e altamente metastatico.

3.2 Pre-processing dei video

3.2.1 Segmentazione e centratura dinamica

Il primo passo della pipeline di pre-processing consiste nell'isolare la cellula target all'interno di ogni frame e nel mantenerne il centroide sempre al centro di una regione di interesse (ROI) quadrata. Questa operazione è necessaria perché, sebbene il protocollo di misura preveda che la cellula venga centrata nella working area prima dell'avvio della registrazione, nella pratica la forza DEP può indurre spostamenti non trascurabili anche nel piano xy del microscopio, oltre al moto verticale lungo l'asse z che costituisce il segnale di interesse. Una ROI fissa, estratta attorno alla posizione iniziale e mantenuta costante per l'intera sequenza, finirebbe per inquadrare il background nel momento in cui la cellula si sposta lateralmente, introducendo artefatti e perdendo il contenuto informativo della cellula stessa.

Per questo motivo, la posizione della cellula viene stimata frame per frame tramite l'algoritmo Cellpose [102], un modello di segmentazione neurale sviluppato specificamente per il riconoscimento e la delineazione di cellule biologiche in immagini di microscopia.

Cellpose individua la maschera di segmentazione della cellula in ogni frame e ne calcola il centroide; questo centroide viene riportato al centro della ROI quadrata, garantendo che la cellula rimanga sempre centrata nell'immagine indipendentemente dai suoi spostamenti laterali.
Per ragioni computazionali legate alla velocità di esecuzione di Cellpose, la centratura viene eseguita ciclo di stimolazione per ciclo di stimolazione: ad ogni ciclo la posizione della cellula viene aggiornata e la ROI riadattata di conseguenza. L'analisi ha mostrato che questa procedura funziona correttamente almeno fino all'ottavo ciclo di stimolazione, oltre il quale la qualità del tracking può degradarsi per alcune cellule. Questa limitazione ha influenzato la scelta del numero di cicli da analizzare, come discusso nella Sezione 4.1.

3.2.2 Normalizzazione del background

Le sessioni di misura acquisite in momenti diversi possono presentare variazioni nelle condizioni di illuminazione che, se non corrette, potrebbero essere apprese dai modelli come feature discriminative, portandoli a classificare in base a parametri sperimentali piuttosto che alle proprietà intrinseche della cellula. Per eliminare questo effetto confondente, il background di ciascun frame viene normalizzato sottraendo il valore medio dell'intensità del background stesso, operazione eseguita frame per frame in modo da tenere conto di eventuali variazioni temporali dell'illuminazione all'interno della stessa sessione di misura.

3.2.3 Intensity stretching e organizzazione in clip

Dopo la normalizzazione del background, i valori di intensità di ciascuna clip video vengono scalati linearmente nell'intervallo [0, 1] (*intensity stretching*). Questa operazione viene eseguita a livello di singola clip, e non del singolo frame, in modo da preservare l'informazione relativa allo sfocamento: poiché il massimo di intensità corrisponde all'istante in cui la cellula è maggiormente sfocata, il valore 1 viene assegnato a quel frame specifico, consentendo alla rete di percepire direttamente l'entità del defocus in relazione agli altri frame della stessa sequenza.
I video vengono segmentati in clip corrispondenti ai singoli cicli di stimolazione: per ciascun ciclo, che comprende una fase di risalita (nDEP, pattern a ciambella) e una fase di discesa (pDEP, pattern circolare), viene creata una clip indipendente e salvata nella cartella della linea cellulare di appartenenza. Questa struttura organizzativa consente di alimentare le reti

neurali con sequenze di durata standardizzata, limitando al contempo l'influenza di variabili confondenti legate alla deriva temporale della sessione di misura.
Il risultato complessivo della pipeline di pre-processing è illustrato in Figura 3.3, che riporta un frame rappresentativo per ciascuna delle tre linee cellulari dopo l'applicazione di tutti gli step descritti.

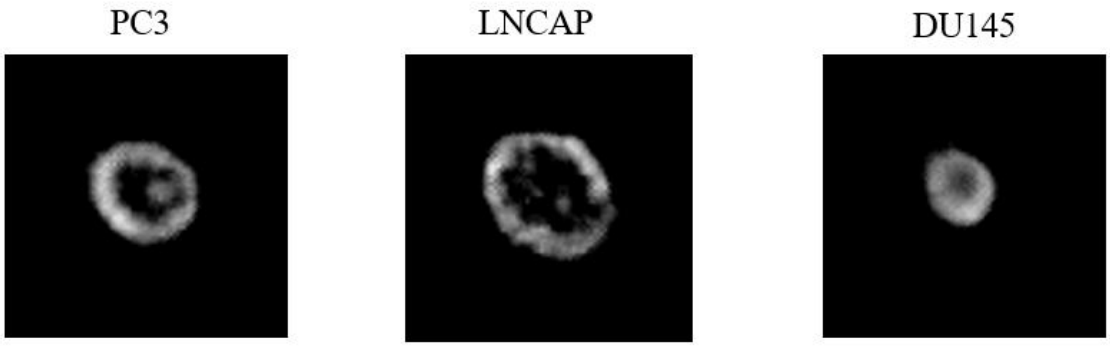


Figura 3.3: Esempi rappresentativi di frame pre-processati per ciascuna delle tre linee cellulari analizzate (PC3, LNCaP, DU145).

3.3 Classificazione tramite LDA

3.3.1 Il Contrasto di Michelson come indicatore di defocus

Il primo approccio di classificazione adottato opera sul segnale scalare di defocus, riducendo ciascun frame a un singolo numero e rinunciando quindi all'analisi della distribuzione spaziale dei pixel. Questo approccio costituisce una baseline interpretabile che consente di quantificare il contenuto informativo del segnale di defocus in assenza di qualsiasi analisi strutturale dell'immagine, e la cui limitazione principale risiede proprio nella perdita di tutta l'informazione bidimensionale contenuta nei frame (forma, texture e distribuzione locale delle intensità), che viene collassata in un unico valore scalare per istante temporale. La quantificazione del defocus cellulare lungo l'asse z viene effettuata frame per frame mediante il calcolo del contrasto di Michelson. Questa metrica, originariamente introdotta per quantificare la visibilità delle frange di interferenza in reticoli sinusoidali [103], oggi risulta ampiamente adottata in applicazioni di image processing per la sua semplicità computazionale. È definita come:

$$C = \frac{I_{max} - I_{min}}{I_{max} + I_{min}}$$

dove I_{max} e I_{min} rappresentano rispettivamente l'intensità massima e minima dei pixel all'interno della ROI. Il valore di C è compreso nell'intervallo [0, 1]: un contrasto prossimo all'unità indica bordi netti e distribuzione eterogenea delle intensità, condizione associata alla cellula a fuoco; un contrasto basso indica invece un'omogeneizzazione delle intensità, corrispondente alla condizione di defocus in cui i bordi cellulari risultano sfumati e i pattern di diffrazione si estendono sull'intera ROI. Le due condizioni sono illustrate in Figura 3.4.

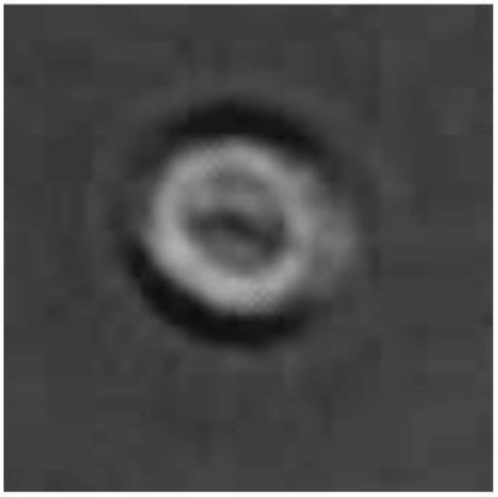
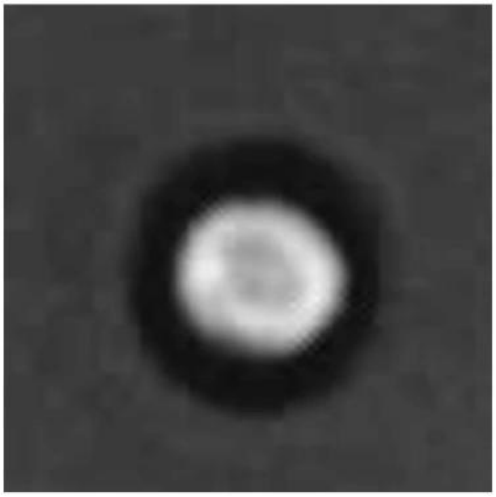
(a)  (b) 

Figura 3.4: (a) Cellula a fuoco: bordi più nitidi e distribuzione eterogenea delle intensità nella ROI, corrispondente a un valore di contrasto elevato. (b) Cellula sfocata: bordi indistinti e pattern di diffrazione estesi, corrispondente a un valore di contrasto ridotto.

La metrica è invariante rispetto al livello assoluto di illuminazione [104], caratteristica vantaggiosa per sessioni acquisite in condizioni non perfettamente controllate.
Per rendere confrontabili cellule diverse e sessioni di misura acquisite in condizioni differenti, il segnale di contrasto non viene espresso in valore assoluto, bensì come variazione relativa rispetto al primo frame della sequenza [105]:

$$\Delta C(t) = \frac{C(t) - C(t_0)}{C(t_0)}$$

Come illustrato in Figura 3.2, questo segnale normalizzato assume un andamento oscillante nel tempo, sincronizzato con l'alternanza dei pattern di illuminazione ODEP, con un

inviluppo decrescente che costituisce la firma dielettrica della cellula. L'analisi è di tipo cumulativo: le feature vengono calcolate sul segnale che si allunga progressivamente all'aumentare del numero di cicli di stimolazione osservati, consentendo di valutare come la quantità di informazione disponibile influenzi le prestazioni del classificatore.

3.3.2 Estrazione delle feature

Dal segnale $\Delta C(t)$ vengono calcolate la derivata prima e la derivata seconda. La scelta di includerle è motivata dalla necessità di catturare la dinamica dello sfocamento nel tempo e non solo la sua ampiezza istantanea: la velocità con cui la cellula sfoca e torna a fuoco in risposta alla stimolazione, e la curvatura di questa risposta, contengono informazioni sulle proprietà viscoelastiche e dielettriche della membrana che non sono completamente codificate nel segnale di contrasto assoluto.

Per ciascuna di queste tre rappresentazioni, ossia il segnale stesso, la derivata prima e la derivata seconda, vengono estratti 8 descrittori: 7 descrittori statistici (media, deviazione standard, massimo, minimo, range, skewness, curtosi) e 1 descrittore di regolarità (entropia approssimata), per un totale di 24 feature per cellula. L'entropia approssimata misura la complessità e la predicibilità del segnale nel tempo, una proprietà qualitativa distinta dalle statistiche di distribuzione.

3.3.3 Selezione delle feature e modello di classificazione

Non tutte le 24 feature estratte sono necessariamente informative per la discriminazione delle tre linee cellulari. Per selezionare automaticamente il sottoinsieme ottimale, viene adottata una procedura di selezione sequenziale in avanti (forward sequential feature selection), che aggiunge iterativamente la feature che massimizza le prestazioni del classificatore in cross-validazione.

Il modello di classificazione adottato è la LDA (*Linear Discriminant Analysis*) [106], un classificatore parametrico che proietta i dati in uno spazio a dimensionalità ridotta trovando le direzioni che massimizzano la separazione tra le classi. La LDA è particolarmente adatta a questo contesto per la sua interpretabilità e per la sua robustezza in scenari con numero di campioni relativamente limitato rispetto alla dimensionalità delle feature.

La valutazione delle prestazioni viene condotta tramite cross-validazione k-fold con k = 10, ripetuta su tutto il dataset. I risultati sono espressi come accuratezza media +/- deviazione standard sull'insieme di test delle 10 fold.

3.4 Classificazione tramite Deep learning

3.4.1 Analisi morfologica dei frame

Le differenze morfologiche tra le tre linee cellulari analizzate non si manifestano esclusivamente nella dinamica di defocus lungo l'asse z, ma possono riflettersi anche nella struttura visiva della cellula nei singoli frame. Come discusso nella Sezione 1.8.1, LNCaP, DU145 e PC3 presentano gradi crescenti di complessità morfologica della membrana plasmatica, quantificati dal fattore di ripiegamento ϕ : la progressione verso fenotipi più aggressivi è associata a una membrana più elaborata, con un maggior numero di proiezioni, microvilli e irregolarità superficiali. Queste differenze strutturali possono tradursi in variazioni nella distribuzione spaziale delle intensità luminose nei frame, sotto forma di pattern di texture e rugosità apparente che, pur non essendo facilmente distinguibili a occhio nudo, possono essere rilevati da un modello di apprendimento automatico. Analogamente, la diversa rigidità meccanica delle membrane può determinare risposte alle micro-deformazioni indotte dalla forza DEP che variano tra i tre fenotipi durante i cicli di stimolazione.

Fornendo alla rete la sequenza completa di immagini si rende disponibile sia l'informazione morfologica sia la dinamica temporale del defocus. In questa forma di analisi il segnale $\Delta C(t)$ non è calcolato esplicitamente: la rete riceve direttamente i frame e apprende autonomamente a estrarre le feature rilevanti, senza che esse debbano essere predefinite a priori. La distribuzione spaziale delle intensità luminose nei frame codifica i pattern di rugosità e dimensione della membrana, mentre la loro evoluzione temporale codifica il profilo di defocus e la risposta dielettrica alle diverse frequenze di stimolazione.

Tuttavia, la presenza di differenze morfologiche tra le linee cellulari pone un problema metodologico rilevante: esiste il rischio che la rete impari a classificare le cellule già a partire dalla loro apparenza statica, cioè dalla forma e dalla texture visibili in un singolo frame, senza sfruttare la dinamica temporale indotta dal protocollo ODEP, che costituisce invece l'elemento distintivo e innovativo di questo approccio. Per affrontare questo problema, la

strategia adottata prevede un confronto sistematico tra diverse configurazioni di rete descritto nella Sezione 3.4.3

3.4.2 Architettura della rete neurale R(2+1)D

La classificazione automatica delle tre linee cellulari viene affidata a una rete neurale convoluzionale basata sull'architettura R(2+1)D, progettata specificamente per l'analisi di sequenze video. La scelta di questa architettura è motivata dalla natura intrinsecamente spazio-temporale del dato prodotto dal sistema ODEP: ogni misura genera una sequenza di frame in cui sia la struttura spaziale della cellula in ogni singolo frame sia la sua evoluzione temporale nel corso dei cicli di stimolazione sono portatori di informazione diagnostica. Un modello che analizzasse i frame singolarmente perderebbe la dimensione temporale, ovvero il profilo di defocus, mentre un approccio puramente temporale ignorerebbe la morfologia cellulare. La R(2+1)D affronta entrambe le dimensioni in modo esplicito e separato. L'architettura complessiva della rete, illustrata in Figura 3.5, è composta da un layer convoluzionale iniziale (*conv1*) seguito da quattro stadi residui (*conv2–conv5*), ciascuno contenente blocchi di convoluzione (2+1)D, e da un layer di average pooling e un fully connected finale per la classificazione [107].

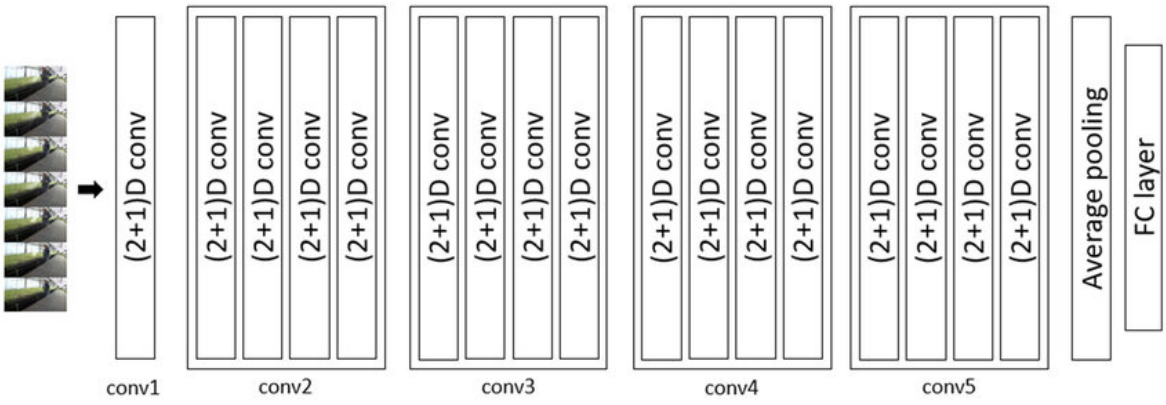


Figura 3.5: Architettura della rete R(2+1)D a 18 layer. *Adattata da [Liu et al., 2021]*

Per comprendere il principio su cui si basa questa architettura, è utile partire dal concetto di convoluzione applicata alle immagini. Una convoluzione consiste nel far scorrere un piccolo filtro, ad esempio una matrice di numeri di dimensione 3×3 pixel, sull'immagine: in ogni posizione il filtro calcola una combinazione pesata dei pixel vicini, estraendo automaticamente caratteristiche locali come bordi, texture e forme.

Estendere questo approccio ai video porta naturalmente alla convoluzione 3D: un filtro tridimensionale di dimensione $t \times d \times d$, dove t è la dimensione temporale e d quella spaziale, scorre simultaneamente nelle tre dimensioni, rilevando pattern che si evolvono nel tempo. Tuttavia, questo approccio presenta due limitazioni: il numero di parametri cresce rapidamente con le dimensioni del filtro, rendendo l'addestramento più difficile, e la fusione immediata di informazione spaziale e temporale in un unico passaggio non consente alla rete di imparare relazioni non-lineari tra le due dimensioni.

La R(2+1)D supera queste limitazioni decomponendo la convoluzione 3D in due operazioni distinte e sequenziali [108]. Il primo passaggio è una convoluzione 2D spaziale con filtro $1 \times d \times d$, che analizza un solo frame per volta ed estrae le caratteristiche visive di ogni singola immagine (forma della cellula, texture della membrana, pattern di rugosità superficiale); il secondo passaggio è una convoluzione 1D temporale con filtro $t \times 1 \times 1$, che analizza come le caratteristiche estratte nel passaggio precedente evolvono nel tempo (profilo di defocus, dinamica della risposta alla forza DEP). Tra i due passaggi viene inserita una funzione di attivazione ReLU, che introduce una non-linearità: le caratteristiche spaziali vengono filtrate prima di essere analizzate temporalmente, consentendo alla rete di apprendere relazioni non-lineari tra morfologia e dinamica che una convoluzione 3D classica non sarebbe in grado di cogliere, poiché in essa le due dimensioni vengono mescolate in un unico passaggio continuo senza interruzioni. Una rappresentazione schematica del confronto tra i due approcci è riportata in Figura 3.6.

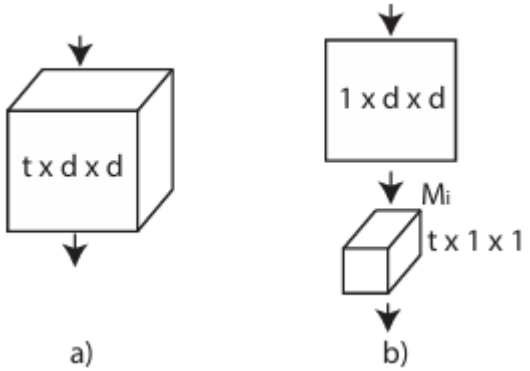


Figura 3.6: La R(2+1)D decompone la convoluzione 3D in una convoluzione 2D spaziale seguita da una convoluzione 1D temporale, con una funzione di attivazione ReLU intermedia. *[Adattata da Tran et al., 2018]*.

Questa decomposizione porta a tre vantaggi concreti rispetto alla convoluzione 3D classica: il numero di parametri da addestrare è inferiore, poiché due filtri più piccoli coprono lo stesso

spazio con meno moltiplicazioni rispetto a un unico filtro tridimensionale; l'addestramento risulta più stabile, perché la backpropagation, ossia il meccanismo con cui l'errore si propaga all'indietro per aggiornare i pesi della rete, funziona meglio su operazioni di spazio e tempo separate; la ReLU intermedia consente di catturare relazioni non-lineari tra le caratteristiche spaziali e temporali, aumentando la capacità espressiva della rete.

La rete è pre-addestrata sul dataset Kinetics-400, un ampio dataset di video d'azione che ha consentito alla rete di sviluppare filtri generalizzabili per il riconoscimento di pattern spazio-temporali. Il processo di addestramento sul dataset ODEP utilizza transfer learning: i pesi pre-addestrati vengono mantenuti come punto di partenza e l'addestramento finale adatta la rete al dominio specifico. L'ottimizzatore utilizzato è lo Stochastic Gradient Descent with Warm Restarts (SGDR), con momentum pari a 0.9, con un learning rate regolato tramite una strategia di cosine annealing. Ciascuna sequenza in ingresso ha dimensione [64 x 64] pixel, con 3 canali di colore ripetuti uguali (le immagini sono in scala di grigi), per 8 frame per cellula, organizzati in mini-batch da 64 video.

I frame non sono estratti con campionamento uniforme diretto: poiché ogni ciclo di stimolazione (corrispondente a una singola oscillazione nDEP/pDEP), comprende 110 frame acquisiti dalla camera, viene applicata una interpolazione lineare per ridurre la dimensione temporale a 8 frame equidistanti sull'asse temporale. Rispetto al campionamento diretto, l'interpolazione stima i valori intermedi tra frame adiacenti, preservando meglio la forma dell'oscillazione: la sequenza risultante cattura la messa a fuoco iniziale, la fase di risalita verso il massimo sfocamento, il picco e la fase di discesa, offrendo una rappresentazione compatta ma fedele della dinamica del ciclo, come illustrato in Figura 3.7.

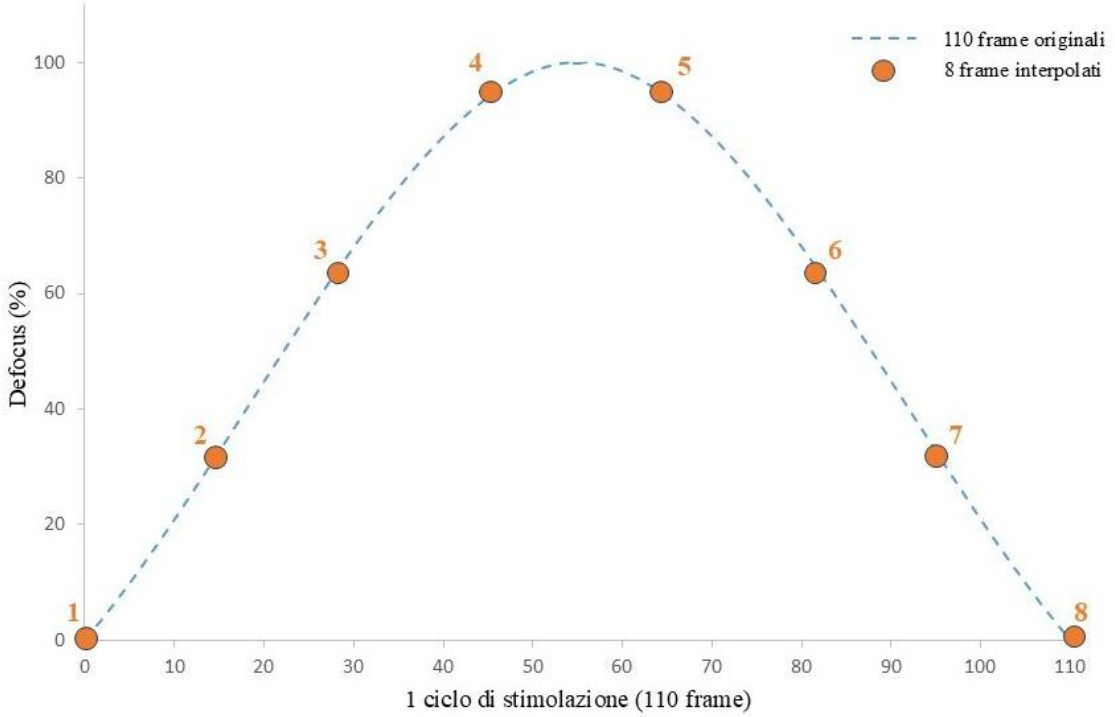


Figura 3.7: Schema concettuale dell'interpolazione lineare applicata a un ciclo di stimolazione: i 110 frame originali (curva tratteggiata) vengono ridotti a 8 frame equidistanti (punti arancioni) che coprono l'intera dinamica del ciclo, dalla cellula a fuoco (defocus = 0%) al picco di sfocamento massimo e al ritorno al piano focale.

La scelta di 8 frame per ciclo è un compromesso dettato dai tempi di addestramento disponibili; come discusso nella Sezione 4.4, aumentare questo numero è tra le priorità degli sviluppi futuri.

3.4.3 Strategia di confronto tra configurazioni

Come discusso nella Sezione 3.4.1, uno dei rischi principali nell'applicazione di reti neurali a questo tipo di dato è che il modello apprenda a classificare le cellule già a partire dalla loro apparenza morfologica statica, senza sfruttare la dinamica temporale indotta dal protocollo ODEP. Per quantificare separatamente il contributo dell'informazione morfologica statica e quello della dinamica temporale, vengono confrontate tre configurazioni distinte.

La prima è una rete 2D convenzionale progettata per l'analisi di singole immagini, basata sull'architettura SqueezeNet e pre-addestrata su ImageNet. Questa configurazione classifica sulla base dell'informazione spaziale statica: riceve in ingresso 8 frame per cellula, selezionati come i frame a fuoco dei primi 8 cicli di stimolazione (primo frame di ogni ciclo,

quando la cellula si trova al piano focale prima dell'attivazione della nDEP). Viene addestrato esclusivamente il layer convoluzionale finale (conv10), mantenendo congelato il resto della rete pre-addestrata. L'ottimizzatore utilizzato è Adam. L'architettura della rete, illustrata in Figura 3.8, si basa sul Fire module [109]: ogni modulo è composto da un layer di squeeze (filtri 1×1 che riducono la dimensionalità dei canali) seguito da un layer di expand (filtri 1×1 e 3×3 in parallelo che ne aumentano la rappresentatività).

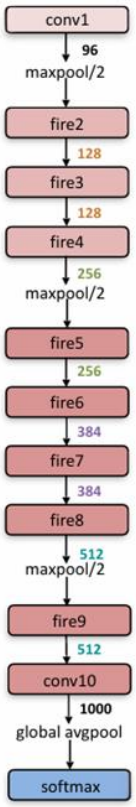


Figura 3.8: Architettura della rete 2D SqueezeNet. La rete è composta da un layer convoluzionale iniziale (conv1), otto Fire module con connessioni residuali e un layer convoluzionale finale (conv10), seguiti da global average pooling e classificatore softmax. *[Adattata da Iandola et al., 2016].*

I risultati ottenuti con questa configurazione forniscono una baseline che quantifica il contributo della sola morfologia alla classificazione: la rete vede la cellula a fuoco in 8 momenti temporalmente distinti della sessione di misura, senza alcuna informazione sul defocus o sulla dinamica del ciclo.

La seconda è la rete R(2+1)D in configurazione statica: la stessa architettura della configurazione dinamica riceve in ingresso 8 frame identici (lo stesso frame a fuoco ripetuto 8 volte), anziché 8 frame diversi che coprono la dinamica del ciclo. In questo modo la dimensione temporale è presente nell'architettura ma non porta alcuna informazione aggiuntiva rispetto alla singola immagine. Questa configurazione non ha un'utilità operativa in sé, ma è introdotta esclusivamente come test di controllo: confrontando i suoi risultati con la rete 2D convenzionale, con cui condivide l'informazione disponibile (stesso frame, sola morfologia), si isola l'effetto della diversa architettura indipendentemente dalla dinamica temporale; confrontandoli invece con la configurazione dinamica, a parità di architettura, si verifica se la rete dinamica stia effettivamente sfruttando la dimensione temporale, oppure se il suo vantaggio dipenda unicamente dalla struttura della rete.

La terza è la rete R(2+1)D in configurazione dinamica: riceve in ingresso la sequenza di 8 frame interpolati dall'intero ciclo di stimolazione, come descritto nella Sezione 3.4.2. Questa configurazione sfrutta simultaneamente l'informazione morfologica dei singoli frame e la dinamica temporale del defocus indotto dalla forza DEP, costituendo l'approccio completo proposto in questo lavoro.

Per tutte e tre le configurazioni la divisione del dataset in training (80%), validazione (10%) e test (10%) è effettuata con lo stesso seme di inizializzazione casuale (*random seed*), garantendo che le tre configurazioni operino sugli stessi campioni nei tre set e rendendo i confronti diretti e non influenzati da variazioni nella partizione dei dati. La validazione è cellula-indipendente: nessuna cellula compare contemporaneamente in più di un set. Il modello selezionato per la valutazione finale è quello che ha ottenuto la massima accuratezza sul set di validazione durante le 50 epoche di addestramento. Viene adottata la data augmentation durante la fase di training per aumentare la variabilità dei campioni visti dalla rete e migliorare la capacità di generalizzazione.

4. Capitolo 4: Risultati e Discussione

4.1 Dataset e Protocollo di Validazione

Il dataset utilizzato per l'addestramento e la valutazione dei modelli è stato costruito a partire dalle sessioni di misura descritte nel Capitolo 2, condotte sulle tre linee cellulari di carcinoma prostatico LNCaP, DU145 e PC3. Il dataset è bilanciato tra le tre classi e comprende, all'ottavo ciclo di stimolazione, 595 cellule totali.

La scelta di fermarsi all'ottavo ciclo, anziché all'undicesimo o al dodicesimo (che producono accuratezze leggermente superiori nel classificatore LDA, come mostrato nella Sezione 4.2), è motivata da un compromesso tra prestazioni e affidabilità del tracking: la procedura di centratura basata su Cellpose garantisce risultati affidabili almeno fino all'ottavo ciclo per tutte le cellule del dataset, mentre proseguendo oltre si osserva una riduzione del numero di cellule analizzabili, che renderebbe il dataset meno comparabile con quello degli altri approcci. L'ottavo ciclo rappresenta quindi un punto di equilibrio tra ampiezza del segnale disponibile e completezza del dataset.

La validazione è cellula-indipendente: la suddivisione in training (80%), validazione (10%) e test (10%), descritta nella Sezione 3.4.3, è effettuata garantendo che nessuna cellula compaia in più di un set. È importante sottolineare che i risultati presentati corrispondono a una singola esecuzione con seme fisso: per ottenere una stima più robusta dell'accuratezza media, come sviluppo futuro, sarebbe opportuno ripetere l'esperimento con più semi casuali e mediarne i risultati, analogamente a quanto fatto per il classificatore LDA tramite k-fold cross-validazione.

4.2 Risultati: valutazione dello sfocamento (LDA)

4.2.1 Accuratezza in funzione del numero di cicli

Il primo risultato riguarda la capacità del classificatore LDA di distinguere le tre linee cellulari analizzando esclusivamente il segnale scalare di defocus $\Delta C(t)$, senza alcuna informazione morfologica sui pixel. La Figura 4.1 mostra l'andamento dell'accuratezza di classificazione (media +/- deviazione standard su 10 fold) al variare del numero di cicli di stimolazione considerati, da 1 a 12, con il corrispondente numero di cellule analizzabili.

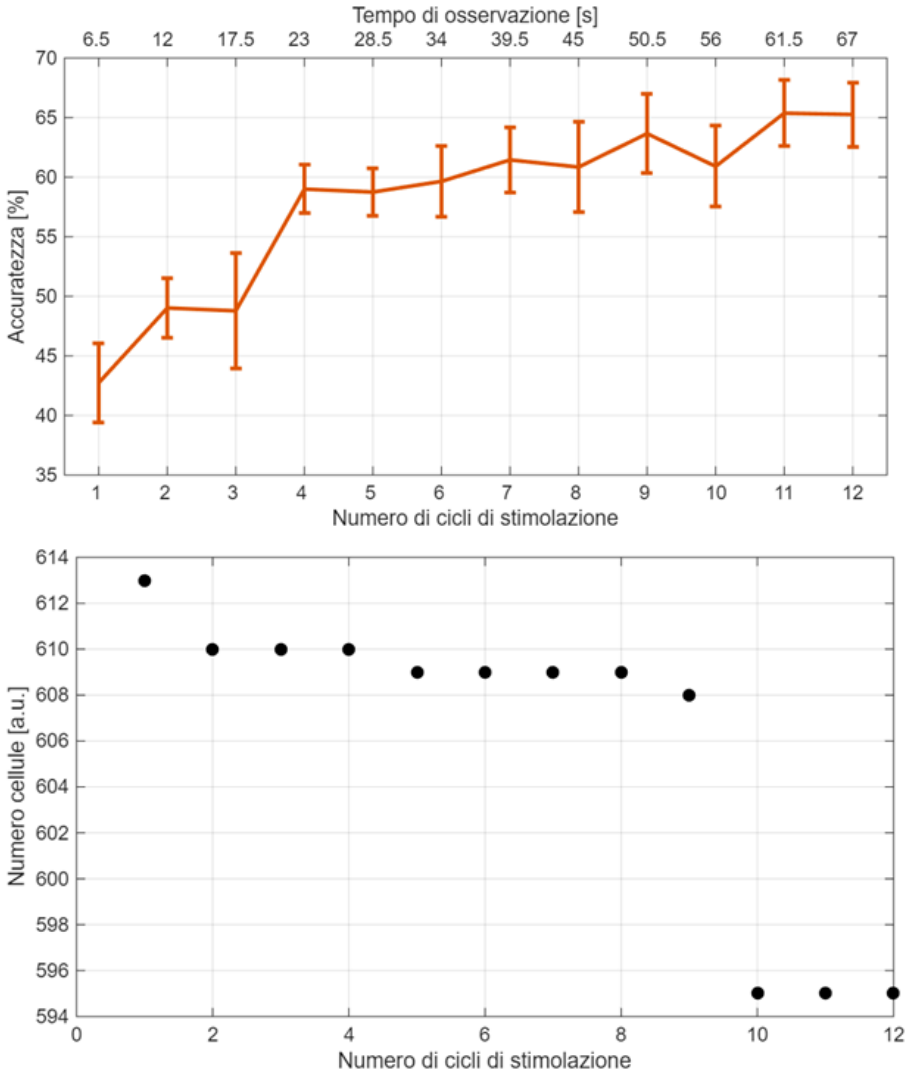


Figura 4.1: Accuratezza del classificatore LDA in funzione del numero di cicli di stimolazione (sopra). Numero di cellule analizzate al variare dei cicli (sotto).

L'accuratezza, che fornisce una misura globale della percentuale di cellule classificate correttamente, parte da valori intorno al 45% con il solo primo ciclo e cresce progressivamente all'aumentare del numero di cicli, riflettendo il fatto che osservare la cellula per un tempo più lungo, a un maggior numero di frequenze di stimolazione, arricchisce il segnale di defocus e ne aumenta il potere discriminativo. All'ottavo ciclo, corrispondente a un tempo di osservazione di circa 45 secondi, l'accuratezza è del 61.7% +/- 7.5% su 595 cellule totali. All'undicesimo ciclo raggiunge il suo valore massimo di 66.2% +/- 5.5% sulle stesse cellule. Il numero di cellule analizzabili si riduce leggermente all'aumentare dei cicli per effetto della perdita di tracking: si passa da 613 cellule al primo ciclo a 595 a partire dall'ottavo in poi.

4.2.2 Matrice di confusione

La matrice di confusione fornisce invece un quadro dettagliato degli errori di classificazione, mostrando per ciascuna classe quante cellule vengono correttamente identificate e quante vengono erroneamente assegnate alle altre linee. La Figura 4.2 riporta la matrice di confusione per l'ottavo ciclo, con appunto un numero totale di cellule pari a 595 (PC3: 202, LNCaP: 192, DU145: 215).

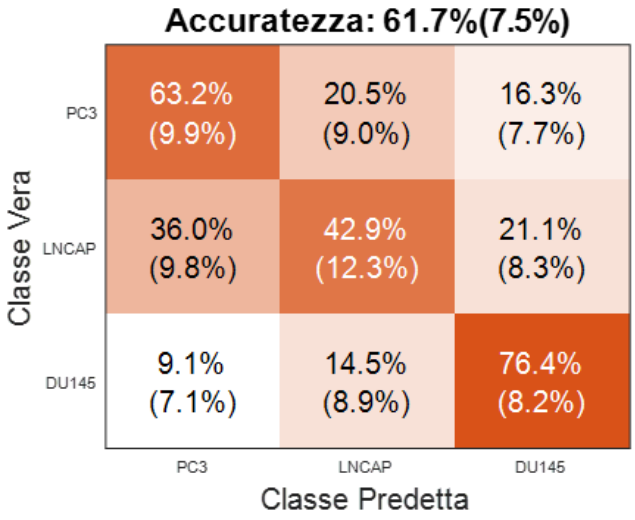


Figura 4.2: Matrice di confusione del classificatore LDA all'ottavo ciclo

La figura 4.3 riporta invece la matrice di confusione per l'undicesimo ciclo, sempre con 595 cellule (PC3: 200, LNCaP: 191, DU145: 204).

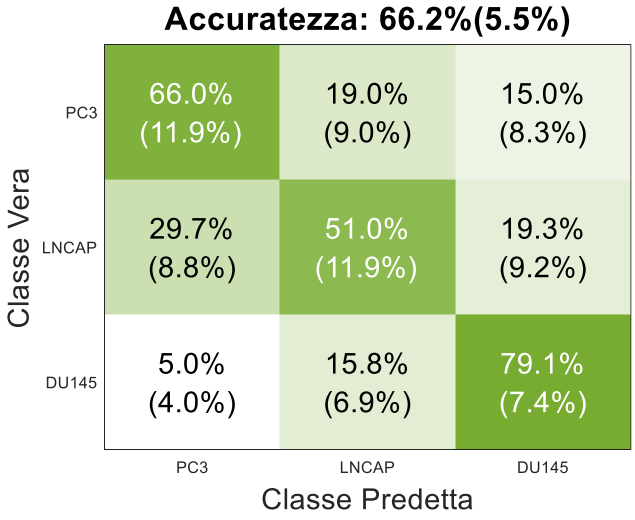


Figura 4.3: Matrice di confusione del classificatore LDA all'undicesimo ciclo.

4.2.3 Analisi dei risultati LDA

L'analisi delle matrici di confusione rivela un pattern consistente: DU145 è la linea classificata con maggiore accuratezza in entrambe le configurazioni (76.4% all'8° ciclo, 79.1% all'11° ciclo), mentre LNCaP risulta la più difficile da identificare (42.9% e 51.0% rispettivamente), con una quota significativa di cellule LNCaP erroneamente classificate come PC3 (36.0% all'8° ciclo).

Il risultato complessivo, ossia un'accuratezza massima del 66% su tre classi con il solo segnale di defocus scalare, dimostra che le proprietà dielettriche delle cellule contengono effettivamente informazione classificatoria, ma che questa informazione è insufficiente da sola. La riduzione del frame a un unico valore scalare comporta una perdita significativa: tutta la struttura spaziale della cellula viene collassata in un numero. Questo risultato motiva e giustifica l'adozione dell'approccio di deep learning che analizza direttamente i pixel dei frame.

4.3 Risultati: classificazione tramite Deep Learning

4.3.1 Rete 2D convenzionale (SqueezeNet)

La rete 2D convenzionale basata su SqueezeNet, che classifica sulla base di 8 frame a fuoco selezionati dai primi 8 cicli di stimolazione senza alcuna informazione temporale sul defocus, ottiene un'accuratezza bilanciata del 78% sul set di test. La curva di addestramento (Figura 4.4) mostra una convergenza regolare sia per l'accuratezza che per la loss, con training e validation che rimangono allineati nel corso delle 50 epoche di addestramento, senza evidenti fenomeni di overfitting.

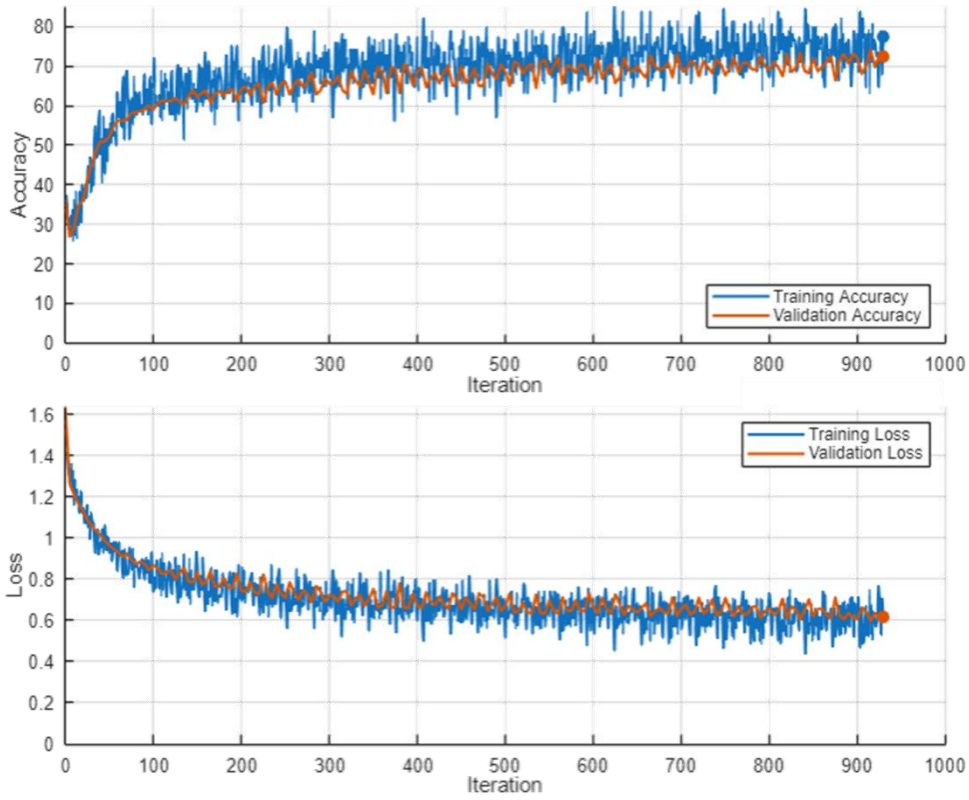


Figura 4.4: Curve di training e validation per la rete SqueezeNet 2D: accuratezza (sopra) e loss (sotto) in funzione delle iterazioni.

La matrice di confusione (Figura 4.5) riporta i seguenti valori:

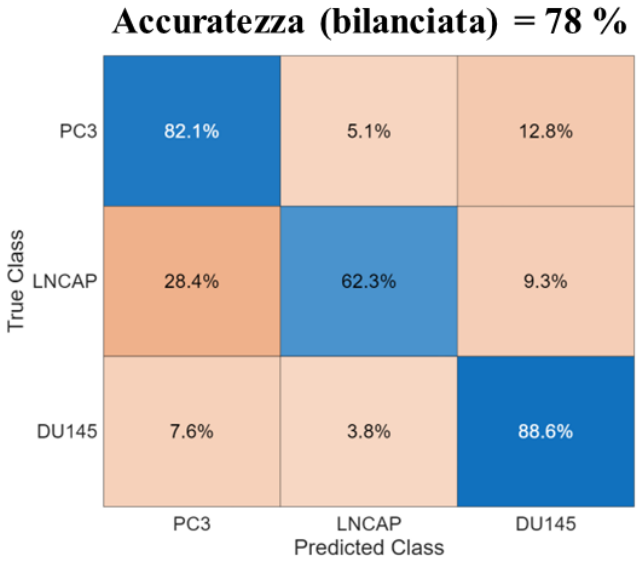


Figura 4.5: Matrice di confusione della rete SqueezeNet 2D.

DU145 è la linea classificata con la maggiore accuratezza (88.6%), seguita da PC3 (82.1%), mentre LNCaP rimane la più difficile da identificare (62.3%), con il 28.4% delle cellule LNCaP classificate erroneamente come PC3. Questo pattern di confusione è coerente con quanto osservato nel classificatore LDA. Il risultato di accuratezza del 78% ottenuto analizzando esclusivamente la morfologia statica della cellula a fuoco dimostra che le differenze morfologiche tra le tre linee cellulari sono sufficientemente marcate da essere discriminative per una rete 2D e stabilisce la baseline morfologica del sistema.

4.3.2 Rete R(2+1)D (configurazione statica)

La rete R(2+1)D in configurazione statica, in cui la sequenza in ingresso è composta dallo stesso frame a fuoco ripetuto identico per tutti gli 8 istanti temporali, ottiene un'accuratezza bilanciata del 75% sul set di test. La matrice di confusione (Figura 4.6) è riportata di seguito:

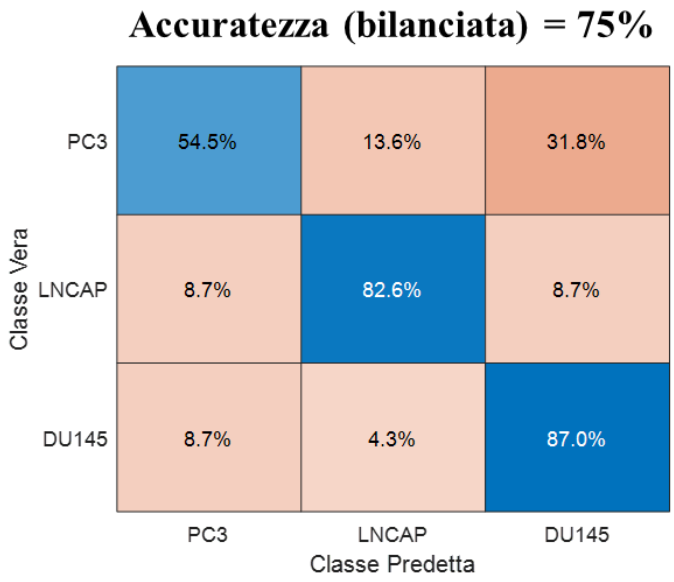


Figura 4.6: Matrice di confusione della rete R(2+1)D in configurazione statica.

Confrontando questo risultato con la rete 2D convenzionale (75% vs 78%), quest'ultima ottiene un'accuratezza leggermente superiore a parità di informazione disponibile (stesso frame, sola morfologia). Questo risultato è atteso: la R(2+1)D è pre-addestrata su Kinetics-400 per analizzare sequenze video con dinamica reale; quando le si fornisce lo stesso frame ripetuto, deve in qualche misura disimparare durante il fine-tuning la dipendenza temporale acquisita in pre-addestramento. Una rete più semplice ottimizzata per l'analisi di singole

immagini affronta il problema con la struttura appropriata e risulta più efficiente in questo scenario. Questo confronto conferma che il vantaggio della R(2+1)D rispetto alla baseline non dipende dall'architettura in sé, ma dall'informazione temporale che essa è in grado di sfruttare.

Vale inoltre la pena osservare che, rispetto alla rete 2D convenzionale, la configurazione statica R(2+1)D produce un pattern di confusione biologicamente più coerente: mentre la SqueezeNet confonde prevalentemente LNCaP con PC3 (28.4%), due linee che si collocano ai poli opposti del gradiente di aggressività metastatica, la R(2+1)D statica tende a confondere maggiormente PC3 con DU145, che condividono il fenotipo castrazione-resistente e androgeno-indipendente e presentano caratteristiche biologiche più simili tra loro. Questo suggerisce che, a parità di informazione morfologica disponibile, la diversa architettura stia catturando una struttura delle feature più aderente alla biologia sottostante.

4.3.3 Rete R(2+1)D (configurazione dinamica)

La rete R(2+1)D in configurazione dinamica, che riceve in ingresso la sequenza di 8 frame interpolati sull'intero ciclo di stimolazione, ottiene l'accuratezza bilanciata più alta tra tutti i modelli testati: 83% sul set di test.

La matrice di confusione (Figura 4.7) è riportata di seguito:

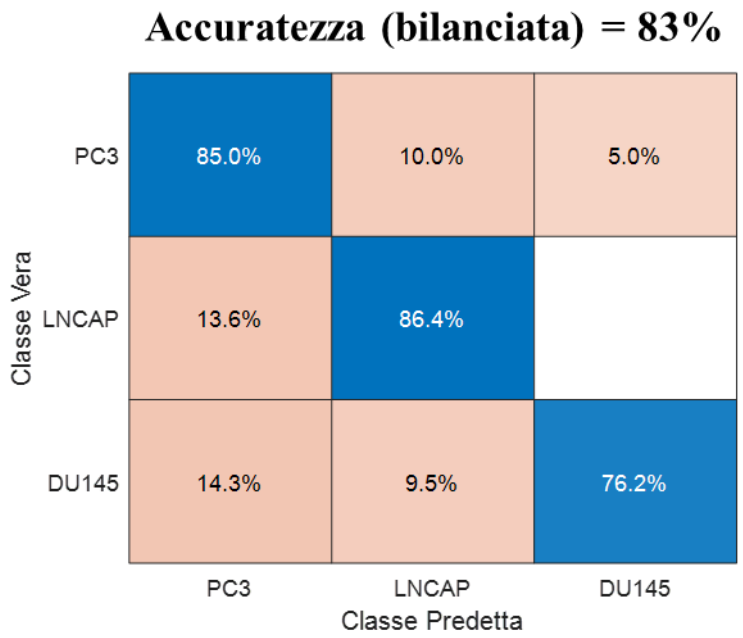


Figura 4.7: Matrice di confusione della rete R(2+1)D in configurazione dinamica.

Il confronto tra la configurazione R(2+1)D dinamica (83%) e quella statica (75%) mostra un netto miglioramento a parità di architettura, attribuibile esclusivamente alla presenza della dinamica temporale nell'input. Questo incremento dimostra in modo diretto che il profilo di defocus indotto dal protocollo ODEP, codificato nella sequenza temporale dei frame, fornisce informazioni discriminative che non sono accessibili dalla sola analisi morfologica statica, e che l'integrazione della dinamica temporale rappresenta quindi un contributo essenziale alla classificazione.

Il pattern della matrice di confusione presenta caratteristiche diverse rispetto alle configurazioni statiche. LNCaP, la linea più difficile da classificare nelle configurazioni statiche, raggiunge con la rete dinamica la sua accuratezza più elevata (86.4%). La linea che beneficia di meno dell'informazione temporale è DU145 (76.2%), che nelle configurazioni statiche era classificata con accuratezza maggiore (88.6% con la 2D, 87.0% con la R(2+1)D statica). Questo cambiamento suggerisce che la dinamica temporale sia particolarmente informativa per discriminare LNCaP dalle altre due linee, probabilmente perché la sua frequenza di crossover si distingue in modo netto da quella di DU145 e PC3 nella risposta alle frequenze di stimolazione del protocollo. Un aspetto degno di nota è che la rete R(2+1)D dinamica riduce sensibilmente la confusione tra LNCaP e PC3 rispetto alle configurazioni statiche: nelle reti senza informazione temporale, LNCaP viene frequentemente classificata erroneamente come PC3, come osservato nella sezione 4.3.2. Questo errore, biologicamente poco intuitivo, potrebbe essere attribuibile a una sovrapposizione parziale delle caratteristiche morfologiche statiche. L'introduzione della dinamica temporale sembra correggere in parte questo comportamento, migliorando la separazione tra le linee più distanti biologicamente. Al contrario, la confusione residua si concentra prevalentemente tra PC3 e DU145, che condividono caratteristiche biologiche più simili: questo è il pattern di errore atteso e biologicamente più coerente. L'interpretazione di questi pattern rimane tuttavia preliminare e andrà approfondita in studi futuri con dataset più ampi.

4.3.4 Confronto riassuntivo

La Tabella 4.1 riassume le prestazioni di tutte le configurazioni analizzate.

Modello	Input	Accuratezza bilanciata
LDA	24 feature da $\Delta C(t)$, 8 cicli	61.7% +/- 7.5%

SqueezeNet 2D	8 frame a fuoco distinti (morfologia)	78%
R(2+1)D statica	8 frame identici (morfologia)	75%
R(2+1)D dinamica	8 frame interpolati (morfologia + dinamica)	83%

Tabella 4.1: Confronto delle accuratezze bilanciate per le quattro configurazioni analizzate.

4.4 Conclusioni e sviluppi futuri

Il presente lavoro ha proposto e validato un approccio integrato per la caratterizzazione e stratificazione label-free di linee cellulari di carcinoma prostatico a diversa aggressività metastatica, basato sulla tecnologia ODEP con silicio amorfo e su tecniche di deep learning per l'analisi di sequenze video.

I risultati ottenuti dimostrano che l'integrazione della dinamica di defocus lungo l'asse z (una dimensione tipicamente trascurata nella classificazione cellulare basata su immagini) con l'informazione morfologica contenuta nei singoli frame, analizzate congiuntamente tramite una rete neurale spazio-temporale R(2+1)D, consente di raggiungere un'accuratezza bilanciata dell'83% nella discriminazione delle tre linee cellulari LNCaP, DU145 e PC3. Questo risultato supera sia la baseline morfologica statica (78% con SqueezeNet 2D) sia la classificazione basata sul solo segnale di defocus scalare (62% con LDA all'ottavo ciclo), confermando il valore aggiunto dell'approccio multimodale proposto.

Un elemento di originalità del sistema è l'utilizzo del moto lungo l'asse z come fonte di informazione: il profilo di defocus indotto dal protocollo ODEP riflette le proprietà dielettriche intrinseche della cellula, in particolare la posizione della sua frequenza di crossover, che dipende, oltre che dalla conducibilità del mezzo, dalla composizione e dalla struttura della membrana plasmatica, la quale è correlata al grado di aggressività del fenotipo tumorale. Integrare questo canale informativo con la morfologia visiva dei frame, tramite un'architettura in grado di elaborare entrambe le dimensioni in modo esplicito e separato, costituisce il contributo principale di questo lavoro rispetto agli approcci esistenti basati sull'analisi di singole immagini.

I risultati presentati hanno carattere preliminare e sono stati ottenuti con un numero ridotto di frame per clip (8 frame per ciclo, selezionati tramite interpolazione lineare da 110 frame originali) per ragioni di tempo computazionale. Gli sviluppi futuri più immediati riguardano:

- Aumento del numero di frame per clip: ci si aspetta un miglioramento delle prestazioni grazie a una rappresentazione più fedele della dinamica del ciclo.
- Stima robusta dell'accuratezza media: ripetere l'addestramento con molteplici semi di inizializzazione casuale e mediare i risultati, analogamente allo schema k-fold adottato per il classificatore LDA.
- Validazione esperimento-indipendente: estendere il protocollo di validazione a uno schema in cui il set di test comprende sessioni sperimentali complete mai viste durante l'addestramento, per valutare la capacità di generalizzazione in uno scenario clinicamente più realistico.
- Ottimizzazione dell'architettura: esplorare varianti della R(2+1)D con diversi numeri di layer, dimensioni dei filtri e strategie di regolarizzazione, nonché possibili architetture alternative specificamente progettate per segnali biomedici.
- Ampliamento del dataset: aumentare il numero di cellule per linea e di sessioni indipendenti per rafforzare la significatività statistica dei risultati e la loro generalizzabilità a nuove condizioni di misura.

Nel complesso, i risultati di questo lavoro suggeriscono che l'integrazione della dinamica di defocus lungo z con l'analisi morfologica tramite reti spazio-temporali rappresenta un approccio promettente per la stratificazione label-free dell’aggressività tumorale, con potenziali applicazioni nella diagnostica oncologica personalizzata e nel monitoraggio della risposta terapeutica.

BIBLIOGRAFIA

[1] Sandhu, S.; Moore, C.M.; Chiong, E.; Beltran, H.; Bristow, R.G.; Williams, S.G. Prostate cancer. Lancet 2021.

[2] Berish, Richard B., et al. "Translational models of prostate cancer bone metastasis." Nature Reviews Urology 15.7 (2018).

[3] Boyd, Lara K., Xueying Mao, and Yong-Jie Lu. "The complexity of prostate cancer: genomic alterations and heterogeneity." Nature reviews urology 9.11 (2012).

[4] Cooper, Colin S., et al. "Analysis of the genetic phylogeny of multifocal prostate cancer identifies multiple independent clonal expansions in neoplastic and morphologically normal prostate tissue." Nature genetics 47.4 (2015)

[5] Berglund, Emelie, et al. "Spatial maps of prostate cancer transcriptomes reveal an unexplored landscape of heterogeneity." Nature communications 9.1 (2018)

[6] Espiritu, Shadrielle Melijah G., et al. "The evolutionary landscape of localized prostate cancers drives clinical aggression." Cell 173.4 (2018)

[7] Banyard, Jacqueline, and Bruce R. Zetter. "The role of cell motility in prostate cancer." Cancer and Metastasis Reviews 17.4 (1998)

[8] Bitting, Rhonda L., et al. "The role of epithelial plasticity in prostate cancer dissemination and treatment resistance." Cancer and Metastasis Reviews 33.2 (2014).

[9] Marín-Aguilera, Mercedes, et al. "Epithelial-to-mesenchymal transition mediates docetaxel resistance and high risk of relapse in prostate cancer." Molecular cancer therapeutics 13.5 (2014): 1270-1284.

[10] Thiery JP. "Epithelial-mesenchymal transitions in development and pathologies." Curr Opin Cell Biol. 2003

[11] Khan MI, Hamid A, Adhami VM, Lall RK, Mukhtar H. "Role of Epithelial Mesenchymal Transition in Prostate Tumorigenesis." Curr Pharm Des. 2015

[12] Thiery JP. "Epithelial-mesenchymal transitions in tumour progression." Nat Rev Cancer. 2002; 2:442-454

[13] Nieto MA. "The ins and outs of the epithelial to mesenchymal transition in health and disease." Annu Rev Cell Dev Biol. 2011; 27:347-376

[14] Kalluri, Raghu, and Robert A. Weinberg. "The basics of epithelial-mesenchymal transition." The Journal of clinical investigation 119.6 (2009): 1420-1428.

[15] Ahmed, Hashim U., et al. "Diagnostic accuracy of multi-parametric MRI and TRUS biopsy in prostate cancer (PROMIS): a paired validating confirmatory study." The Lancet 389.10071 (2017): 815-822.

[16] Wen, Lu, et al. "Single-cell technologies: From research to application." The Innovation 3.6 (2022).

[17] Macey, Marion G. "Principles of flow cytometry." Flow cytometry: Principles and applications. Totowa, NJ: Humana Press, 2007. 1-15.

[18] Wilkerson, Melinda J. "Principles and applications of flow cytometry and cell sorting in companion animal medicine." Veterinary Clinics: Small Animal Practice 42.1 (2012): 53-71.

[19] Shapiro HM. (2004). Lasers for flow cytometry. Curr Protoc Cytom, 49, 1.1.9–.1.17.; Wilkerson, 2012

[20] Adan, Aysun, et al. "Flow cytometry: basic principles and applications." Critical reviews in biotechnology 37.2 (2017): 163-176.

[21] Zeng, Jia, et al. "A minimally invasive method for retrieving single adherent cells of different types from cultures." Scientific reports 4.1 (2014): 5424.

[22] Khan, Sumbul Jawed, et al. "A rapid, gentle and scalable method for dissociation and fluorescent sorting of imaginal disc cells for mRNA sequencing." Fly 10.2 (2016): 73-80.

[23] Qiu, X.L.; De Jesus, J.; Pennell, M.; Troiani, M.; Haun, J.B. Microfluidic device for mechanical dissociation of cancer cell aggregates into single cells. Lab Chip 2015

[24] Saadatpour, A.; Lai, S.; Guo, G.; Yuan, G.C. Single-cell analysis in cancer genomics. Trends Genet. 2015

[25] Liu, S.; Trapnell, C. Single-cell transcriptome sequencing: Recent advances and remaining challenges. F1000Research 2016

[26] Abraham, P.; Maliekal, T.T. Single cell biology beyond the era of antibodies: Relevance, challenges, and promises in biomedical research. Cell. Mol. Life Sci. 2017

[27] Bradbury, A.; Pluckthun, A. Standardize antibodies used in research. Nature 2015, Baker, M. Reproducibility crisis: Blame it on the antibodies. Nature 2015

[28] Hodzic, E. Single-cell analysis: Advances and future perspectives. Bosn. J. Basic Med. Sci. 2016

[29] Decarlo, K.; Emley, A.; Dadzie, O.E.; Mahalingam, M. Laser capture microdissection: Methods and applications. Methods Mol. Biol. 2011

[30] Ziegenhain, Christoph, et al. "Comparative analysis of single-cell RNA sequencing methods." Molecular cell 65.4 (2017): 631-643.

[31] Macosko, E.Z.; et al. Highly parallel genome-wide expression profiling of individual cells using nanoliter droplets. Cell 2015

[32] Klein, A.M.; et al. Droplet barcoding for single-cell transcriptomics applied to embryonic stem cells. Cell 2015

[33] Islam, S.; Zeisel, A.; Joost, S.; La Manno, G.; Zajac, P.; Kasper, M.; Lonnerberg, P.; Linnarsson, S. Quantitative single-cell RNA-seq with unique molecular identifiers. Nat. Methods 2014

[34] Kivioja, T.; Vaharautio, A.; Karlsson, K.; Bonke, M.; Enge, M.; Linnarsson, S.; Taipale, J. Counting absolute numbers of molecules using unique molecular identifiers. Nat. Methods 2012

[35] Kolodziejczyk, A.A.; Kim, J.K.; Svensson, V.; Marioni, J.C.; Teichmann, S.A. The technology and biology of single-cell RNA sequencing. Mol. Cell 2015

[36] Zhu, S.; et al. Advances in single-cell RNA sequencing and its applications in cancer research. Oncotarget 2017

[37] Hedlund, E.; Deng, Q. Single-cell RNA sequencing: Technical advancements and biological applications. Mol. Asp. Med. 2018

[38] Craighead, H. Future lab-on-a-chip technologies for interrogating individual molecules. Nature 2006

[39] Lichtenberg, J.; de Rooij, N.F.; Verpoorte, E. Sample pretreatment on microfabricated devices. Talanta 2002

[40] Salafi, T.; Zeming, K.K.; Zhang, Y. Advancements in microfluidics for nanoparticle separation. Lab Chip 2017

[41] Gopalan, V.; Islam, F.; Lam, A.K. Surface markers for the identification of cancer stem cells. Methods Mol. Biol. 2018

[42] Ansari, M.A. Temporal profile of m1 and m2 responses in the hippocampus following early 24 h of neurotrauma. J. Neurol. Sci. 2015

[43] Mansor, M.A.; Ahmad, M.R. Single cell electrical characterization techniques. Int. J. Mol. Sci. 2015

[44] Lin, D.M.; Loveall, B.; Ewer, J.; Deitcher, D.L.; Sucher, N.J. Characterization of mRNA expression in single neurons. Methods Mol. Biol. 2007

[45] Mach, A.J.; Di Carlo, D. Continuous Scalable Blood Filtration Device Using Inertial Microfluidics. Biotechnol. Bioeng. 2010

[46] Helton, K.L.; Nelson, K.E.; Fu, E.; Yager, P. Conditioning saliva for use in a microfluidic biosensor. Lab Chip 2008

[47] Yeo, J.C.; Kenry; Zhao, Z.; Zhang,, P.; Wang, Z.; Lim, C.T. Label-free extraction of extracellular vesicles using centrifugal microfluidics. Biomicrofluidics 2018
[48] Wu, J.; Cui, Y.; Xuan, S.; Gong, X. 3D-printed microfluidic manipulation device integrated with magnetic array. Microfluid. Nanofluid. 2018
[49] Ding, X.; Lin, S.-C.S.; Kiraly, B.; Yue, H.; Li, S.; Chiang, I.K.; Shi, J.; Benkovic, S.J.; Huang, T.J. On-chip manipulation of single microparticles, cells, and organisms using surface acoustic waves. Proc. Natl. Acad. Sci. USA 2012
[50] Lazar, I.M.; Trisiripisal, P.; Sarvaiya, H.A. Microfluidic liquid chromatography system for proteomic applications and biomarker screening. Anal. Chem. 2006
[51] Khatri, K.; Klein, J.A.; Haserick, J.R.; Leon, D.R.; Costello, C.E.; McComb, M.E.; Zaia, J. Microfluidic Capillary Electrophoresis Mass Spectrometry for Analysis of Monosaccharides, Oligosaccharides, and Glycopeptides. Anal. Chem. 2017
[52] Abd Rahman, N.; Ibrahim, F.; Yafouz, B. Dielectrophoresis for Biomedical Sciences Applications: A Review. Sensors 2017
[53] Fernandez, R.E.; Rohani, A.; Farmehini, V.; Swami, N.S. Review: Microbial analysis in dielectrophoretic microfluidic systems. Anal. Chim. Acta 2017
[54] Pohl HA. The Motion and Precipitation of Suspensoids in Divergent Electric Fields. J Appl Phys 1951; Pohl HA, Schwar JP. Factors Affecting Separation of Suspensions in Nonuniform Electric Fields. J Appl Phys 1959
[55] Khoshmanesh, K.; Nahavandi, S.; Baratchi, S.; Mitchell, A.; Kalantar-zadeh, K. Dielectrophoretic platforms for bio-microfluidic systems. Biosens. Bioelectron. 2011
[56] Khoshmanesh, Khashayar, et al. "Dielectrophoretic platforms for bio-microfluidic systems." Biosensors and Bioelectronics 26.5 (2011): 1800-1814.
[57] Alazzam, A.; Mathew, B.; Alhammadi, F. Novel microfluidic device for the continuous separation of cancer cells using dielectrophoresis. J. Sep. Sci. 2017
[58] R. Pethig, “The Clausius – Mossotti Factor,” 2017
[59] A. Mortadi, A. El Melouky, E. G. Chahid, R. El Moznine, and O. Cherkaoui, “Studies of the clausius–Mossotti factor,” J. Phys. Stud., vol. 20, no. 4, pp. 4001-1-4001–4, 2016
[60] R. Omori, “Observation of a single-beam gradient-force optical trap for dielectric particles in air,” 1997
[61] R. Pethig, “The Clausius–Mossotti Factor,” Dielectrophoresis, pp. 119–144, Mar. 2017
[62] Russo, Giorgio Ivan, et al. "The role of dielectrophoresis for cancer diagnosis and prognosis." Cancers 14.1 (2021): 198.

[63] Ohta, Aaron T., et al. Optoelectronic tweezers for the manipulation of cells, microparticles, and nanoparticles. Vol. 2. InTech, 2010.
[64] Raicu, Valerică, Georgeta Raicu, and Grigore Turcu. "Dielectric properties of yeast cells as simulated by the two-shell model." Biochimica et Biophysica Acta (BBA)-Bioenergetics 1274.3 (1996): 143-148.
[65] Moncada-Hernandez H, Baylon-Cardiel JL, Pérez-González VH, H. L-E. "Insulator-based dielectrophoresis of microorganisms: Theoretical and experimental results." Electrophoresis 2011
[66] Gascoyne, P.R.C.; Shim, S. Isolation of Circulating Tumor Cells by Dielectrophoresis. Cancers 2014, 6, 545-579.
[67] Chan JY, Ahmad Kayani A Bin, Md Ali MA, Kok CK, Yeop Majlis B, Hoe SLL et al. 1070 Dielectrophoresis-based microfluidic platforms for cancer diagnostics. Biomicrofluidics 2018
[68] Henslee EA, Sano MB, Rojas AD, Schmelz EM, Davalos R V. Selective concentration of human 1088 cancer cells using contactless dielectrophoresis. Electrophoresis 2011
[69] P. R. C. Gascoyne and S. Shim, “Isolation of Circulating Tumor Cells by Dielectrophoresis,” Cancers (Basel)., vol. 6, no. 1, pp. 545–579, Mar. 2014
[70] Russo, Giorgio Ivan, et al. "The role of dielectrophoresis for cancer diagnosis and prognosis." Cancers 14.1 (2021): 198.
[71] P. R. C. Gascoyne, X. B. Wang, Y. Huang, and R. F. Becker, “Dielectrophoretic separation of cancer cells from blood,” IEEE Trans. Ind. Appl., vol. 33
[72] Zhang, Shuailong, et al. "Optoelectronic tweezers: a versatile toolbox for nano-/micro-manipulation." Chemical Society Reviews 51.22 (2022): 9203-9242
[73] Liang, Shuzhang, et al. "Interaction between positive and negative dielectric microparticles/microorganism in optoelectronic tweezers." Lab on a Chip 21.22 (2021): 4379-4389.
[74] Liang, Shuzhang, et al. "Interaction between positive and negative dielectric microparticles/microorganism in optoelectronic tweezers." Lab on a Chip 21.22 (2021): 4379-4389.
[75] Zhao, Kai, et al. "Optically-induced dielectrophoresis: A versatile platform for advanced micromanipulation, precision separation, and integrated device assembly." TrAC Trends in Analytical Chemistry 198 (2026): 118760.

[76] Filippi, J., et al. "Exploiting spectral information in Opto-Electronic Tweezers for cell classification and drug response evaluation." Sensors and Actuators B: Chemical 368 (2022): 132200.
[77] Filippi, Joanna, et al. "Cell Electrokinetic Fingerprint: A Novel Approach Based on Optically Induced Dielectrophoresis (ODEP) for In-Flow Identification of Single Cells." Small Methods 8.8 (2024): 2300923.
[78] Filippi, Joanna, et al. "ODEP-Based Robotic System for Micromanipulation and In-Flow Analysis of Primary Cells." Cyborg and Bionic Systems 6 (2025): 0234.
[79] Filippi, J., et al. "An Optically-Induced Dielectrophoresis-Based Platform for Enhanced Identification of Prostate Cancer Cells with Dif-ferent Grades of Malignancy.
[80] Eulenberg, Philipp, et al. "Reconstructing cell cycle and disease progression using deep learning." Nature communications 8.1 (2017): 463.
[81] Tran, Du, et al. "Learning spatiotemporal features with 3D convolutional networks." Proceedings of the IEEE international conference on computer vision. 2015.
[82] D'Orazio, Michele, et al. "Domain adaptation to enhance (2+1)D CNN dynamic analysis of cell collective behavior in time-lapse microscopy videos." Neural Computing and Applications 37 (2025): 4133–4153.
[83] Feng, Lin, et al. Optoelectronic Tweezers for Manipulation at the Micro and Nano Scale. John Wiley & Sons, 2026.
[84] Valley, Justin K., et al. "Optoelectronic tweezers as a tool for parallel single-cell manipulation and stimulation." IEEE transactions on biomedical circuits and systems 3.6 (2009): 424-431.
[85] Aydın, Elif Burcu, and Mustafa Kemal Sezgintürk. "Indium tin oxide (ITO): A promising material in biosensing technology." TrAC Trends in Analytical Chemistry 97 (2017): 309-315.
[86] Pawar, Eshwar. "A review article on acrylic PMMA." IOSR J. Mech. Civ. Eng 13.2 (2016): 1-4.
[87] Filippi, Joanna, et al. "ODEP-Based Robotic System for Micromanipulation and In-Flow Analysis of Primary Cells." Cyborg and Bionic Systems 6 (2025): 0234.
[88] Filippi, J., et al. "Exploiting spectral information in Opto-Electronic Tweezers for cell classification and drug response evaluation." Sensors and Actuators B: Chemical 368 (2022): 132200.

[89] Filippi, Joanna, et al. "Cell Electrokinetic Fingerprint: A Novel Approach Based on Optically Induced Dielectrophoresis (ODEP) for In-Flow Identification of Single Cells." Small Methods 8.8 (2024): 2300923.
[90] Tai, Sheng, et al. "PC3 is a cell line characteristic of prostatic small cell carcinoma." The Prostate 71.15 (2011): 1668-1679.
[91] Huang J, Yao JL, di Sant'agnese PA, Yang Q, Bourne PA, Na Y. Immunohistochemical characterization of neuroendocrine cells in prostate cancer. Prostate 2006;66:1399–1406.
[92] Horoszewicz JS, Leong SS, Chu TM, WajsmanZL, Friedman M, Papsidero L, Kim U, Chai LS, Kakati S, Arya SK, Sandberg AA. The LNCaP cell line—A new model for studies on human prostatic carcinoma. Prog Clin Biol Res 1980;37:115–132.
[93] Horoszewicz JS, Leong SS, Kawinski E, Karr JP, Rosenthal H, Chu TM, Mirand EA, Murphy GP. LNCaP model of human prostatic carcinoma. Cancer Res 1983;43:1809–1818.
[94] Cooperberg MR, Park S, Carroll PR. Prostate cancer 2004: Insights from national disease registries. Oncology (Williston Park) 2004;18:1239–1247; discussion 48–50, 56–58.
[95] Stone KR, Mickey DD, Wunderli H, Mickey GH, Paulson DF. Isolation of a human prostate carcinoma cell line (DU 145). Int J Cancer 1978; 21: 274–81.
[96] Chlenski A, Nakashiro K, Ketels KV, Korovaitseva GI, Oyasu R. Androgen receptor expression in androgen-independent prostate cancer cell lines. Prostate 2001; 47: 66–75.
[97] Naeem, Abdulghani A., et al. "Prostate cell lines." Journal of Oncology and Medicine (2022).
[98] Kaighn ME, Narayan KS, Ohnuki Y, Lechner JF, Jones LW. Establishment and characterization of a human prostatic carcinoma cell line (PC-3). Investig Urol 1979;17:16–23.
[99] van Bokhoven A, Varella-Garcia M, Korch C, Johannes WU, Smith EE, Miller HL, Nordeen SK, Miller GJ, Lucia MS. Molecular characterization of human prostate carcinoma cell lines. Prostate 2003;57:205–225.
[100] Hyler, Alexandra R., et al. "A novel ultralow conductivity electromanipulation buffer improves cell viability and enhances dielectrophoretic consistency." Electrophoresis 42.12-13 (2021): 1366-1377.
[101] Filippi, Joanna, et al. "ODEP-Based Robotic System for Micromanipulation and In-Flow Analysis of Primary Cells." Cyborg and Bionic Systems 6 (2025): 0234.
[102] Stringer, Carsen, et al. "Cellpose: a generalist algorithm for cellular segmentation." Nature methods 18.1 (2021): 100-106.

[103] Beghdadi, Azeddine, et al. "A critical analysis on perceptual contrast and its use in visual information analysis and processing." IEEE Access 8 (2020): 156929-156953.
[104] Wiebel, C. B., Singh, M., & Maertens, M. (2016). Testing the role of Michelson contrast for the perception of surface lightness. Journal of Vision, 16(11):17, 1–19. doi:10.1167/16.11.17
[105] Filippi, J., et al. "An Optically-Induced Dielectrophoresis-Based Platform for Enhanced Identification of Prostate Cancer Cells with Dif-ferent Grades of Malignancy.
[106] Zhao, Shuping, et al. "Linear discriminant analysis." Nature Reviews Methods Primers 4.1 (2024): 70.
[107] Liu, Liang-Chien, Dan Jeric Arcega Rustia, and Ta-Te Lin. "Remote surveillance video activity recognition using spatiotemporal convolutional neural networks for greenhouse workload analysis." 2021 ASABE Annual International Virtual Meeting. American Society of Agricultural and Biological Engineers, 2021.
[108] Tran, Du, et al. "A closer look at spatiotemporal convolutions for action recognition." Proceedings of the IEEE conference on Computer Vision and Pattern Recognition. 2018.
[109] Iandola, Forrest N., et al. "SqueezeNet: AlexNet-level accuracy with 50x fewer parameters and< 0.5 MB model size." *arXiv preprint arXiv:1602.07360* (2016).

Ringraziamenti

Giunta alla fine di questo percorso, sento il bisogno di ringraziare tutti coloro che mi hanno accompagnata e sostenuta in questi anni di studio.

In particolare, desidero esprimere la mia gratitudine al mio relatore, il Prof. Eugenio Martinelli, per aver reso possibile questo lavoro grazie al suo supporto, per la fiducia che ha riposto in me sin dall'inizio e per l'umanità e la comprensione che ha sempre dimostrato.

Un ringraziamento speciale va alla mia correlatrice, la Dott.ssa Joanna Filippi, per aver condiviso con me le sue competenze con estrema pazienza e disponibilità e per essere stata un grande esempio da seguire.

Desidero inoltre ringraziare la Prof.ssa Arianna Mencattini per aver seguito con sguardo critico il mio lavoro di tesi e aver rappresentato un valido riferimento durante questo percorso universitario.

Un sentito ringraziamento va infine alla ricercatrice Paola Casti per la grande professionalità e per l'essenziale supporto tecnico fornito.